RECONSTRUCCIÓN MUOGRÁFICA POR TRANSMISIÓN ASISTIDA POR APRENDIZAJE PROFUNDO MEDIANTE MEJORA PREDICTIVA DE IMÁGENES DE BAJA ESTADÍSTICA PARA EXPLORACIÓN VOLCÁNICA

Reinaldo Cárdenas Tirado, 2190201
Daniel Andrés Pinto Ortega, 2190558

UNIVERSIDAD INDUSTRIAL DE SANTANDER
FACULTAD DE INGENIERÍAS FISICOMECÁNICAS
ESCUELA DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
PROGRAMA DE INGENIERÍA DE SISTEMAS
BUCARAMANGA
2026

RECONSTRUCCIÓN MUOGRÁFICA POR TRANSMISIÓN ASISTIDA POR APRENDIZAJE PROFUNDO MEDIANTE MEJORA PREDICTIVA DE IMÁGENES DE BAJA ESTADÍSTICA PARA EXPLORACIÓN VOLCÁNICA

Trabajo de grado, modalidad Trabajo de Investigación,
para optar al título de
Ingeniero de Sistemas

Autores:
Reinaldo Cárdenas Tirado, 2190201
Daniel Andrés Pinto Ortega, 2190558

Director:
Profesor: Andrés Leonardo González Gómez, PhD(c).
Candidato a Doctor en Ciencias de la Computación

Codirector:
Profesor: Jaime Enrique Meneses Fonseca, PhD.
Doctor en Ciencias para la Ingeniería

UNIVERSIDAD INDUSTRIAL DE SANTANDER
FACULTAD DE INGENIERÍAS FISICOMECÁNICAS
ESCUELA DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
PROGRAMA DE INGENIERÍA DE SISTEMAS
BUCARAMANGA
2026

Índice general

Índice de tablas **IV**

Índice de figuras **V**

Resumen **VI**

Abstract **VII**

1 Introducción **1**

1.1 Contexto y planteamiento del problema 1
1.2 Justificación 3
1.3 Objetivos 4
1.3.1 Objetivo general 4
1.3.2 Objetivos específicos 4
1.4 Alcance del trabajo 5
1.5 Organización del documento 6

2 Marco teórico **7**

2.1 Muones cósmicos y su paso por la materia 7
2.2 Imagen muográfica por transmisión 9
2.3 Estadística de conteo y exposición 11
2.4 Simulación Monte Carlo del transporte de muones 13
2.5 Aprendizaje profundo para la mejora de imágenes 14
2.6 Métricas de calidad y conservación 16
2.7 Aprendizaje profundo en muografía 18

3 Metodología **20**

3.1 Diseño del estudio y secuencia experimental 20
3.1.1 Alcance y unidades de análisis 20
3.1.2 Versiones y condiciones de comparación 21
3.2 Escenarios y simulación de muones 22
3.2.1 Catálogo y asignación de materiales 22
3.2.2 Fuente y observable 24
3.2.3 Número de muones simulados y consolidación 25
3.2.4 Coordenadas y exportación 26
3.3 Verificación y preparación del conjunto 27

3.3.1 Integridad, bordes y estadística de roca 27
3.3.2 Construcción de pares 29
3.3.3 Particiones y contrato de datos 29
3.4 Representación de conteos y arquitectura 31
3.4.1 Normalización disponible en inferencia 31
3.4.2 Generador y crítico 32
3.4.3 Pérdidas y coherencia del gradiente 33
3.5 Entrenamiento y desarrollo experimental 35
3.5.1 Piloto y selección con validación 35
3.5.2 Ajustes regionales y espaciales 36
3.6 Evaluación de similitud y conservación de cuentas 37
3.6.1 Congelamiento e inferencia 37
3.6.2 Métricas de imagen 39
3.6.3 Regiones, sesgo y error espacial 39
3.6.4 Contraste y corrección numérica 42
3.6.5 Agregación e interpretación 42
3.7 Evaluación multifracción y métricas locales 43
3.7.1 Diseño del complemento y conservación de los modelos 43
3.7.2 Indicadores locales de anomalía y fondo 43
3.7.3 Agregación de errores y conservación del signo 46
3.8 Criterio de reducción y diagnóstico de opacidad 46
3.8.1 Exposición convencional y comparación operativa 46
3.8.2 Fracción mínima y factor asociado 47
3.8.3 Opacidad nominal y controles geométricos 48
3.9 Reproducibilidad y trazabilidad 49

4 Resultados y discusión **51**
4.1 Conjunto sintético y controles de la campaña 51
4.1.1 Producto obtenido y diversidad de las referencias 51
4.1.2 Respuesta en los bordes angulares 52
4.1.3 Suficiencia de conteo en roca y conservación de excepciones . . 53
4.1.4 Integridad, reproducción y alcance del primer objetivo 54
4.2 Recuperación de imágenes al cinco por ciento 55
4.2.1 Modelos seleccionados y resultado de similitud 55
4.2.2 Compromiso entre similitud y conservación regional 58
4.2.3 Efecto de la pérdida espacial de borde 59
4.3 Transferencia de los modelos a otras fracciones 60
4.3.1 Evaluación completa y correspondencia entre entregas 60

4.3.2 Respuesta de la cGAN frente a la estadística de entrada . . . 61
4.4 Conservación de anomalías y métricas locales . . . 62
4.4.1 Soportes y lectura conjunta de los indicadores . . . 62
4.4.2 Suavizado, señal local y límites de detectabilidad . . . 63
4.5 Factor de reducción y diagnóstico de opacidad . . . 64
4.5.1 Resultado del criterio operativo por vista . . . 64
4.5.2 Comparación descriptiva con el doble de conteos . . . 65
4.5.3 Opacidad nominal y diferencia respecto de una inversión . . . 65
4.6 Discusión integrada y alcance de los resultados . . . 67
4.6.1 Correspondencia entre la tarea aprendida y la calidad evaluada 67
4.6.2 Dependencia de los datos y alcance de generalización . . . 67
4.6.3 Balance del experimento concluido . . . 68

5 Conclusiones y trabajo futuro 69
5.1 Conclusión del primer objetivo específico . . . 69
5.2 Conclusión del segundo objetivo específico . . . 69
5.3 Conclusión del tercer objetivo específico . . . 70
5.4 Conclusión general . . . 70
5.5 Trabajo futuro . . . 71

Referencias 73

A Protocolo propuesto para estimar el factor de reducción 78

Índice de tablas

3.1 Etapas metodológicas y productos del estudio. 21
3.2 Configuración de la campaña corregida. 25
3.3 Escenarios, vistas y pares por partición. 30
3.4 Niveles del codificador del generador. 33
3.5 Configuración común del piloto y diferencias entre métodos. 35
3.6 Definición geométrica de las regiones de evaluación. 40
3.7 Diseño de la evaluación multifracción OE3-C1. 44
3.8 Información para reproducir e interpretar la cadena. 50

4.1 Vistas bajo la meta descriptiva de roca 53
4.2 Evaluación de todos los modelos al 5 % 56
4.3 Comparación pareada del error de borde 60
4.4 cGAN y entrada sin red en cuatro fracciones 61
4.5 Errores locales de entrada y cGAN al 5 % 63
4.6 Balance del criterio conjunto por vista 64
4.7 Balance de resultados y alcance de los tres objetivos. 68

5.1 Limitaciones identificadas y posibles líneas de investigación 71

Índice de figuras

2.1 La imagen muográfica por transmisión como proyección 10
2.2 Media sobre desviación estándar y ruido relativo de un conteo de Poisson 12
2.3 Esquema conceptual de una red generativa antagónica condicional de Wasserstein 17

3.1 Secuencia experimental y separación de las particiones. 21
3.2 Geometría idealizada y posiciones de observación 23
3.3 Coordenadas y malla angular 26
3.4 Referencia y pares de conteo 30
3.5 Normalización y recuperación de cuentas 32
3.6 Generador U-Net y crítico condicional 34
3.7 Secuencia de ensayos y modelos finales 38
3.8 Regiones y controles de evaluación 40
3.9 Diseño de la evaluación multifracción y del criterio de reducción. . . . 44

4.1 Referencias del conjunto corregido en escenarios y vistas seleccionados. 52
4.2 Control de respuesta en bordes angulares 53
4.3 Suficiencia de conteo en roca por geometría y vista. 54
4.4 Comparación de referencia, entrada y modelos originales en casos fijados por índice. 57
4.5 Similitud frente a sesgo regional al 5 % 58
4.6 Error espacial de borde por geometría 59
4.7 Similitud y sesgo regional de los modelos en las cuatro fracciones. . . 62
4.8 Contribuciones nominales de densidad y longitud en los controles geométricos. 66

Resumen

Título: Reconstrucción muográfica por transmisión asistida por aprendizaje profundo mediante mejora predictiva de imágenes de baja estadística para exploración volcánica[1]

Autores: Reinaldo Cárdenas Tirado; Daniel Andrés Pinto Ortega.[2]

Palabras clave: muografía por transmisión, exploración volcánica, aprendizaje profundo, simulación Monte Carlo, mejora de imágenes, baja estadística.

Descripción:

La muografía por transmisión estima la distribución de densidad en el interior de un volcán a partir de la atenuación del flujo de muones cósmicos, pero el bajo flujo natural exige exposiciones de semanas o meses para que los contrastes de densidad se distingan del ruido de conteo. Este trabajo investigó si un modelo de aprendizaje profundo entrenado con datos sintéticos puede transformar imágenes muográficas de baja estadística en imágenes de calidad comparable a las de alta estadística y, con ello, reducir el tiempo efectivo de adquisición en exploración volcánica. Mediante simulación Monte Carlo con Geant4 y EcoMug se obtuvieron 114 referencias de diecinueve escenarios volcánicos idealizados y, por submuestreo binomial, 9 120 pares con el 50, 10, 5 y 1 % de los conteos, particionados por geometría. Con el 5 % se entrenaron una red generativa antagónica condicional de Wasserstein (cGAN), un control U-Net y seis continuaciones con pérdidas regionales y de borde, evaluados después con las cuatro fracciones. En una evaluación descriptiva sobre datos potencialmente expuestos, la cGAN aumentó en prueba el SSIM de 0,7643 a 0,8342 y el PSNR de 24,258 a 31,170 dB respecto de su entrada, por debajo de la U-Net, y superó en ambas métricas a la entrada sin red con el doble de conteos en las veinticuatro vistas reservadas, pero el sesgo regional de cuentas pasó de 1,832 a 14,566 %. Ninguna de las 768 combinaciones de modelo, fracción y vista alcanzó conjuntamente el SSIM y el PSNR de la entrada sin red al 50 %, por lo que el factor de reducción no quedó determinado bajo ese criterio. Los indicadores locales, calculados en anomalías de ubicación conocida, mostraron mejoras y deterioros simultáneos y no demuestran la detección de anomalías desconocidas. Se concluye que el conjunto sintético cumplió su objetivo, que la calidad comparable quedó respaldada solo de forma parcial y que no se demostró un factor de reducción del tiempo de adquisición ni una equivalencia cuantitativa de opacidad. Los resultados se limitan a escenarios sintéticos, sin detector físico ni datos de campo.

[1]Trabajo de grado, modalidad Trabajo de Investigación.

[2]Facultad de Ingenierías Fisicomecánicas. Escuela de Ingeniería de Sistemas e Informática. Director: Andrés Leonardo González Gómez, PhD(c).Codirector: Jaime Enrique Meneses Fonseca, PhD.

Abstract

Title: Deep learning-assisted transmission muographic reconstruction through predictive enhancement of low-statistics images for volcanic exploration.[3]

Authors: Reinaldo Cárdenas Tirado; Daniel Andrés Pinto Ortega.[4]

Keywords: transmission muography, volcanic exploration, deep learning, Monte Carlo simulation, image enhancement, low statistics.

Description:

Transmission muography estimates the density distribution inside a volcano from the attenuation of the cosmic-ray muon flux, but the low natural flux requires exposures of weeks or months before density contrasts can be distinguished from counting noise. This work investigated whether a deep learning model trained on synthetic data can transform low-statistics muographic images into images of quality comparable to high-statistics ones and thereby reduce the effective acquisition time in volcanic exploration. Monte Carlo simulations with Geant4 and EcoMug produced 114 references of nineteen idealized volcanic scenarios and, through binomial thinning, 9,120 input–reference pairs with 50, 10, 5 and 1 % of the counts, partitioned by geometry. With 5 % of the counts, a conditional Wasserstein generative adversarial network (cGAN), a U-Net baseline and six continuations with regional and boundary losses were trained and later evaluated at the four fractions. In a descriptive evaluation on potentially exposed data, the cGAN increased the test SSIM from 0.7643 to 0.8342 and the PSNR from 24.258 to 31.170 dB with respect to its input, below the U-Net, and outperformed on both metrics the unprocessed input with twice the counts in all twenty-four reserved views, but the regional count bias rose from 1.832 to 14.566 %. None of the 768 model–fraction–view combinations jointly reached the SSIM and PSNR of the unprocessed input at 50 %, so the reduction factor remained undetermined under that criterion. Local indicators, computed on anomalies of known location, showed simultaneous improvements and deteriorations and do not demonstrate the detection of unknown anomalies. It is concluded that the synthetic dataset fulfilled its objective, that comparable quality was only partially supported, and that neither an acquisition-time reduction factor nor quantitative opacity equivalence was demonstrated. The results are limited to synthetic scenarios, without a physical detector or field data.

[3]Undergraduate thesis, research modality.

[4]Universidad Industrial de Santander. Faculty of Physical and Mechanical Engineering. School of Systems Engineering and Informatics. Supervisor: Andrés Leonardo González Gómez, PhD candidate. Co-supervisor: Jaime Enrique Meneses Fonseca, PhD.

1. Introducción

Conocer la distribución de densidad en el interior de un edificio volcánico es una de las bases para evaluar su amenaza. Los conductos por los que asciende el magma, las cavidades, las zonas de alteración hidrotermal y los cuerpos de roca más densa modifican la masa que encuentra cualquier trayecto que atraviese la montaña, y su localización contribuye a interpretar procesos como la desgasificación, el ascenso de material o la estabilidad de los flancos (Tanaka et al., 2007, 2023). Los métodos geofísicos convencionales infieren esa estructura de manera indirecta, a partir de campos medidos en la superficie, y las técnicas de inspección con radiación artificial no alcanzan a atravesar cientos de metros de roca (Bonomi et al., 2020). Este trabajo se ocupó de una técnica que sí lo hace, la muografía por transmisión, y de una de sus limitaciones más severas: el tiempo de exposición necesario para obtener una imagen interpretable. El capítulo presenta el problema que motivó el estudio, las razones que justificaron abordarlo con aprendizaje profundo, los objetivos formulados, el alcance del trabajo y la organización del documento.

1.1 Contexto y planteamiento del problema

La muografía aprovecha los muones que se producen cuando los rayos cósmicos interactúan con la alta atmósfera. Por su energía elevada y su interacción débil con la materia, una fracción de esos muones atraviesa cientos de metros, e incluso kilómetros, de roca, y la atenuación de su flujo en cada dirección de observación informa sobre la opacidad, es decir, sobre la cantidad de materia que encuentran a lo largo de ella (Bonomi et al., 2020; Tanaka et al., 2023). En la modalidad por transmisión, un detector situado al pie del edificio registra cuántos muones llegan desde cada dirección, y el resultado es un mapa bidimensional en el que cada píxel resume la densidad acumulada a lo largo de un trayecto. Con esta técnica se visualizaron estructuras bajo el cráter del monte Asama (Tanaka et al., 2007) y se obtuvieron imágenes de alta definición del volcán Sakurajima (Oláh et al., 2018), ambos en Japón, y en Colombia se diseñó y construyó el telescopio híbrido MuTe con el propósito de estudiar volcanes activos del país (Peña-Rodríguez et al., 2020).

La fuente de la técnica es, al mismo tiempo, su principal limitación. A diferencia de la radiografía médica o industrial, en la que la intensidad de la fuente puede ajustarse, la muografía depende del flujo natural de muones, cercano a un muon por centímetro cuadrado y por minuto sobre un detector horizontal al nivel del mar (Particle Data Group et al., 2022). En las direcciones casi horizontales

desde las que se observa un volcán ese flujo es mucho menor, y después de atravesar cientos de metros de roca solo sobrevive una fracción pequeña de él. La llegada de los muones es, además, un proceso aleatorio de conteo: el número registrado en cada dirección fluctúa alrededor de su valor esperado, y el ruido relativo de esa fluctuación disminuye solo con la raíz cuadrada del número de eventos, como se expone en la sección 2.3. Para que los contrastes de densidad se distingan de las fluctuaciones se requieren exposiciones de semanas o meses (Lesparre et al., 2010), durante las cuales el instrumento debe operar en ambientes remotos, a la intemperie y con suministro de energía limitado. Esa condición encarece la adquisición, aumenta el riesgo de fallas y limita la frecuencia con la que puede actualizarse una imagen (Bonomi et al., 2020; Lechmann et al., 2021).

Una exposición corta produce, en consecuencia, una imagen de baja estadística. En ella, la fluctuación de conteo domina sobre las diferencias que se pretende observar, las direcciones de menor transmisión registran pocas cuentas o ninguna, y el contraste de una anomalía de densidad puede quedar enmascarado o confundirse con una fluctuación del mismo orden. Un suavizado de la imagen reduce el ruido, pero puede atenuar también los contrastes débiles y las estructuras de pequeña escala que sustentan la interpretación. Disminuir el tiempo de adquisición sin perder la información necesaria para interpretar la imagen constituye, por ello, un problema abierto de la muografía volcánica.

En otros campos de la imagenología, el aprendizaje profundo ha ofrecido una alternativa al aumento de la exposición. En la tomografía computarizada de baja dosis, cuyo ruido cuántico también sigue una distribución de Poisson, las redes generativas antagónicas se han empleado para transformar imágenes ruidosas en estimaciones próximas a las de dosis completa (Yang et al., 2018). En muografía, O'Donnell et al. (2025) aplicaron una red generativa antagónica condicional de Wasserstein con penalización de gradiente a imágenes de baja estadística de bloques de concreto y reportaron que imágenes de un día de exposición alcanzaron, según el índice de similitud estructural, la calidad de imágenes de 21 días. Ese resultado se obtuvo, sin embargo, en un escenario de infraestructura civil, cuyas geometrías, distancias y contrastes de densidad difieren sustancialmente de los de un edificio volcánico.

De esta situación surgió la pregunta que orientó el trabajo: si un modelo de aprendizaje profundo, entrenado con datos sintéticos generados mediante simulación Monte Carlo, puede transformar imágenes muográficas por transmisión de baja estadística en imágenes de calidad comparable a las obtenidas con exposiciones prolongadas en escenarios volcánicos, conservando los contrastes de densidad que dan sentido a la imagen, y en qué medida ese procedimiento permitiría reducir el

tiempo de adquisición. La reducción del tiempo de adquisición fue, así, el propósito investigado; lo que la evidencia obtenida permite afirmar al respecto se expone en el capítulo 5.

1.2 Justificación

El estudio se justificó por tres razones: la pertinencia del aprendizaje profundo para el problema planteado, la necesidad de evaluarlo con criterios propios de la muografía y la viabilidad de abordarlo mediante simulación.

La primera razón es el costo del tiempo de exposición y la posibilidad de reducirlo por medios computacionales. Como disminuir a la mitad el ruido relativo de un conteo exige cuadruplicar la exposición, cualquier procedimiento que extraiga más información de una adquisición corta incide directamente sobre el costo logístico y sobre la frecuencia con la que puede vigilarse un volcán (Lechmann et al., 2021; Tanaka et al., 2023). Un modelo supervisado puede aprender, a partir de pares de imágenes de baja y alta estadística, regularidades espaciales asociadas al proceso de atenuación y estimar con ellas la imagen que se habría obtenido con mayor exposición. Las redes neuronales se han aplicado ya a la reducción del ruido estadístico de muografías simuladas (Lefevre et al., 2024) y a la tomografía por dispersión de corta duración (Wang et al., 2026), y el trabajo de O'Donnell et al. (2025) mostró la factibilidad de la mejora predictiva en estructuras de concreto. En la literatura revisada, que se presenta en la sección 2.7, no se identificó, en cambio, la aplicación de redes generativas condicionales a imágenes de baja estadística de muografía volcánica por transmisión.

La segunda razón es que la utilidad de una imagen mejorada no puede juzgarse solo por su parecido con la referencia. En la muografía, cada píxel es un conteo ligado a la opacidad del trayecto correspondiente, y la interpretación se apoya en las cuentas de regiones y en los contrastes entre ellas. Las métricas de similitud de uso general, como el índice de similitud estructural y la relación señal-ruido de pico, resumen la imagen completa y no distinguen las regiones relevantes para la interpretación. Además, la distorsión respecto de la referencia y la apariencia realista de una estimación no pueden optimizarse simultáneamente más allá de cierto límite (Blau & Michaeli, 2018), y en la traducción de imágenes médicas se ha mostrado que las pérdidas que ajustan la distribución de las imágenes generadas pueden introducir o suprimir estructuras ausentes en la imagen real (Cohen et al., 2018). Una red que suaviza el ruido puede, por tanto, elevar la similitud global y, al mismo tiempo, desplazar cuentas o atenuar una anomalía. Por ello se consideró necesario evaluar el esquema tanto por la similitud de sus imágenes con la referencia como por la conservación de la información relevante para la muografía, es decir, las

cuentas regionales, el contraste de las anomalías y su signo, con los criterios que se fundamentan en la sección 2.6.

La tercera razón es la viabilidad del estudio mediante simulación. Los pares formados por una imagen de baja estadística y su referencia de alta estadística, necesarios para el aprendizaje supervisado, no existen en la práctica: una medición de campo no tiene una versión equivalente sin ruido, y su estructura interna verdadera no se conoce. La simulación Monte Carlo del transporte de muones con Geant4 (Agostinelli et al., 2003; Allison et al., 2016), alimentada por la parametrización del flujo de Guan et al. (2015) y por el generador EcoMug (Pagano et al., 2021), permite construir esos pares en condiciones controladas, sobre escenarios cuya estructura se fija de antemano y sin depender de campañas experimentales costosas. Esa posibilidad hizo abordable el problema en el marco de un trabajo de grado y facilita la reproducción de sus resultados. El proyecto se inscribió, además, en la línea de trabajo del Grupo de Óptica y Tratamiento de Señales de la Universidad Industrial de Santander, que articula la simulación física, el procesamiento de imágenes y el aprendizaje profundo, y en el interés nacional por la muografía de volcanes colombianos (Peña-Rodríguez et al., 2020).

1.3 Objetivos

Los objetivos se presentan a continuación tal como se formularon en el plan de trabajo de grado.

1.3.1 Objetivo general

Desarrollar y validar un esquema de reconstrucción muográfica por transmisión asistido por aprendizaje profundo para reducir el tiempo efectivo de adquisición en exploración volcánica, mediante mejora predictiva de imágenes de baja estadística hacia imágenes de referencia de alta estadística, evaluando la mejora en calidad y detectabilidad de estructuras internas.

1.3.2 Objetivos específicos

OE1. Generar un conjunto de datos sintéticos de imágenes muográficas por transmisión, con diferentes niveles de estadística de conteo, mediante simulación Monte Carlo que reproduzca escenarios representativos de exploración volcánica.

OE2. Diseñar e implementar un modelo de aprendizaje profundo basado en redes generativas adversarias condicionales para transformar imágenes muográficas de baja estadística en imágenes de calidad comparable a las de alta estadística.

OE3. Evaluar el desempeño del modelo entrenado y determinar el factor de reducción del tiempo de adquisición alcanzable con el esquema propuesto, comparando la calidad de las imágenes mejoradas por el modelo frente a imágenes obtenidas con tiempos de exposición prolongados.

Los tres objetivos específicos se abordaron en secuencia, porque el producto de cada uno fue el insumo del siguiente: el conjunto sintético del primero sirvió para entrenar y evaluar el modelo del segundo, y ese modelo fue el objeto de la evaluación del tercero. El objetivo general añade a esa secuencia la exigencia de juzgar las imágenes estimadas tanto por su calidad como por la detectabilidad de las estructuras internas.

1.4 Alcance del trabajo

El plan de trabajo de grado delimitó el estudio a geometrías simplificadas, manejables computacionalmente a nivel de pregrado, y a mapas bidimensionales obtenidos a partir de la atenuación del flujo de muones. Dentro de ese marco, el trabajo fue un estudio enteramente computacional con tres componentes: la definición de escenarios volcánicos sintéticos, la simulación Monte Carlo del transporte de muones a través de ellos y la evaluación de modelos de aprendizaje profundo sobre las imágenes resultantes.

Los escenarios fueron conos idealizados de roca homogénea con anomalías internas de geometría simple, del tipo que la muografía volcánica asocia con conductos, cavidades y cuerpos densos. No reproducen la topografía ni la estructura de densidades de un volcán concreto, y su representatividad es de mecanismos y configuraciones, no de una población geológica. Cada imagen es un mapa de conteos direccionales, ordenado por elevación y acimut desde una posición de observación, que registra los muones primarios que alcanzan un plano de conteo con la energía establecida. Las imágenes no incluyen la respuesta de un detector físico, el fondo instrumental ni las partículas secundarias, y su exposición es una escala convencional y no un tiempo calibrado de medición. En consecuencia, el trabajo no incluyó adquisición de datos de campo, reconstrucción tridimensional ni una inversión de opacidad validada: la información de densidad de las imágenes estimadas se examinó mediante contrastes de cuentas, que no equivalen a diferencias de opacidad (sección 2.2).

Por la misma razón, la reducción del tiempo de adquisición se estudió bajo una equivalencia idealizada. Con flujo estable y detección constante, el número esperado de cuentas es proporcional a la exposición, de modo que reducir los conteos de una imagen de referencia mediante submuestreo equivale nominalmente a reducir su tiempo de exposición. Toda razón de reducción que se discute en el documento es,

por ello, una razón de conteos en condiciones simuladas, y su traducción a un tiempo de adquisición de campo requeriría un instrumento calibrado.

En el componente de aprendizaje, los modelos se entrenaron con una sola fracción de conteo y se evaluaron después con varias, con el fin de examinar su comportamiento ante distintas estadísticas de entrada. Los escenarios se asignaron por geometría completa a entrenamiento, validación, prueba y generalización, con doce, tres, tres y una geometrías, respectivamente, en lugar de la proporción de 70, 15 y 15 % prevista en el plan de trabajo. La asignación por geometría impide que imágenes derivadas de un mismo escenario intervengan a la vez en el ajuste y en la evaluación (Kaufman et al., 2012), a costa de un número reducido de escenarios reservados. Los indicadores de conservación de anomalías se calcularon sobre regiones cuya ubicación se conocía por construcción; permiten examinar si una estructura conocida se preserva, pero no constituyen un procedimiento de detección ni de localización de anomalías desconocidas.

Las afirmaciones del trabajo se refieren a estas condiciones. La inversión de las imágenes estimadas a opacidad y la validación del esquema con un instrumento real en campo quedaron fuera del estudio; su desarrollo permitiría establecer si lo observado en el caso sintético se sostiene ante observaciones reales, y se plantea como posible continuación en la sección 5.5.

1.5 Organización del documento

El documento se organiza en cinco capítulos. Después de esta introducción, el capítulo 2 presenta los fundamentos en que se apoya el trabajo: el paso de los muones por la materia, la formación de la imagen muográfica por transmisión, la estadística de conteo, la simulación Monte Carlo, los modelos de aprendizaje profundo para la mejora de imágenes, las métricas de calidad y conservación y los antecedentes del aprendizaje profundo en muografía. El capítulo 3 describe el diseño del estudio, la simulación de los escenarios, la verificación y preparación del conjunto de datos, la arquitectura y el entrenamiento de los modelos y los protocolos de evaluación. El capítulo 4 presenta y discute los resultados de cada objetivo específico, y el capítulo 5 expone las conclusiones por objetivo, la conclusión general y posibles líneas de continuación. El anexo A detalla un protocolo propuesto, no ejecutado, para estimar el factor de reducción con criterios fijados de antemano.

2. Marco teórico

La metodología de este trabajo combina tres campos: la física del paso de los muones por la materia, la estadística de los procesos de conteo y el aprendizaje profundo aplicado a la mejora de imágenes. Este capítulo presenta los fundamentos de esos campos en el orden en que la metodología los requiere. Primero se explica por qué la atenuación del flujo de muones informa sobre la materia atravesada y qué contiene, y qué no contiene, una imagen muográfica por transmisión. Después se describe la estadística que gobierna su ruido, la simulación con la que pueden producirse imágenes de exposición conocida y los modelos capaces de estimar una imagen de mayor estadística a partir de una ruidosa. El capítulo concluye con los criterios con los que se juzga la calidad de esa estimación y con una revisión breve del aprendizaje profundo en muografía. Los procedimientos con los que estos conceptos se aplicaron se describen en el capítulo 3.

2.1 Muones cósmicos y su paso por la materia

Los rayos cósmicos primarios, en su mayoría protones y núcleos de helio, interactúan con los núcleos de la alta atmósfera y producen cascadas de partículas secundarias. Entre ellas abundan los piones y kaones cargados, cuya desintegración da lugar a los muones. El muon tiene la carga del electrón y una masa de 105,7 MeV/c^2, unas doscientas veces mayor; no participa en la interacción fuerte y, por su masa, pierde energía por radiación mucho más lentamente que el electrón. Aunque su vida media en reposo es de 2,2 μs, la dilatación relativista del tiempo permite que una fracción importante de los muones producidos a decenas de kilómetros de altura alcance la superficie y atraviese después grandes espesores de roca (Gaisser et al., 2016; Particle Data Group et al., 2022).

El flujo en la superficie se describe por su intensidad diferencial $\Phi(E, \zeta)$, el número de muones por unidad de área, de tiempo, de ángulo sólido y de energía, que depende de la energía E y del ángulo cenital ζ de la dirección de llegada. Al nivel del mar, la energía media de los muones es del orden de 4 GeV; el espectro es casi plano por debajo de 1 GeV y decae aproximadamente como $E^{-2,7}$ entre decenas y centenares de GeV. La intensidad disminuye con el ángulo cenital, en forma aproximadamente proporcional a $\cos^2 \zeta$ para muones de algunos GeV, mientras que la energía media aumenta en las direcciones inclinadas, porque los muones de baja energía que recorren más atmósfera se desintegran o se detienen antes de llegar al suelo (Particle Data Group et al., 2022). Para la muografía interesa el flujo integral por encima de un

umbral de energía $E_{\min}$ en cada dirección, definido en la ecuación (2.1):

$$\Phi_{\text{int}}(E_{\min}, \zeta) = \int_{E_{\min}}^{\infty} \Phi(E, \zeta)\, \mathrm{d}E, \tag{2.1}$$

donde Φ_{int} se expresa en $\mathrm{cm^{-2}\,s^{-1}\,sr^{-1}}$ cuando Φ se expresa en $\mathrm{cm^{-2}\,s^{-1}\,sr^{-1}\,GeV^{-1}}$ y la energía en GeV. El flujo se evalúa mediante parametrizaciones ajustadas a mediciones. La fórmula de Gaisser lo describe a energías altas y ángulos cenitales moderados, y Guan et al. (2015) la modificaron para extenderla a energías bajas y a todo el intervalo de ángulos cenitales, que es el régimen de las observaciones casi horizontales de la muografía volcánica (Gaisser et al., 2016).

Un muon que atraviesa la roca pierde energía de forma prácticamente continua. La pérdida media por unidad de espesor másico X, en $\mathrm{g\,cm^{-2}}$, se describe en la ecuación (2.2a) con dos términos (Groom et al., 2001; Particle Data Group et al., 2022): uno de ionización, $a_{\text{ion}}(E)$, y uno radiativo, $b_{\text{rad}}(E)\,E$, que agrupa la radiación de frenado, la producción de pares y las interacciones fotonucleares. El término de ionización, descrito por la fórmula de Bethe, alcanza un mínimo amplio en $\beta\gamma \approx 3$–4 y por encima de él crece solo de forma logarítmica, de modo que para los muones relativistas puede tratarse como casi constante. Si a_{ion} y b_{rad} se toman constantes, la integración de la pérdida media a lo largo del recorrido en la aproximación de frenado continuo da la energía mínima necesaria para atravesar un espesor másico X, que expresa la ecuación (2.2b):

$$-\frac{\mathrm{d}E}{\mathrm{d}X} = a_{\text{ion}}(E) + b_{\text{rad}}(E)\,E, \tag{2.2a}$$

$$E_{\min}(X) = \frac{a_{\text{ion}}}{b_{\text{rad}}}\left(\mathrm{e}^{b_{\text{rad}}X} - 1\right), \tag{2.2b}$$

donde a_{ion} se expresa en $\mathrm{GeV\,cm^2\,g^{-1}}$, b_{rad} en $\mathrm{cm^2\,g^{-1}}$ y $E_{\min}$ en GeV. En la roca estándar, un material de referencia de densidad 2,65 $\mathrm{g\,cm^{-3}}$, a_{ion} es del orden de 2×10^{-3} $\mathrm{GeV\,cm^2\,g^{-1}}$ y b_{rad} del orden de 4×10^{-6} $\mathrm{cm^2\,g^{-1}}$, y ambos términos se igualan a una energía crítica de varios cientos de GeV (Groom et al., 2001). Para espesores pequeños, $b_{\text{rad}}X \ll 1$ y la energía mínima crece linealmente con X; para espesores grandes crece exponencialmente, de modo que atravesar un kilómetro de roca estándar, unos $2{,}65 \times 10^5$ $\mathrm{g\,cm^{-2}}$, exige del orden de 1 TeV. Como el espectro decae con la energía, la columna de masa atravesada determina qué fracción del flujo sobrevive: esa es la relación que convierte la atenuación de los muones en información sobre la materia. La energía mínima de la ecuación (2.2b) es un umbral físico de transmisión y debe distinguirse de cualquier umbral de registro que se imponga a los muones que alcanzan un plano de observación.

El paso por la roca también cambia la dirección del muon. Las numerosas

desviaciones de pequeño ángulo en el campo eléctrico de los núcleos, conocidas como dispersión múltiple de Coulomb, producen una desviación angular aleatoria cuya anchura es inversamente proporcional al momento y crece con la raíz del espesor atravesado medido en longitudes de radiación (Particle Data Group et al., 2022). El efecto es mayor para los muones de baja energía, que son precisamente los que cruzan los espesores pequeños cerca del contorno de un edificio; por ello, la transición entre roca y cielo en una imagen muográfica no es un borde nítido, sino una franja en la que se mezclan direcciones. Las descripciones geométricas que trazan rayos rectos desde el punto de observación representan proyecciones nominales y no las trayectorias dispersadas de los muones.

2.2 Imagen muográfica por transmisión

La muografía por transmisión registra cuántos muones llegan desde cada dirección después de atravesar el objeto de estudio. Una dirección de observación se describe por su acimut α y su elevación η, medida desde el horizonte, de modo que el ángulo cenital cumple $\zeta = 90^\circ - \eta$. A lo largo de esa dirección, el muon recorre en la roca un trayecto de longitud $L(\alpha, \eta)$ con densidad variable. La magnitud que gobierna su atenuación es la opacidad, o espesor másico, definida como la integral de línea de la densidad a lo largo del trayecto (Lesparre et al., 2010; Tanaka et al., 2023). Con ella, la tasa esperada de muones registrados en una celda angular y la transmisión, que compara esa tasa con la que se registraría en la misma dirección sin roca interpuesta, son las de la ecuación (2.3):

$$X(\alpha, \eta) = \int_0^{L(\alpha,\eta)} \rho(l)\, \mathrm{d}l, \tag{2.3a}$$

$$\lambda(\alpha, \eta) = A\, \Delta\Omega\, \Phi_{\mathrm{int}}\Big(E_{\min}(X(\alpha, \eta)), \zeta\Big), \tag{2.3b}$$

$$\mathcal{T}(\alpha, \eta) = \frac{\lambda(\alpha, \eta)}{\lambda_{\mathrm{libre}}(\alpha, \eta)}. \tag{2.3c}$$

En la ecuación (2.3a), $\rho(l)$ es la densidad en el punto situado a la distancia l del origen del trayecto, en $\mathrm{g\,cm^{-3}}$, y l y L se expresan en cm, de modo que X resulta en $\mathrm{g\,cm^{-2}}$. En la ecuación (2.3b), λ es la tasa esperada de muones, en $\mathrm{s^{-1}}$; A es el área efectiva de detección, en $\mathrm{cm^2}$, y $\Delta\Omega$ el ángulo sólido de la celda, en sr. La expresión corresponde a un detector ideal; un instrumento real introduce además su aceptancia angular, su eficiencia y un fondo de partículas que no proceden del objeto (Lesparre et al., 2010). En la ecuación (2.3c), λ_{libre} es la tasa en la misma dirección cuando el muon solo atraviesa aire, y $\mathcal{T}$ es adimensional.

La ecuación (2.3) contiene la propiedad que define el alcance de la técnica, que ilustra la figura 2.1. Cada dirección de observación corresponde a un píxel, y

el valor de ese píxel resume con un solo número toda la densidad encontrada a lo largo de un trayecto que puede medir cientos de metros. La imagen muográfica por transmisión es, por tanto, una proyección del objeto sobre el espacio de direcciones y no una representación de su volumen: un conducto, una cavidad o un cuerpo denso modifican el conteo del píxel por el que pasan, pero la imagen no indica en qué punto del trayecto se encuentran.

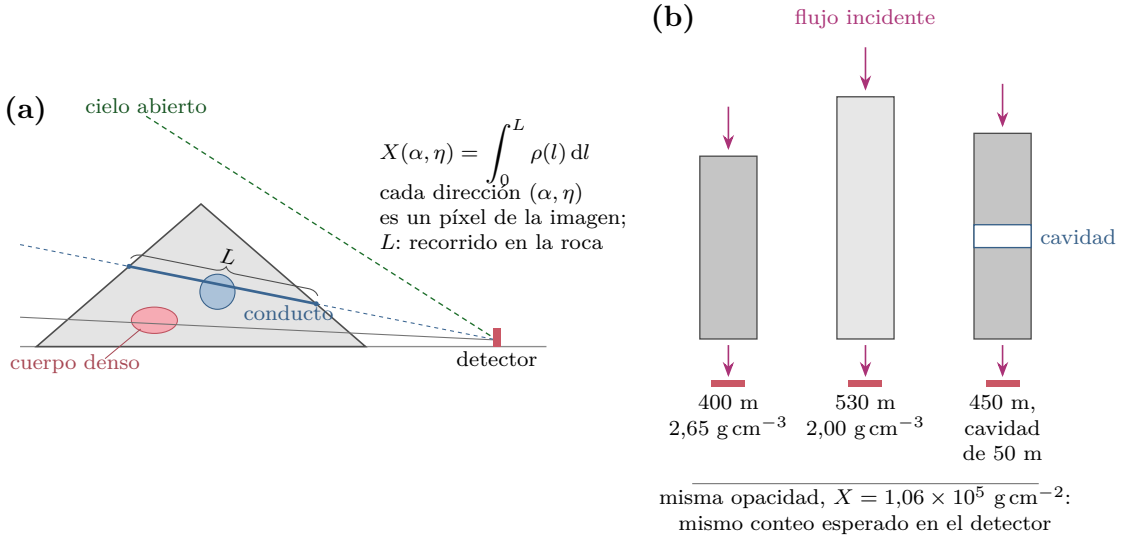

Figura 2.1: La imagen muográfica por transmisión como proyección (esquema sin escala). (a) Cada dirección (α, η) define un trayecto; el píxel correspondiente depende de la opacidad X acumulada a lo largo del recorrido L en la roca, incluidas las anomalías que encuentre, y la dirección de cielo abierto sirve de referencia para la transmisión. (b) Ambigüedad entre espesor y densidad: 400 m de roca de 2,65 g cm^{-3}, 530 m de roca de 2,00 g cm^{-3} y 450 m de roca de 2,65 g cm^{-3} con una cavidad de 50 m tienen la misma opacidad, $1{,}06 \times 10^5$ g cm^{-2}, y producen el mismo conteo esperado. Fuente: elaboración de los autores.

De esa propiedad se siguen dos consecuencias. La primera es que el problema inverso no tiene solución única. Como muestra el panel (b) de la figura 2.1, distribuciones de densidad diferentes producen la misma opacidad y, por tanto, el mismo conteo esperado: una roca delgada y densa equivale a una gruesa y liviana, y una cavidad puede compensarse con un trayecto más largo. Convertir una opacidad en densidad media exige conocer la longitud del recorrido, y recuperar la distribución tridimensional exige combinar varias vistas o información adicional (Lechmann et al., 2021; Tanaka et al., 2023). La segunda consecuencia es que la interpretación se apoya en contrastes. Se compara el conteo de una región con el de otra región de referencia cuyo trayecto sea comparable, y una diferencia de conteo se atribuye a una diferencia de densidad solo si los trayectos comparados tienen longitudes semejantes; de lo contrario, una diferencia de longitud produce por sí sola una diferencia de opacidad.

Las ecuaciones (2.3b) and (2.3c) muestran, además, que la relación entre

conteos y opacidad no es lineal: depende del espectro del flujo, del ángulo cenital y de la pérdida de energía. Un contraste de conteos entre dos regiones es, por ello, una magnitud adimensional distinta de una diferencia de opacidad, que se expresa en $\mathrm{g\,cm^{-2}}$. Pasar de uno a otra requiere un modelo de respuesta que relacione los conteos esperados con el flujo, la opacidad y la detección, o una calibración equivalente (Lesparre et al., 2010).

2.3 Estadística de conteo y exposición

La llegada de muones a una celda angular es una sucesión de eventos independientes y raros, que se modela como un proceso de Poisson. Si la tasa λ es constante, el número de muones $N(t)$ registrados durante una exposición t sigue la distribución de la ecuación (2.4a); su valor esperado y su varianza coinciden, como expresa la ecuación (2.4b), y su ruido relativo es el de la ecuación (2.4c):

$$P\big(N(t)=n\big) = \frac{(\lambda t)^n\,\mathrm{e}^{-\lambda t}}{n!}, \qquad n = 0, 1, 2, \ldots, \tag{2.4a}$$

$$\mathbb{E}[N(t)] = \mathrm{Var}[N(t)] = \lambda t, \tag{2.4b}$$

$$\frac{\sqrt{\mathrm{Var}[N(t)]}}{\mathbb{E}[N(t)]} = \frac{1}{\sqrt{\lambda t}}. \tag{2.4c}$$

En estas expresiones, λ se expresa en $\mathrm{s^{-1}}$ y t en s, de modo que $\mu = \lambda t$, el número esperado de cuentas, es adimensional. La señal crece en proporción a la exposición y la desviación estándar solo con su raíz cuadrada. En consecuencia, el cociente entre la media y la desviación estándar de un conteo es $\sqrt{\mu}$ y el ruido relativo de la ecuación (2.4c) es $1/\sqrt{\mu}$, como muestra la figura 2.2. Un conteo con un valor esperado de cien cuentas fluctúa típicamente un 10 %, y uno de diez mil, un 1 %; reducir el ruido relativo a la mitad exige cuadruplicar la exposición. Este cociente estadístico de un conteo debe distinguirse de los indicadores espaciales que comparan la media de una región con la dispersión de sus píxeles, en los que la dispersión contiene también la estructura de la escena.

De lo anterior se sigue una precisión sobre la expresión *alta estadística*. Una imagen de alta estadística no es una imagen sin azar, sino una con muchos conteos por píxel y, por tanto, con ruido relativo pequeño pero no nulo. Cuando una imagen de larga exposición se usa como referencia para juzgar otra, la referencia conserva sus propias fluctuaciones, y ninguna estimación puede coincidir exactamente con ella.

El proceso de Poisson tiene una propiedad que permite estudiar exposiciones menores a partir de una sola medición o simulación. Si cada evento de un proceso de Poisson se conserva de manera independiente con probabilidad f, los

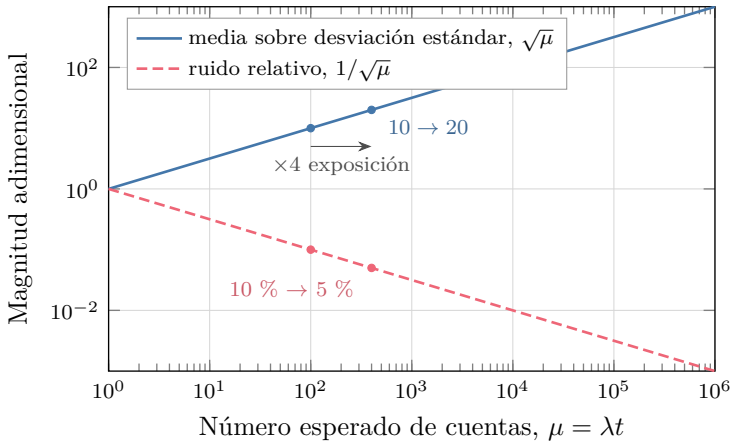

Figura 2.2: Cociente entre media y desviación estándar, $\sqrt{\mu}$, y ruido relativo, $1/\sqrt{\mu}$, de un conteo de Poisson en función de su valor esperado $\mu = \lambda t$, en escalas logarítmicas. Los puntos ilustran que cuadruplicar la exposición, de $\mu = 100$ a $\mu = 400$, duplica el cociente y reduce el ruido relativo del 10 al 5 %. Curvas analíticas, sin datos del proyecto. Fuente: elaboración de los autores.

eventos conservados forman de nuevo un proceso de Poisson, con la tasa multiplicada por f (Kingman, 1992). En términos de conteos, la ecuación (2.5) expresa este adelgazamiento binomial:

$$N \sim \text{Poisson}(\lambda t), \quad L \mid N \sim \text{Binomial}(N, f) \implies L \sim \text{Poisson}(f\lambda t), \tag{2.5}$$

donde L es el conteo conservado y f, con $0 < f \leq 1$, la fracción de conservación, ambos adimensionales. Como $f\lambda t$ es el valor esperado que correspondería a una exposición ft, el adelgazamiento produce, a partir de una imagen de exposición t, imágenes con la distribución marginal que tendrían mediciones de exposición ft, y la razón $1/f$ describe la reducción nominal de la exposición. La equivalencia vale para cada imagen por separado: las imágenes reducidas obtenidas de una misma imagen original comparten sus eventos y no son mediciones independientes entre sí ni de la original.

La estadística de conteo interviene también en el control de una proporción. Cuando de N eventos se observa que K cumplen una condición, la proporción estimada K/N tiene una incertidumbre binomial, y el intervalo de Clopper y Pearson, construido a partir de los cuantiles de la distribución beta, garantiza una cobertura no menor que la nominal sin recurrir a aproximaciones normales (Clopper & Pearson, 1934). Cuando se examinan simultáneamente muchas proporciones, la probabilidad de que alguno de los intervalos no contenga su valor verdadero crece con su número; la corrección de Bonferroni reparte el nivel de error entre las comparaciones para conservar una cobertura conjunta, a costa de intervalos más anchos (Dunn, 1961).

Por último, los conteos de una imagen muográfica abarcan varios órdenes de magnitud entre las direcciones de cielo abierto y las que atraviesan grandes espesores de roca. Una transformación logarítmica comprime ese intervalo dinámico, de modo que diferencias relativas iguales ocupen intervalos semejantes, y una transformación acotada permite representar los conteos en un intervalo finito adecuado para la salida de una red neuronal. Como toda transformación no lineal, cambia la escala de los errores: una discrepancia pequeña en el dominio transformado puede corresponder a una discrepancia grande en cuentas, en particular donde los conteos son altos, por lo que los errores deben examinarse en ambos dominios.

2.4 Simulación Monte Carlo del transporte de muones

La muografía de campo no proporciona pares de imágenes de baja y alta estadística de un mismo objeto con estructura interna conocida: una medición real no tiene una versión equivalente sin ruido, y su estructura verdadera no se conoce. La simulación Monte Carlo resuelve esa carencia, porque produce imágenes de exposición controlada sobre escenarios cuya geometría y cuyos materiales se fijan de antemano. El método consiste en muestrear aleatoriamente las partículas primarias y los procesos físicos que cada una sufre a lo largo de su trayectoria, y en estimar las magnitudes de interés a partir de muchas historias independientes; la precisión de esas estimaciones está limitada por la estadística de conteo de la sección 2.3.

Geant4 es un conjunto de herramientas de propósito general para simular el paso de partículas por la materia. Proporciona la descripción de la geometría y de los materiales, el seguimiento paso a paso de las partículas y el registro de las magnitudes de interés (Agostinelli et al., 2003; Allison et al., 2016). Los procesos físicos se agrupan en listas de física, que combinan modelos electromagnéticos y hadrónicos validados para distintos intervalos de energía; la lista FTFP_BERT, por ejemplo, emplea el modelo de cuerdas de Fritiof a energías altas y la cascada intranuclear de Bertini a energías bajas, junto con la física electromagnética estándar (Allison et al., 2016). Geant4 define además un corte de producción, expresado como una distancia, por debajo del cual no se generan partículas secundarias explícitas y su energía se deposita de forma continua. Ese corte controla el detalle de la simulación y no equivale a un umbral de energía para registrar las partículas que alcanzan una superficie de observación. Los materiales pueden tomarse de una base de datos de referencia, como el aire normalizado de Geant4, o definirse por su composición y densidad.

Las partículas primarias deben generarse según el flujo de la sección 2.1.

EcoMug es un generador de muones cósmicos que lo hace a partir de parametrizaciones del flujo medido y con distintas superficies de generación, lo que permite muestrear eficientemente momentos y direcciones (Pagano et al., 2021). Como la mayoría de los muones generados no atraviesa la roca o no llega a la región de observación, la eficiencia del muestreo condiciona el costo computacional de una campaña de simulación muográfica.

La simulación tiene, sin embargo, un límite epistemológico. Un modelo entrenado con datos simulados aprende la distribución de esos datos, y su desempeño sobre datos reales depende de la semejanza entre ambas distribuciones. En la muografía, la brecha entre simulación y realidad tiene varias fuentes: los detectores reales tienen eficiencia menor que la unidad, aceptancia y resolución angular finitas y un fondo de partículas que no son muones transmitidos, cuyo peso relativo crece donde la señal es menor (Lechmann et al., 2021; Lesparre et al., 2010); los volcanes reales tienen topografía irregular y una estructura de densidades heterogénea, y las simulaciones simplificadas pueden omitir partículas secundarias o el detalle de la respuesta instrumental. El desempeño medido sobre escenarios simulados excluidos del entrenamiento describe, por tanto, la generalización dentro de la familia simulada y no garantiza por sí solo el comportamiento ante observaciones de campo.

2.5 Aprendizaje profundo para la mejora de imágenes

El ruido de una imagen muográfica solo se reduce por medios físicos aumentando la exposición. La alternativa computacional consiste en estimar, a partir de la imagen ruidosa, la imagen que se habría obtenido con más exposición. En el aprendizaje supervisado, esa estimación se obtiene ajustando los parámetros θ de una función G_θ a un conjunto de pares formados por una entrada degradada $\boldsymbol{u}$ y su referencia $\boldsymbol{y}$, de modo que la salida $G_\theta(\boldsymbol{u})$ se aproxime a $\boldsymbol{y}$ según una función de pérdida. Los parámetros se ajustan con variantes del descenso de gradiente estocástico sobre lotes de ejemplos; el método Adam adapta el paso de cada parámetro a partir de estimaciones de los momentos primero y segundo de su gradiente (Kingma & Ba, 2015).

Un modelo con muchos parámetros puede ajustarse a las particularidades de los datos de entrenamiento sin generalizar a casos nuevos. Por ello, el desempeño se juzga en un conjunto de validación no usado para ajustar los parámetros, que sirve para elegir el estado del modelo y detener el entrenamiento, y la estimación final se obtiene en un conjunto de prueba reservado. Esa separación solo es informativa si ningún dato del conjunto reservado influye en el entrenamiento: cuando las muestras

están agrupadas, por ejemplo varias imágenes derivadas de un mismo escenario, repartir muestras de un mismo grupo entre entrenamiento y evaluación produce una fuga de información que sobrestima el desempeño, y la partición debe hacerse por grupos completos (Kaufman et al., 2012).

Las redes neuronales convolucionales son la arquitectura habitual para transformar imágenes. Cada capa aplica filtros aprendidos que recorren la imagen con pesos compartidos, seguidos de funciones de activación no lineales y, con frecuencia, de una normalización de las activaciones; la red detecta así un mismo patrón en cualquier posición. Al encadenar capas y reducir la resolución, cada salida depende de una región creciente de la entrada, llamada campo receptivo, y la red construye representaciones de escala cada vez mayor. La arquitectura U-Net organiza esas capas en un codificador, que reduce la resolución y captura el contexto, y un decodificador, que la recupera, unidos por conexiones de salto que transmiten directamente los detalles finos de cada escala (Ronneberger et al., 2015). Esa estructura resulta adecuada para transformar una imagen en otra del mismo tamaño.

La función de pérdida condiciona el tipo de estimación. Cuando varias referencias son compatibles con una misma entrada ruidosa, minimizar el error cuadrático conduce a su media condicional y minimizar el error absoluto, la pérdida $\mathcal{L}_1$, a su mediana. Ambas estimaciones promedian las estructuras posibles en lugar de elegir una de ellas y tienden, por ello, a producir imágenes suaves (Isola et al., 2017). Las redes generativas antagónicas se propusieron como una alternativa para aprender distribuciones de datos. En ellas, un generador G_θ produce muestras y un discriminador D_ϕ aprende a distinguirlas de los datos reales; ambos se entrenan como adversarios en el juego de la ecuación (2.6) (Goodfellow et al., 2014):

$$\min_{\theta}\max_{\phi}\ \mathbb{E}_{\boldsymbol{y}\sim p_{\text{datos}}}\Big[\log D_\phi(\boldsymbol{y})\Big] + \mathbb{E}_{\boldsymbol{z}\sim p_{\boldsymbol{z}}}\Big[\log\Big(1 - D_\phi(G_\theta(\boldsymbol{z}))\Big)\Big], \tag{2.6}$$

donde p_{datos} es la distribución de los datos reales, $\boldsymbol{z}$ una variable aleatoria con distribución $p_{\boldsymbol{z}}$ y $D_\phi(\cdot) \in (0,1)$ la probabilidad, estimada por el discriminador, de que su argumento provenga de los datos; todas las magnitudes son adimensionales. En la versión condicional, generador y discriminador reciben además una información de entrada, de modo que el generador aprende una distribución condicionada por ella (Mirza & Osindero, 2014). Para la traducción entre imágenes, Isola et al. (2017) combinaron un generador U-Net condicionado por la imagen de entrada con un discriminador que recibe el par formado por la entrada y una imagen real o generada y juzga parches locales en lugar de la imagen completa, y añadieron un término $\mathcal{L}_1$ que mantiene la salida próxima a la referencia. El tamaño del parche juzgado corresponde al campo receptivo del discriminador y es una propiedad de la arquitectura, no una

resolución física.

El entrenamiento antagónico es inestable cuando las distribuciones de los datos reales y generados apenas se solapan. Arjovsky et al. (2017) propusieron sustituir la divergencia implícita en la ecuación (2.6) por la distancia de Wasserstein, que sigue siendo informativa en ese caso y que, por la dualidad de Kantorovich y Rubinstein, se expresa como en la ecuación (2.7):

$$W\left(P_{\boldsymbol{y}}, P_{\widehat{\boldsymbol{y}}}\right) = \sup_{\|D\|_L \leq 1} \mathbb{E}_{\boldsymbol{y}\sim P_{\boldsymbol{y}}}\left[D(\boldsymbol{y})\right] - \mathbb{E}_{\widehat{\boldsymbol{y}}\sim P_{\widehat{\boldsymbol{y}}}}\left[D(\widehat{\boldsymbol{y}})\right], \tag{2.7}$$

donde $P_{\boldsymbol{y}}$ y $P_{\widehat{\boldsymbol{y}}}$ son las distribuciones de las referencias y de las salidas del generador, y el supremo se toma sobre las funciones D con constante de Lipschitz $\|D\|_L$ no mayor que uno. El discriminador deja de estimar una probabilidad y se convierte en un crítico que asigna puntuaciones reales, cuya diferencia media aproxima la distancia. Gulrajani et al. (2017) impusieron la restricción de Lipschitz mediante una penalización que lleva hacia uno la norma del gradiente del crítico en puntos interpolados al azar entre referencias y salidas generadas, en lugar de recortar sus pesos; en la práctica, el crítico se actualiza varias veces por cada actualización del generador para que su estimación de la distancia sea informativa. La figura 2.3 reúne estos elementos en el caso condicional: el generador recibe la entrada, el crítico evalúa pares condicionados por ella mediante puntuaciones por parche y el generador se ajusta para reducir a la vez la discrepancia con la referencia y la separación que el crítico establece entre pares reales y generados.

2.6 Métricas de calidad y conservación

Juzgar si una imagen estimada se aproxima a su referencia exige métricas de referencia completa, que comparan ambas imágenes píxel a píxel o en ventanas locales. El error cuadrático medio promedia las diferencias al cuadrado, y la relación señal-ruido de pico, PSNR, lo expresa en decibelios respecto del valor máximo de la representación; ambas miden la fidelidad punto a punto y son sensibles a cualquier diferencia de amplitud. El índice de similitud estructural, SSIM, compara en ventanas locales la luminancia, el contraste y la estructura de las dos imágenes, con la motivación de aproximarse a la percepción humana de la calidad (Wang et al., 2004). Ambas medidas responden de forma diferente a distintos tipos de degradación y conviene informarlas juntas (Horé & Ziou, 2010). Las dos dependen, además, de la representación en que se calculan: evaluadas sobre conteos transformados, describen la similitud en esa escala y no la conservación de las cuentas.

La mejora de la similitud no basta para caracterizar una estimación. Blau y Michaeli (2018) demostraron que la distorsión de una estimación, medida por su

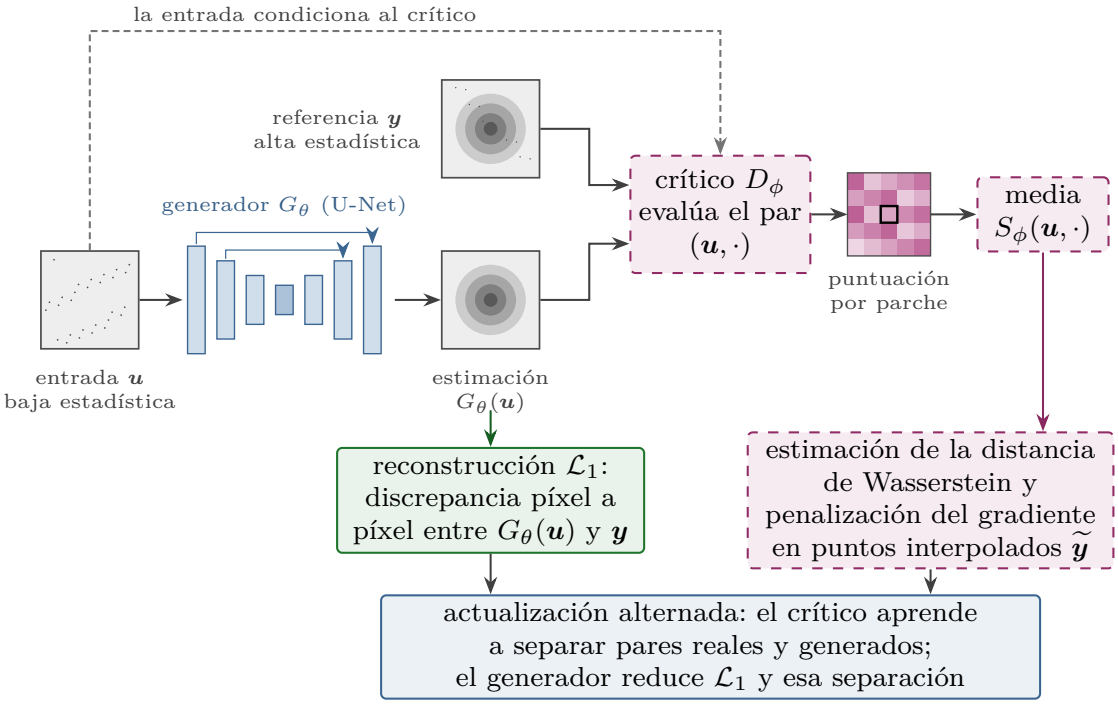

Figura 2.3: Esquema conceptual de una red generativa antagónica condicional de Wasserstein con crítico de parches. El generador G_θ transforma la entrada $\boldsymbol{u}$; el crítico D_ϕ puntúa por parches el par formado por la entrada y una imagen real o generada, y la media S_ϕ resume esas puntuaciones. El término $\mathcal{L}_1$ mide la discrepancia con la referencia $\boldsymbol{y}$ y la penalización del gradiente se evalúa en puntos interpolados $\widetilde{\boldsymbol{y}}$. Esquema sin dimensiones de capas. Fuente: elaboración de los autores a partir de Isola et al. (2017) y Gulrajani et al. (2017).

distancia a la referencia, y su calidad perceptual, medida por la proximidad de su distribución a la de las imágenes reales, no pueden optimizarse simultáneamente más allá de cierto límite. Una estimación de distorsión mínima tiende a ser suave, y una de apariencia realista tiende a alejarse más de la referencia; una red entrenada solo con error absoluto y una red antagónica ocupan, por ello, puntos distintos de ese compromiso, y ninguna métrica aislada basta para compararlas. Un suavizado, además, puede elevar la similitud global y reducir la dispersión de una región mientras atenúa una anomalía.

En la muografía, cada valor de píxel es un conteo con significado físico, ligado a la opacidad por la ecuación (2.3), y las métricas globales promedian sobre la imagen sin distinguir las regiones relevantes para la interpretación. La evaluación de una estimación muográfica requiere, por ello, medidas físicamente motivadas. El sesgo de las cuentas integradas en una región indica si la estimación conserva la información de transmisión; al permitir que excesos y déficits se compensen, se complementa con el error absoluto acumulado en la región, que distingue la conservación de la suma de la fidelidad espacial. La franja del contorno del edificio merece un tratamiento propio, porque allí los gradientes de conteo son mayores y la dispersión múltiple ya difumina la transición (sección 2.1). El contraste de conteos de una anomalía respecto de regiones de control con trayectos comparables expresa la magnitud con la que se interpreta una imagen muográfica (sección 2.2), y su signo indica si la anomalía aparece como exceso o déficit de muones. Los indicadores que comparan la media de una región con la dispersión espacial de sus píxeles o de su fondo describen la intensidad y el contraste locales, pero no constituyen probabilidades de detección, porque esa dispersión contiene tanto fluctuaciones de conteo como estructura de la escena.

2.7 Aprendizaje profundo en muografía

El aprendizaje automático se ha incorporado a la muografía en varios puntos de la cadena de obtención de imágenes. La revisión de Luo et al. (2025) organiza las técnicas de reconstrucción en imagen por dispersión, por transmisión y con partículas secundarias, y examina para la transmisión las limitaciones del método basado en la razón de flujos frente a algoritmos de inversión de densidad. En la etapa del detector, Galgóczi et al. (2024) entrenaron una red neuronal profunda con muestras simuladas para suprimir el fondo de baja energía en un sistema orientado a la muografía de volcanes, un problema que el telescopio colombiano MuTe aborda con instrumentación híbrida (Peña-Rodríguez et al., 2020). En la tomografía por dispersión, que reconstruye volúmenes pequeños a partir de la desviación de cada muon, se han desarrollado marcos de reconstrucción diferenciables (Sattler et al., 2025)

y redes convolucionales que reducen el ruido de las reconstrucciones (Vinodkumar et al., 2025), y Wang et al. (2026) aplicaron una U-Net entrenada con simulaciones a datos experimentales de exposición corta.

En la mejora de imágenes de baja estadística, los antecedentes son más escasos. Lefevre et al. (2024) entrenaron con muografías simuladas una red para reducir el ruido estadístico de imágenes obtenidas con detectores Micromegas, y O'Donnell et al. (2025) aplicaron una red generativa antagónica condicional de Wasserstein con penalización de gradiente a la mejora de imágenes muográficas de estructuras de concreto, con imágenes de un día de exposición que alcanzaron, según el SSIM, la calidad de imágenes de 21 días. En un problema estadísticamente análogo, la tomografía computarizada de baja dosis, cuyo ruido cuántico también es de Poisson, Yang et al. (2018) mostraron que una red antagónica con distancia de Wasserstein preserva texturas que una pérdida de error cuadrático tiende a suavizar. Las aplicaciones volcánicas de la muografía, por su parte, se han apoyado en mapas bidimensionales de opacidad y en sus contrastes (Oláh et al., 2018; Tanaka et al., 2007, 2023). En la literatura revisada no se identificó la aplicación de redes generativas condicionales a la mejora de imágenes de baja estadística de edificios volcánicos, un escenario cuyas distancias, espesores y contrastes difieren de los de las estructuras civiles y de los volúmenes de la tomografía por dispersión, y cuyo entrenamiento exige, como en los trabajos citados, datos simulados.

Con estos elementos quedan establecidos los fundamentos que la metodología requiere: la física que liga los conteos con la opacidad, la estadística que limita su calidad y permite reducir la exposición de forma controlada, la simulación que produce escenarios de estructura conocida, los modelos capaces de estimar imágenes de mayor estadística y los criterios con los que debe juzgarse el resultado. El capítulo 3 describe cómo se aplicaron.

3. Metodología

El procedimiento se desarrolló como un estudio computacional de recuperación de imágenes muográficas de baja estadística. Se partió de escenarios volcánicos idealizados cuya geometría y distribución de materiales eran conocidas; se simuló el transporte de muones, se construyeron imágenes angulares y se redujeron sus conteos de forma controlada. Sobre los pares resultantes se entrenaron modelos de aprendizaje profundo y se evaluó su concordancia con referencias de mayor estadística. La salida estudiada fue una imagen de conteos equivalentes: no se realizó una inversión tridimensional de densidad ni una adquisición de campo.

Las figuras metodológicas incorporadas se seleccionaron de la propuesta de los autores por su correspondencia con la implementación y sus fuentes editables (Cárdenas Tirado & Pinto Ortega, 2026). La descripción sigue la dependencia entre etapas: diseño, simulación, preparación de datos, modelo, entrenamiento y evaluación. Los procedimientos se sustentan en la versión documentada del proyecto (González Gómez et al., 2026). Los valores de desempeño y el balance de cumplimiento se reservan para el capítulo 4. La evaluación incluyó el análisis multifracción y local del tercer objetivo, cuyo procedimiento se ejecutó y revisó antes del cierre experimental. La descripción distingue la generación de datos, el entrenamiento al 5 % y la evaluación de los mismos pesos con cuatro fracciones de conteo.

3.1 Diseño del estudio y secuencia experimental

3.1.1 Alcance y unidades de análisis

La simulación permitió controlar los materiales y disponer de una referencia común para comparar métodos. Esta elección es coherente con el uso de muones transmitidos para estudiar diferencias de columna de masa, sin identificar la respuesta simulada con la de un instrumento real (Bonomi et al., 2020; Lesparre et al., 2010). La representatividad adoptada fue de mecanismos y configuraciones: trayectorias, contrastes de densidad y fluctuaciones de conteo. No se pretendió representar estadísticamente una población de volcanes ni reproducir un sitio particular.

Se distinguieron cuatro unidades. La geometría definió un escenario completo; la vista, una posición de observación; la realización, un submuestreo de una referencia fija; y la ejecución de entrenamiento, una trayectoria de optimización. Esta separación evitó tratar píxeles o realizaciones de una vista como escenarios independientes. Los métodos se compararon sobre las mismas entradas y referencias.

Los resúmenes entre escenarios se calcularon por geometría, manteniendo separadas prueba y generalización.

La Tabla 3.1 relaciona las etapas con los objetivos. La Figura 3.1 muestra su secuencia y la separación entre generación de datos, ajuste y evaluación.

Tabla 3.1: Etapas metodológicas y productos del estudio.

Etapa	Procedimiento	Producto y función
Generación (OE1)	Configurar escenarios, fuente y transporte; consolidar imágenes.	Referencias y pares de conteo verificables.
Aprendizaje (OE2)	Transformar datos, entrenar U-Net y cGAN, estudiar ajustes.	Pesos y configuraciones vinculados con sus datos.
Evaluación (OE2–OE3)	Comparar similitud, cuentas, contraste y fracciones.	Tablas por escenario y curvas descriptivas.

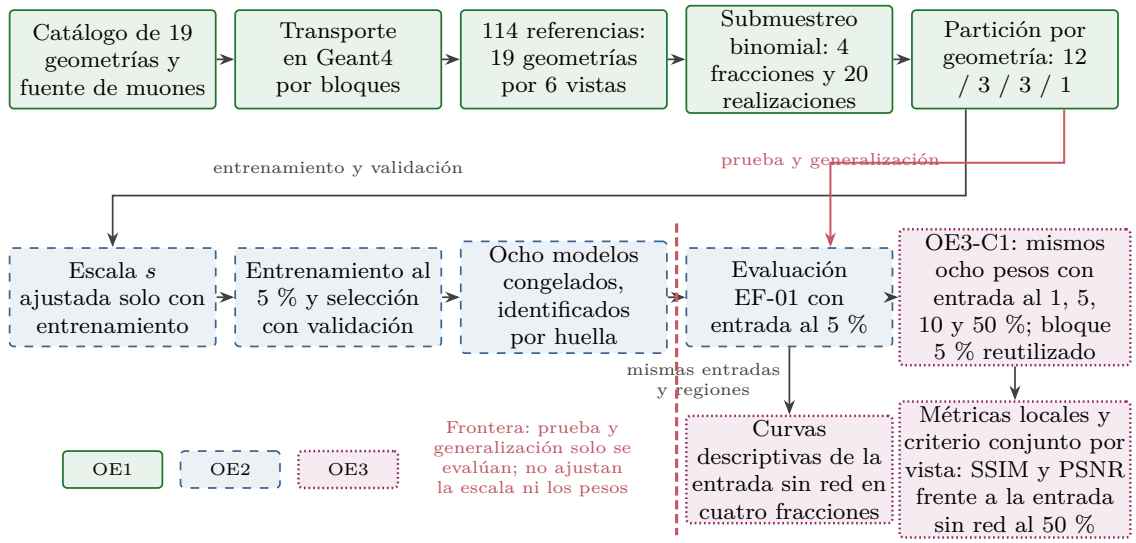

Figura 3.1: Secuencia experimental y separación de las particiones.

3.1.2 Versiones y condiciones de comparación

Se utilizó como base final la campaña corregida de la entrega `f395570`. Las referencias históricas se conservaron como antecedentes; no se convirtieron en datos finales mediante cambios de nombre. Esta distinción fue necesaria porque cambiaron la construcción geométrica, el registro angular y la receta de transporte. La distribución de aprendizaje se vinculó con las referencias finales mediante comprobaciones de contenido.

Se variaron el nivel de conteo, el tipo y contraste de anomalía, la configuración geométrica y la vista. Dentro de cada comparación se conservaron fuente, receta, coordenadas, referencia y preprocesamiento. Las respuestas incluyeron similitud,

sesgo de cuentas, error espacial y contraste. Así se distinguió la modificación evaluada de las condiciones mantenidas constantes.

Los ajustes de redes fueron decisiones de desarrollo sobre validación, no ensayos confirmatorios independientes de los resultados que los motivaron. Las escenas reservadas habían sido conocidas en etapas históricas del proyecto. Aunque las redes finales no se ajustaron con esas particiones, su evaluación se presentó como descriptiva sobre un catálogo potencialmente expuesto. La separación de datos en el entrenamiento actual no elimina ese antecedente.

3.2 Escenarios y simulación de muones

3.2.1 Catálogo y asignación de materiales

Se emplearon diecinueve edificios cónicos, con radios basales entre 509,7 y 698,7 m y alturas entre 356,2 y 449,6 m. La roca de fondo tuvo densidad de 2,65 $\mathrm{g\,cm^{-3}}$. El control homogéneo fue `geo-train-01`; los otros dieciocho escenarios incorporaron conductos, cavidades o cuerpos densos. Se representaron mediante cilindros, esferas y elipsoides, respectivamente. La geometría `geo-gen-01` contuvo un conducto y dos cavidades; no fue el control homogéneo.

Cada escenario conservó dimensiones, posiciones y densidades en una descripción estructurada. Esos parámetros produjeron diferencias de columna de masa y de proyección sin atribuir al catálogo validación geológica externa. La Figura 3.2 permite reconocer primitivas, coordenadas y posiciones de observación.

Para resolver las intersecciones se adoptó la prioridad de la última anomalía en el orden del catálogo. La Ecuación (3.1) expresa la región asignada a cada material: se restringió la anomalía al edificio y se sustrajeron las anomalías posteriores.

$$\mathcal{R}_i = (A_i \cap \mathcal{K}) \setminus \bigcup_{j>i} A_j. \tag{3.1}$$

Aquí A_i es la primitiva, $\mathcal{K}$ el edificio y $\mathcal{R}_i$ su región final. Se emplearon operaciones booleanas y un margen interior de 1 mm cuando fue necesario recortar contra el edificio, evitando superficies coincidentes. Esta regla no implica identidad matemática de todas las fronteras con el motor analítico. Se conservaron también las diferencias declaradas de densidad del aire. En particular, el constructor conservado sustituyó densidades inferiores a 0,05 $\mathrm{g\,cm^{-3}}$ por `G4_AIR`. Se distinguieron las densidades nominales del catálogo de la asignación material del transporte; esta distinción se retoma al describir el diagnóstico de opacidad en la sección 3.8.3.

La verificación combinó controles de solapamiento, sondeos de material, comparación de volúmenes e inspección de cortes. Las intersecciones se contrastaron

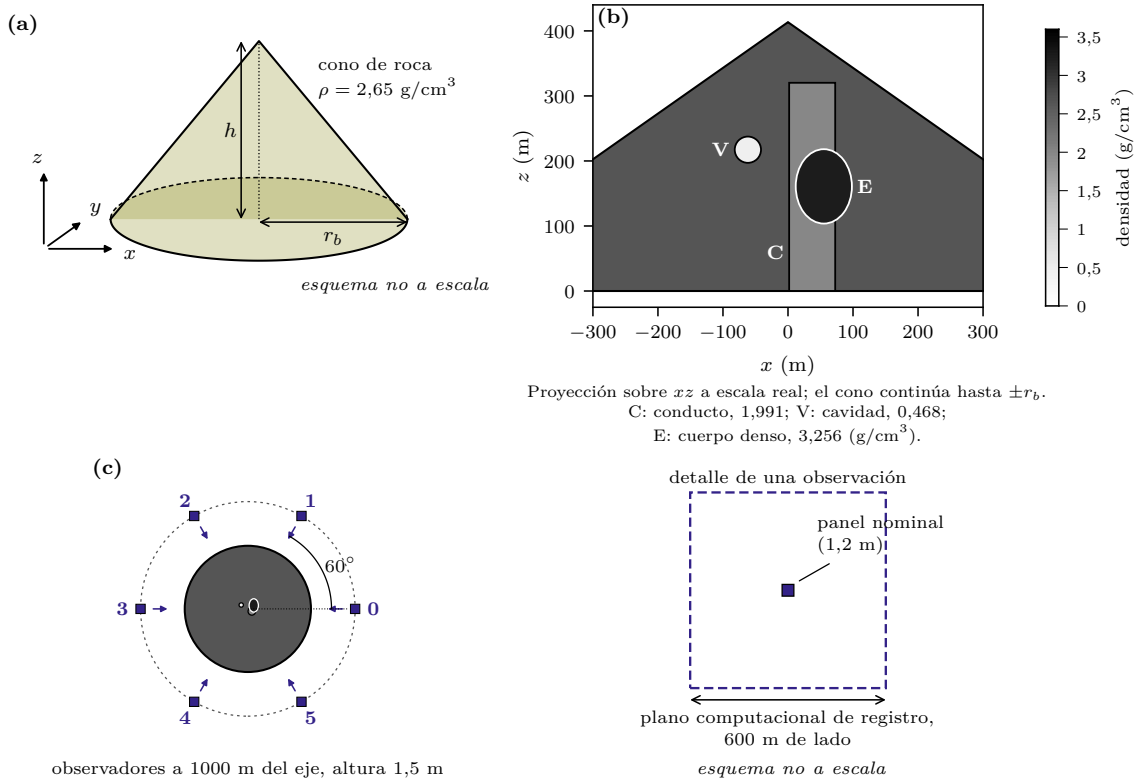

Figura 3.2: Geometría idealizada y seis posiciones de observación. Se ilustra geo-train-08; las densidades son nominales. El panel de detalle distingue el panel nominal de 1,2 m del plano computacional de 600 m. Fuente: elaboración de los autores, conservada en la propuesta de capítulos.

mediante integración independiente. Se distinguió ausencia de advertencias bajo el muestreo aplicado de una prueba universal de navegación. La concordancia geométrica tampoco cuantificó por sí sola el efecto sobre conteos, por lo que se mantuvieron separados los controles geométricos y de transporte.

3.2.2 Fuente y observable

La fuente combinó pesos angulares derivados del modelo de Guan et al. (2015) y cuantiles de momento obtenidos con EcoMug (Pagano et al., 2021). Las tablas y sus huellas se fijaron como entradas de la receta, sin recalcularlas en cada bloque. La fuente híbrida y su extensión angular formaron parte del modelo; no constituyeron una medición local del flujo cósmico.

La generación cubrió un acimut relativo de menos 35 a 35 grados, mientras que la ventana nominal de imagen cubrió de menos 30 a 30 grados. El margen incorporó direcciones adicionales alrededor de la ventana de registro. En elevación se conservaron los pesos tabulados y la extensión documentada en los extremos; los pesos negativos y los centros inferiores a 0,1 grados se anularon. El momento se obtuvo mediante interpolación lineal por tramos de 257 cuantiles en dieciséis bandas de elevación, usando la banda extrema más cercana fuera del dominio tabulado. Esta definición se conservó con las tablas para que una reproducción no sustituyera inadvertidamente el generador por otra distribución.

Se utilizó Geant4 11.4.2, la lista de física FTFP_BERT y un corte de producción de 1 m (Agostinelli et al., 2003; Allison et al., 2016). Se registraron exclusivamente muones primarios. El corte de producción se distinguió del umbral energético de registro, que exigió energía cinética mayor de 3 GeV al cruzar el plano.

Los impactos nominales se muestrearon sobre un panel de 1,2 m de lado. La inyección se situó junto al cono con margen angular de 5 grados; el plano computacional de registro tuvo 600 m de lado. Este plano no representó un instrumento de esa extensión. Su empleo se examinó mediante controles de bordes y fuente ideal, sin convertirlos en una certificación instrumental. La Tabla 3.2 identifica la configuración utilizada.

Tabla 3.2: Configuración de la campaña corregida.

Componente	Configuración
Geometrías y vistas	19 escenarios; seis vistas por escenario.
Transporte	Geant4 11.4.2; FTFP_BERT; primarios.
Registro	Energía cinética mayor de 3 GeV.
Inyección y plano	Panel nominal de 1,2 m; margen de 5 grados; registro de 600 m de lado.
Primarios simulados	344 millones de primarios por vista; nueve bloques.
Resolución	256 filas de elevación y 256 columnas de acimut.
Producción	SC3, partición AMD, 64 hilos, 8 GB solicitados por trabajo; GCC 14.2.0.

3.2.3 Número de muones simulados y consolidación

La campaña final utilizó el mismo número de primarios en cada vista; no se reutilizó el sorteo histórico de eventos asociado a treinta días. Las Ecuaciones (3.2a) y (3.2b) definen el número de primarios por vista y de toda la campaña. Los bloques se identificaron mediante manifiesto y semillas propias.

$$N_{gv} = 344 \times 10^6. \tag{3.2a}$$

$$N_{\text{camp}} = \sum_{g=1}^{19} \sum_{v=0}^{5} N_{gv} = 39\,216\,000\,000. \tag{3.2b}$$

Los índices g y v identifican geometría y vista. Primarios generados y detectados no se consideraron equivalentes. Cada bloque produjo histograma y metadatos; para consolidar se exigió compatibilidad de receta, coordenadas e identidad. Se sumaron cuentas enteras, sin promediar ni suavizar.

Las Ecuaciones (3.3a) y (3.3b) definen referencia y total registrado; b recorre bloques, i elevación y j acimut.

$$C_{gvij} = \sum_{b=1}^{9} C_{gvij}^{[b]}. \tag{3.3a}$$

$$D_{gv} = \sum_{i=0}^{255} \sum_{j=0}^{255} C_{gvij} \leq N_{gv}. \tag{3.3b}$$

Cada píxel representa primarios transmitidos que cumplieron el registro. No representa directamente densidad, opacidad ni transmisión normalizada. La referencia conserva fluctuaciones porque es una realización finita del transporte.

3.2.4 Coordenadas y exportación

Se mantuvo elevación en filas y acimut relativo en columnas. La campaña final utilizó bordes uniformes en acimut y centros uniformes en elevación. Las Ecuaciones (3.4a) y (3.4b) definen el primer eje; las Ecuaciones (3.4c) y (3.4d), el segundo.

$$\alpha_j^e = -30^\circ + j\frac{60^\circ}{256}, \quad j = 0, \ldots, 256. \tag{3.4a}$$

$$\alpha_j = \frac{\alpha_j^e + \alpha_{j+1}^e}{2}, \quad j = 0, \ldots, 255. \tag{3.4b}$$

$$\eta_i = 2^\circ + i\frac{45^\circ}{255}, \quad i = 0, \ldots, 255. \tag{3.4c}$$

$$\Delta\eta = \frac{45^\circ}{255}. \tag{3.4d}$$

Los bordes de elevación se obtuvieron de puntos medios entre centros, extendiendo medio paso en ambos extremos. El soporte efectivo fue aproximadamente de 1,911765 a 47,088235 grados; describirlo como bordes de 2 a 47 grados habría desplazado medio píxel la correspondencia con los archivos. La elevación se midió desde el horizonte y no se confundió con el ángulo cenital referido a la vertical.

Se exportaron coordenadas explícitas con los conteos; no se reconstruyeron desde una figura. La Figura 3.3 explica la relación entre dirección y arreglo. Se verificó correspondencia entre histogramas y matrices, incluyendo coordenadas.

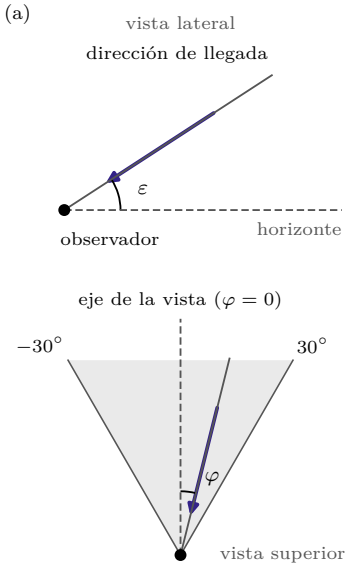

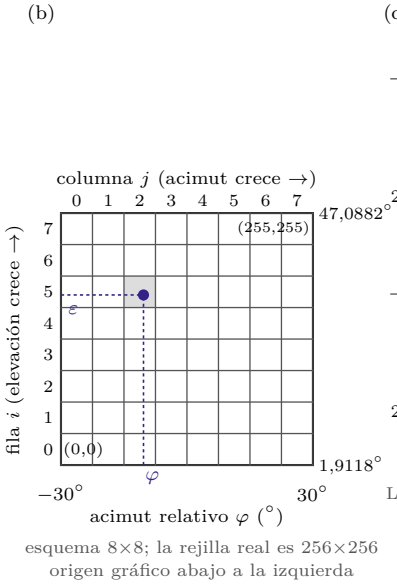

(c)

acimut relativo φ (°), columna j

j	borde izq.	centro	borde der.
0	−30,0000	−29,8828	−29,7656
1	−29,7656	−29,6484	−29,5312
⋮	⋮	⋮	⋮
255	29,7656	29,8828	30,0000

elevación ε (°), fila i

i	borde inf.	centro	borde sup.
0	1,9118	2,0000	2,0882
1	2,0882	2,1765	2,2647
⋮	⋮	⋮	⋮
255	46,9118	47,0000	47,0882

$\Delta\varphi = 0{,}2344^\circ$, $\Delta\varepsilon = 0{,}1765^\circ$
257 bordes y 256 centros por eje.
Leídos de geo-train-06, vista 0 (NPZ final).

Figura 3.3: Direcciones, índices y coordenadas angulares. La rejilla simplificada ilustra la orientación; los valores proceden de geo-train-06, vista 0. Fuente: elaboración de los autores.

3.3 Verificación y preparación del conjunto

3.3.1 Integridad, bordes y estadística de roca

Se verificaron presencia y huellas de archivos, compatibilidad de metadatos y conservación de cuentas y coordenadas. Después se examinaron aspectos del observable. La integridad acreditó identidad de archivos, mientras que los controles del modelo acotaron su interpretación; ninguna verificación sustituyó a las demás.

Para el borde angular se compararon probabilidades registradas con una referencia ideal de la fuente. Las Ecuaciones (3.5a) y (3.5b) definen residuo y diferencia respecto de una región de referencia. K_{gvr} es el conteo regional y p_r^{ideal} y p_r^{nom} son las probabilidades ideal y nominal conservadas en el contrato.

$$e_{gvr} = \frac{K_{gvr}/N_{gv} - p_r^{\text{ideal}}}{p_r^{\text{nom}}}. \tag{3.5a}$$

$$d_{gvr} = e_{gvr} - e_{gvr_0}. \tag{3.5b}$$

Se definieron quince regiones de borde por vista: cinco columnas en cada extremo azimutal, restringidas al cielo entre 30 y 42 grados de elevación, y las cinco filas superiores. La región interior de referencia utilizó cielo en el mismo intervalo de elevación, excluyendo veinte columnas por cada lado. Así se contrastaron bordes con interior bajo la misma fuente, sin exigir uniformidad de cuentas entre elevaciones.

Se construyeron intervalos con cobertura familiar del 95 % bajo el modelo binomial definido en la receta, frente a tolerancia de un punto porcentual. Se conservaron máscaras, referencia ideal y procedimiento de cálculo versionado. El control acotó el comportamiento del observable en bordes; no certificó la respuesta de un instrumento.

Para precisar el cálculo se emplearon límites binomiales Clopper–Pearson y corrección de Bonferroni. La Ecuación (3.6a) define el nivel individual: el factor 16 incluye quince regiones de borde y el interior, y el factor 114 incluye todas las vistas. Las Ecuaciones (3.6b) y (3.6c) especifican los extremos para un conteo regional K en N primarios; B^{-1} denota un cuantil beta.

$$\alpha_* = \frac{0{,}05}{114 \times 16}. \tag{3.6a}$$

$$a_r = \begin{cases} 0, & K = 0, \\ B^{-1}(\alpha_*/2; K, N-K+1), & K > 0. \end{cases} \tag{3.6b}$$

$$b_r = \begin{cases} 1, & K = N, \\ B^{-1}(1-\alpha_*/2; K+1, N-K), & K < N. \end{cases} \tag{3.6c}$$

Al transformar los extremos con la Ecuación (3.5a) se obtuvieron límites para cada residuo. La Ecuación (3.7a) define el intervalo conservador de la diferencia; la Ecuación (3.7b) expresa su criterio de conformidad.

$$I_{gvr} = [e^{-}_{gvr} - e^{+}_{gvr_0},\ e^{+}_{gvr} - e^{-}_{gvr_0}]. \tag{3.7a}$$

$$I_{gvr} \subseteq [-0{,}01;\ 0{,}01]. \tag{3.7b}$$

Se exigió que todo el intervalo estuviera dentro de la tolerancia; no bastó el estimador puntual. La cobertura familiar se sostuvo bajo el modelo binomial marginal, sin exigir independencia entre regiones. No incluyó incertidumbre de las hipótesis físicas de la fuente ideal.

La estadística de roca se examinó en regiones de 4×4 píxeles, seleccionadas por columna nominal de cono homogéneo entre $30\,000$ y $100\,000\ \mathrm{g\,cm^{-2}}$. Las Ecuaciones (3.8a) y (3.8b) definen conteo y proporción de regiones con al menos cien cuentas.

$$H_{gvq} = \sum_{(i,j)\in q} C_{gvij}. \tag{3.8a}$$

$$F_{gv} = \frac{1}{|\mathcal{Q}_{gv}|} \sum_{q \in \mathcal{Q}_{gv}} \mathbf{1}\{H_{gvq} \geq 100\}. \tag{3.8b}$$

$\mathcal{Q}_{gv}$ contiene las regiones elegibles. La meta descriptiva se fijó en una proporción mínima de 0,90 y se aplicó a este soporte; no caracterizó toda la roca ni cada píxel. Las vistas que no alcanzaron la meta se conservaron como excepciones, sin eliminarlas del aprendizaje o evaluación. Su balance pertenece a resultados.

3.3.2 Construcción de pares

La estadística se redujo conservando cada evento de referencia con probabilidad f, sin simular una nueva campaña para cada fracción. Se utilizaron 0,50, 0,10, 0,05 y 0,01, con veinte realizaciones por vista y fracción. Las Ecuaciones (3.9a), (3.9b) y (3.9c) definen el muestreo y sus momentos condicionales (Kingman, 1992).

$$L_{gvij}^{(f,k)} \mid C_{gvij} \sim \text{Binomial}(C_{gvij}, f). \tag{3.9a}$$

$$\mathbb{E}[L_{gvij}^{(f,k)} \mid C_{gvij}] = fC_{gvij}. \tag{3.9b}$$

$$\text{Var}[L_{gvij}^{(f,k)} \mid C_{gvij}] = f(1-f)C_{gvij}. \tag{3.9c}$$

La referencia y las entradas comparten eventos de origen. Las semillas se derivaron de la maestra 20260805 y de índices de geometría, vista, fracción y realización. Se conservaron los estados y se reprodujo contenido con la versión registrada de NumPy (Harris et al., 2020). El empaquetado final no aplicó suavizado, normalización por imagen ni recorte a 65 535 cuentas; no se confundió con la implementación histórica que incluía ese recorte.

El Algoritmo 3.1 sintetiza el procedimiento. La Figura 3.4 ilustrará sus productos con datos identificados de la campaña final.

Algoritmo 3.1 Construcción reproducible de pares.

Entrada: Referencias verificadas, coordenadas, fracciones y semilla maestra.
Salida: Pares y metadatos vinculados con sus referencias.

para cada geometría y vista en el orden fijado **hacer**
    Verificar identidad, forma y coordenadas.
    para cada fracción y cada una de las veinte realizaciones **hacer**
        Derivar un estado aleatorio a partir de los índices registrados.
        Muestrear cada píxel mediante la Ecuación (3.9a).
        Conservar los conteos y asociarlos con la referencia.
    fin para
    Guardar coordenadas, fracciones, semillas y huellas de contenido.
    Comprobar correspondencia con los arreglos originales.
fin para

3.3.3 Particiones y contrato de datos

Se asignaron geometrías completas a entrenamiento, validación, prueba y generalización. Sus vistas, fracciones y realizaciones permanecieron juntas, evitando compartir referencias entre ajuste y evaluación (Kaufman et al., 2012). La Tabla 3.3 distingue el conjunto completo del utilizado al 5 %. No se reasignaron casos después de observar su dificultad. La única geometría de generalización permitió estudiar un caso separado, sin estimar variabilidad entre varios escenarios de esa partición. El

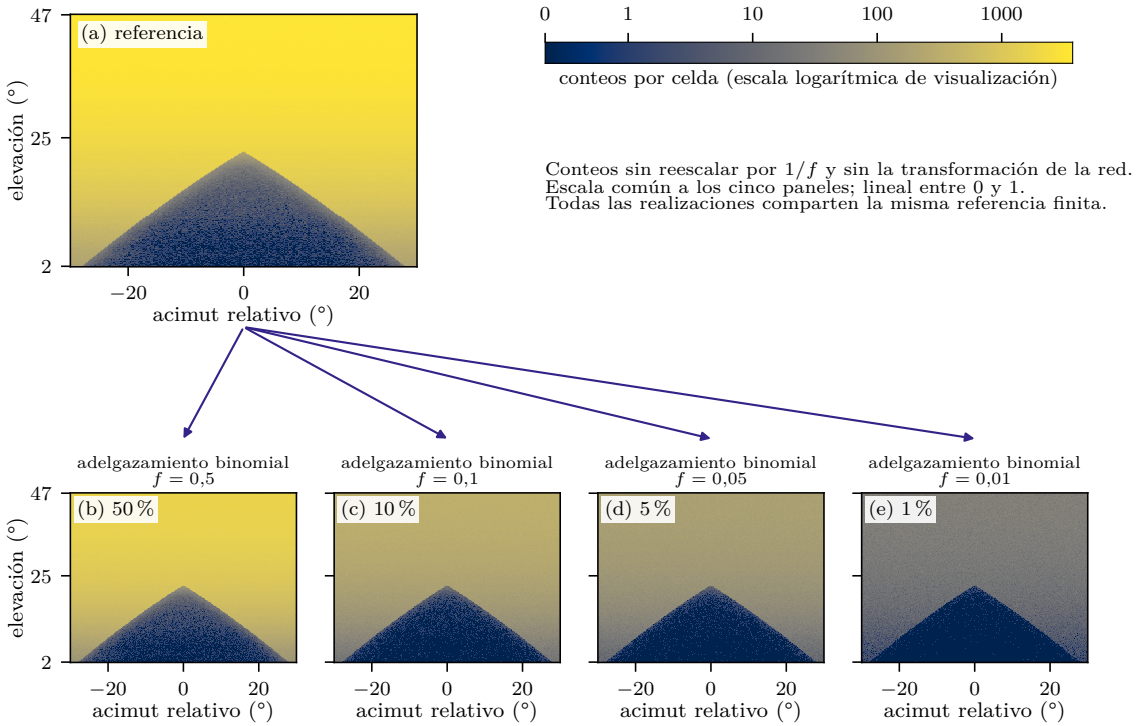

Figura 3.4: Referencia finita y cuatro realizaciones reducidas de geo-train-06, vista 3, realización 0. Se muestran conteos sin dividir por la fracción, con escala común logarítmica de visualización, lineal entre cero y una cuenta. Fuente: elaboración de los autores.

Tabla 3.3: Escenarios, vistas y pares por partición.

Partición	Geometrías	Vistas	Pares totales	Pares al 5 %
Entrenamiento	12	72	5 760	1 440
Validación	3	18	1 440	360
Prueba	3	18	1 440	360
Generalización	1	6	480	120
Total	19	114	9 120	2 280

lector de entrenamiento aceptó únicamente train y val; la evaluación final utilizó otro contrato, con pesos y archivos identificados.

La conversión a la distribución de aprendizaje se verificó contra cada paquete de origen. Se conservaron huellas de archivo y de contenido cuando fue necesario distinguir compresión y arreglos. Una igualdad de contenido no autorizó sustituir archivos dentro de un manifiesto congelado: otra distribución requirió identidad y procedencia propias.

3.4 Representación de conteos y arquitectura

3.4.1 Normalización disponible en inferencia

Los conteos se transformaron para estabilizar la representación y obtener una salida compatible con sigmoide. Se fijó una escala con el máximo de las referencias de entrenamiento, sin usar máximos de validación o reservas. Las Ecuaciones (3.10a) y (3.10b) definen el ajuste.

$$M = \max_{g \in \mathcal{G}_{\text{train}}, v, i, j} C_{gvij} = 3786. \tag{3.10a}$$

$$s = \log(1 + \max\{1, M\}) = 8{,}239329427901795. \tag{3.10b}$$

La escala se guardó con contrato y pesos. La entrada se corrigió por su fracción conocida antes de transformarla, expresándola en cuentas equivalentes a la referencia. Las Ecuaciones (3.11a), (3.11b) y (3.11c) se aplicaron elemento a elemento.

$$T_s(c) = \frac{\log(1 + c)}{s + \log(1 + c)}, \quad c \geq 0. \tag{3.11a}$$

$$\boldsymbol{u} = T_s(\boldsymbol{L}/f). \tag{3.11b}$$

$$\boldsymbol{y} = T_s(\boldsymbol{C}). \tag{3.11c}$$

La entrada depende de sus conteos, de f y de una escala fijada previamente; no necesita la referencia de alta estadística de esa vista. Una entrada vacía produce ceros. No se supuso amplitud transformada proporcional a f, pues la transformación es no lineal.

Las cuentas se recuperaron mediante la Ecuación (3.12). Una predicción fuera del dominio invertible se trató como incidencia explícita, sin recortes silenciosos.

$$T_s^{-1}(z) = \exp\left(\frac{sz}{1 - z}\right) - 1, \quad 0 \leq z < 1. \tag{3.12}$$

Un error pequeño en la representación acotada no equivale a un error constante en

cuentas; se evaluaron ambos dominios. La Figura 3.5 muestra esa separación.

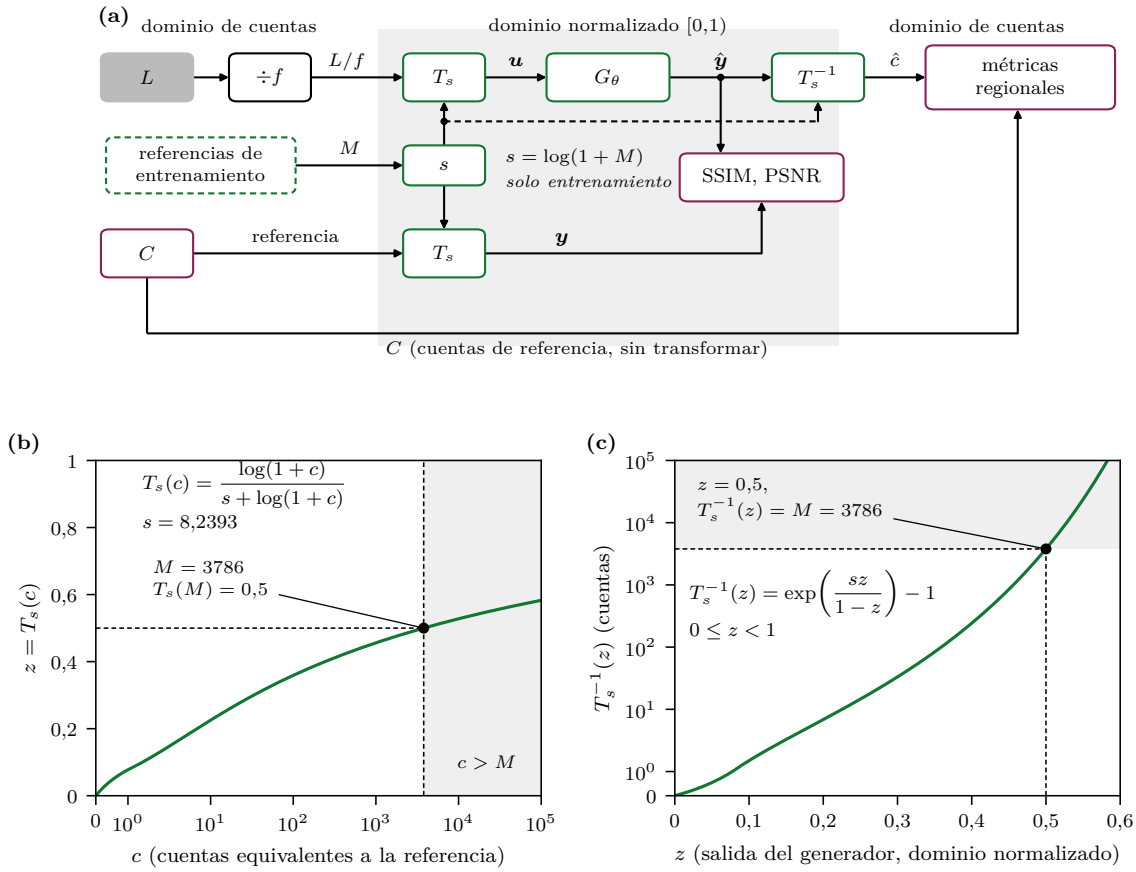

Figura 3.5: Transformación de entrada y referencia y recuperación de cuentas equivalentes. La escala procede exclusivamente de entrenamiento; los gráficos representan la transformación y su inversa. Fuente: elaboración de los autores.

3.4.2 Generador y crítico

El generador se basó en U-Net, con codificador y decodificador conectados a iguales resoluciones (Ronneberger et al., 2015). Las concatenaciones combinaron información espacial temprana con representaciones de mayor contexto. La implementación `unet_dc_5` tuvo cinco niveles con canales 64, 128, 256, 512 y 512. Cada bloque incluyó dos convoluciones de 3×3, normalización por instancia y LeakyReLU. Cuatro reducciones llevaron la imagen de 256×256 a 16×16; el decodificador recuperó resolución mediante convoluciones transpuestas. Una convolución de 1×1 y una sigmoide produjeron un canal.

La Tabla 3.4 resume el codificador. La Figura 3.6 representa además decodificador y crítico. El generador completo tuvo 20 543 809 parámetros. La reducción se realizó mediante agrupamiento máximo de 2×2. Las convoluciones transpuestas tuvieron núcleo de 2×2 y paso dos; cada concatenación se procesó con un bloque de dos convoluciones. La pendiente negativa de LeakyReLU fue 0,2. En el decodificador

se recuperaron sucesivamente 512, 256, 128 y 64 canales antes de la proyección final. El crítico recibió la entrada junto con una imagen real o generada (Isola et al., 2017).

Tabla 3.4: Niveles del codificador del generador.

Nivel	Resolución	Canales
Entrada	256×256	1
Primer bloque	256×256	64
Segundo bloque	128×128	128
Tercer bloque	64×64	256
Cuarto bloque	32×32	512
Nivel profundo	16×16	512

La concatenación se realizó sobre el eje de canales, formando una entrada de dos canales. Se emplearon cinco convoluciones de núcleo 4×4 y relleno de un píxel, con canales de salida 64, 128, 256, 512 y uno. Sus pasos fueron dos, dos, dos, uno y uno. Se aplicaron normalización por instancia en las capas intermedias y LeakyReLU de pendiente 0,2, sin normalización en la primera ni activación sigmoide en la última. Para entrada de 256×256, la salida fue de 30×30 puntuaciones. El campo receptivo convolucional nominal fue de 70×70 píxeles; esta dimensión arquitectónica no se interpretó como resolución física.

La variante `patch_critic_70` produjo puntuaciones espaciales, agregadas por muestra según la Ecuación (3.13). P_D es el número de parches y $D_{\phi,p}$ su puntuación.

$$S_\phi(\boldsymbol{u}, \boldsymbol{y}) = \frac{1}{P_D} \sum_{p=1}^{P_D} D_{\phi,p}(\boldsymbol{u}, \boldsymbol{y}). \tag{3.13}$$

3.4.3 Pérdidas y coherencia del gradiente

Se utilizó entrenamiento de Wasserstein con penalización de gradiente (Gulrajani et al., 2017). Las Ecuaciones (3.14a) y (3.14b) definen interpolación y penalización. ϵ se muestreó uniformemente entre cero y uno para cada muestra del lote.

$$\widetilde{\boldsymbol{y}} = \epsilon \boldsymbol{y} + (1 - \epsilon) G_\theta(\boldsymbol{u}). \tag{3.14a}$$

$$\mathcal{L}_{\mathrm{GP}} = \mathbb{E}\left[\left(\|\nabla_{\widetilde{\boldsymbol{y}}} S_\phi(\boldsymbol{u}, \widetilde{\boldsymbol{y}})\|_2 - 1\right)^2\right]. \tag{3.14b}$$

Se diferenció la misma puntuación media que intervino en el término adversario. No se empleó una suma de parches en la penalización ni se dividió el gradiente individual por el tamaño del lote. Se mantuvo así coherencia entre función optimizada y restricción.

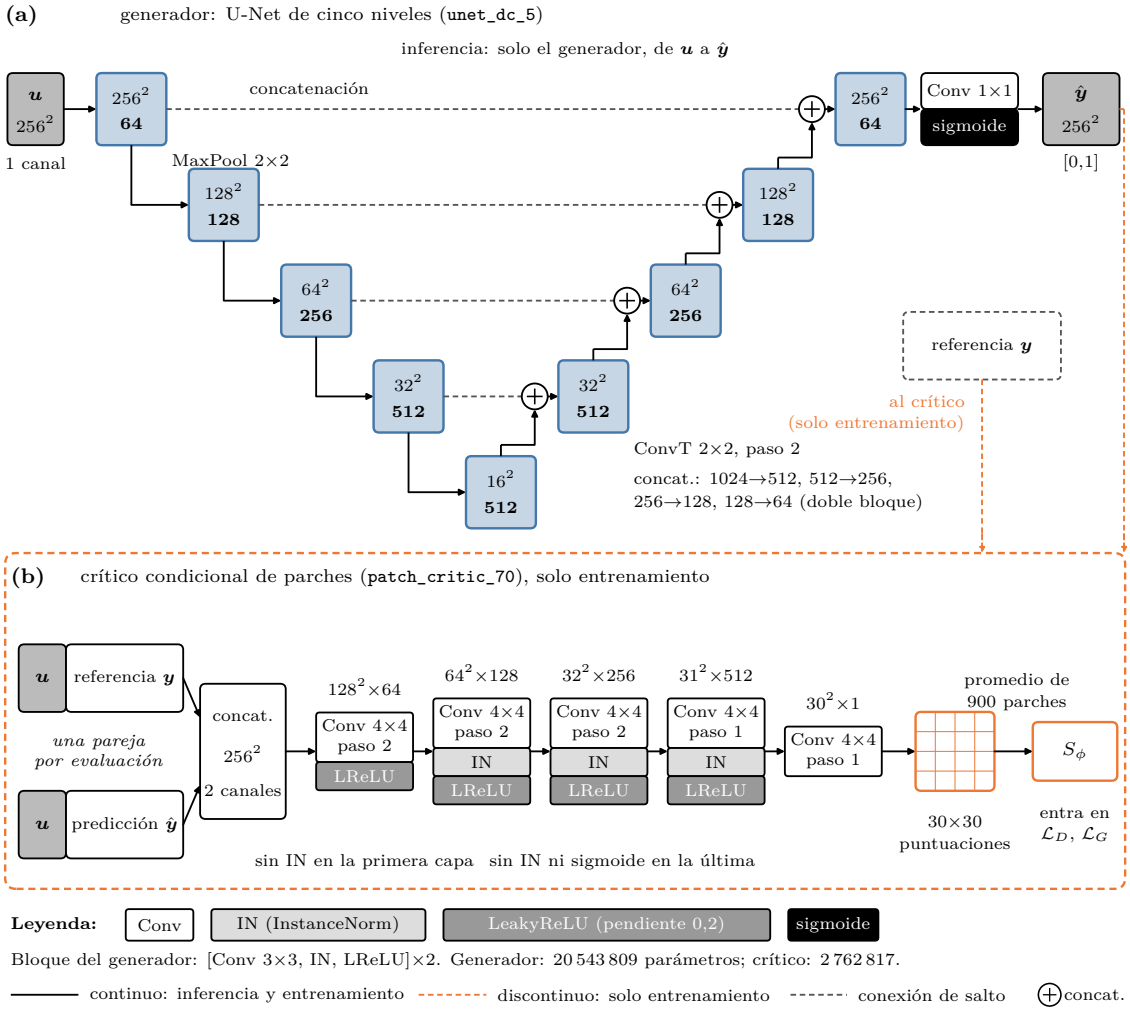

Figura 3.6: Arquitectura del generador U-Net y del crítico condicional. Se distinguen concatenación de características y promedio de puntuaciones. En inferencia se utiliza solo el generador. Fuente: elaboración de los autores.

Las Ecuaciones (3.15a), (3.15b) y (3.15c) describen pérdidas de crítico, reconstrucción y generador. P es el número de píxeles; las esperanzas se estimaron mediante promedios del lote.

$$\mathcal{L}_D = \mathbb{E}[S_\phi(\boldsymbol{u}, G_\theta(\boldsymbol{u}))] - \mathbb{E}[S_\phi(\boldsymbol{u}, \boldsymbol{y})] + 10\mathcal{L}_{\mathrm{GP}}. \tag{3.15a}$$

$$\mathcal{L}_1 = \mathbb{E}\left[\frac{1}{P}\sum_{p=1}^{P} |G_\theta(\boldsymbol{u})_p - y_p|\right]. \tag{3.15b}$$

$$\mathcal{L}_G = -\mathbb{E}[S_\phi(\boldsymbol{u}, G_\theta(\boldsymbol{u}))] + 100\mathcal{L}_1. \tag{3.15c}$$

La U-Net de comparación conservó el generador y minimizó únicamente $100\mathcal{L}_1$. La igualdad de épocas no implicó igualdad de tiempo de cómputo, pues la cGAN requirió actualizaciones del crítico.

3.5 Entrenamiento y desarrollo experimental

3.5.1 Piloto y selección con validación

Los modelos iniciales se entrenaron desde cero al 5 %, con 1 440 pares de entrenamiento y 360 de validación. Se desactivaron aumentos y nuevos adelgazamientos; las realizaciones permanecieron congeladas. La Tabla 3.5 resume la configuración. Se

Tabla 3.5: Configuración común del piloto y diferencias entre métodos.

Parámetro	U-Net	cGAN
Fracción y lote	0,05; cuatro imágenes	0,05; cuatro imágenes
Optimizador	Adam	Adam para G y D
Tasa y betas	10^{-4}; $(0; 0, 9)$	10^{-4}; $(0; 0, 9)$
Semilla	2026100301	2026100301
Actualización por lote	Una de G	Cinco de D y una de G
Límite de entrenamiento	Hasta 30 épocas	Hasta 30 épocas
Selección	Máximo SSIM de validación	Máximo SSIM de validación
Parada	Ocho validaciones sin mejora mínima de 0,001	El mismo criterio

separó el máximo de SSIM para conservar pesos del umbral usado para paciencia. Así no se descartó un máximo real por ser menor que el incremento mínimo de parada. Se distinguió la duración de cada ejecución de la época correspondiente a los pesos seleccionados. El criterio de parada limitó la ejecución, mientras que el máximo de validación determinó el estado utilizado posteriormente; los valores obtenidos se presentan en el capítulo 4.

Antes de prolongar ejecuciones se comprobó recuperación tras interrupción,

conservando redes, optimizadores, estados aleatorios, configuración y contrato. Se rechazaron identidades incompatibles. El Algoritmo 3.2 describe la secuencia adversaria.

Algoritmo 3.2 Entrenamiento condicional y selección con validación.

Entrada: Datos train/val verificados, escala, configuración y semilla.
Salida: Pesos seleccionados, estado recuperable y registro por época.

```
Inicializar G, D y optimizadores, o recuperar un estado compatible.
para cada época hasta el límite de épocas o condición de parada hacer
    para cada lote de entrenamiento hacer
        Transformar entrada y referencia con la escala fija.
        para cinco actualizaciones del crítico hacer
            Generar imágenes sin actualizar G; formar interpolaciones.
            Calcular puntuaciones y penalización; actualizar D.
        fin para
        Calcular reconstrucción y término adversario; actualizar G.
    fin para
    Evaluar validación completa sin actualizar parámetros.
    Conservar máximo de SSIM y actualizar por separado la paciencia.
    Guardar estado completo e identidad.
fin para
```

3.5.2 Ajustes regionales y espaciales

Los diagnósticos en validación motivaron continuaciones para examinar conservación de cuentas. Se estudió un término regional en U-Net y cGAN y, posteriormente, un término espacial de borde. Estas etapas fueron desarrollo sobre validación; no se convirtieron en réplicas independientes ni se supuso que C0 y C1 definieran siempre lo mismo.

Las Ecuaciones (3.16a) y (3.16b) definen media espacial y discrepancia regional. La Ecuación (3.16c) asigna igual peso a familias no vacías y regiones de cada familia, seguido del promedio entre imágenes del lote.

$$\overline{c}_R = \frac{1}{|R|} \sum_{p \in R} c_p. \tag{3.16a}$$

$$\ell_R = |\log(1 + \overline{\widehat{c}}_R) - \log(1 + \overline{c}_R)|. \tag{3.16b}$$

$$\mathcal{L}_{\text{reg}} = \frac{1}{B} \sum_{b=1}^{B} \frac{1}{|\mathcal{F}_b|} \sum_{h \in \mathcal{F}_b} \frac{1}{|\mathcal{R}_{bh}|} \sum_{R \in \mathcal{R}_{bh}} \ell_R. \tag{3.16c}$$

$\mathcal{F}_b$ contiene familias elegibles y $\mathcal{R}_{bh}$ sus regiones. Se promediaron cuentas antes del logaritmo; promediar logaritmos por píxel habría definido otra función. La implementación evaluó establemente las sumas necesarias.

El ensayo E1 añadió discrepancia absoluta en la máscara de borde mediante

la Ecuación (3.17). Se rechazaron soportes menores de veinte píxeles, referencias nulas y valores no finitos.

$$\mathcal{L}_{\text{borde}} = \frac{1}{B}\sum_{b=1}^{B}\frac{\sum_{p\in R_b}|\widehat{c}_{bp} - c_{bp}|}{\sum_{p\in R_b} c_{bp}}. \tag{3.17}$$

Las Ecuaciones (3.18a) y (3.18b) definen las ramas de E1: C0 ya incorporó el término regional y C1 añadió el espacial.

$$\mathcal{L}_G^{C0} = \mathcal{L}_G + \mathcal{L}_{\text{reg}}. \tag{3.18a}$$

$$\mathcal{L}_G^{C1} = \mathcal{L}_G^{C0} + 0{,}629\mathcal{L}_{\text{borde}}. \tag{3.18b}$$

El coeficiente 0,629 se fijó mediante un perfil de gradientes de doce lotes de entrenamiento antes de comparar nuevos resultados de validación. Fue una escala de optimización, no una tolerancia física. Las parejas B1, B2 y B3 usaron semillas 2026100411, 2026100412 y 2026100413. Partieron de los mismos pesos de generador y crítico, con optimizadores nuevos, tasa 10^{-5} y cinco épocas adicionales. Se conservó la quinta época, sin seleccionar retrospectivamente una semilla favorable.

La recuperación se examinó también en procesos separados. La corrección CG-04c separó la derivación de Wasserstein y penalización, sumando gradientes antes de un único paso del optimizador, sin cambiar la pérdida. Las comprobaciones correspondieron al entorno entregado, sin atribuir determinismo universal entre plataformas.

La Figura 3.7 organiza la secuencia. Las máscaras orientaron pérdidas durante entrenamiento, pero no fueron entradas adicionales necesarias para predecir.

3.6 Evaluación de similitud y conservación de cuentas

3.6.1 Congelamiento e inferencia

La evaluación final incluyó U-Net y cGAN originales y las seis continuaciones E1. Se añadió la entrada sin red, corregida por fracción y transformada con la misma escala. Pesos y archivos reservados se fijaron mediante huellas antes del cálculo de desempeño. No se sustituyeron pesos según el resultado de prueba.

Cada red se aplicó a 360 entradas de prueba y 120 de generalización, siempre al 5 %, en modo evaluación y sin optimización. Se conservaron 120 predicciones por geometría, vinculadas con pesos, datos, escala y orden de muestras. Se verificaron forma, rango y valores finitos. La reevaluación completa de métricas desde

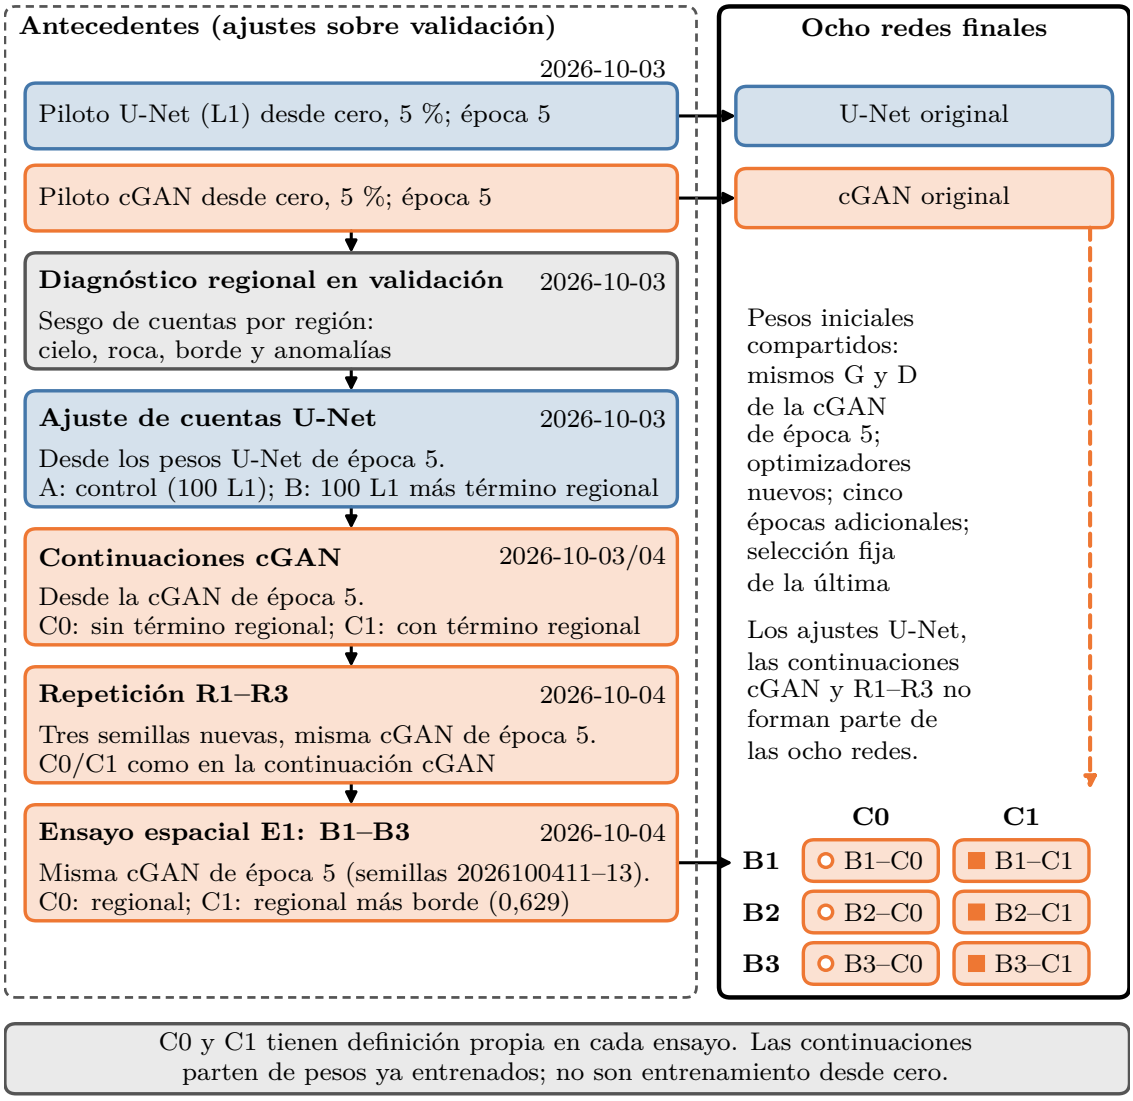

Figura 3.7: Secuencia de desarrollo y ocho redes finales. La mención de época 5 identifica los pesos seleccionados de los modelos originales, no la duración de sus entrenamientos. C0 y C1 conservan definiciones propias de cada ensayo. Fuente: elaboración de los autores.

matrices conservadas se distinguió de una nueva inferencia: la comparación adicional CPU/GPU utilizó una muestra de treinta y dos imágenes.

3.6.2 Métricas de imagen

Se calcularon SSIM y PSNR en representación acotada y rango uno. Las Ecuaciones (3.19a) y (3.19b) definen error cuadrático y transformación a decibelios; p recorre referencia $\boldsymbol{y}$ y predicción $\boldsymbol{z}$.

$$\mathrm{MSE} = \frac{1}{P}\sum_{p=1}^{P}(z_p - y_p)^2. \tag{3.19a}$$

$$\mathrm{PSNR} = -10\log_{10}(\mathrm{MSE}). \tag{3.19b}$$

Un error nulo se registró como coincidencia perfecta con PSNR infinito, no como cero. SSIM comparó luminancia, contraste y estructura local (Wang et al., 2004). La Ecuación (3.20) emplea medias, varianzas y covarianza en ventanas uniformes de 7×7. Las constantes fueron $C_1 = 0{,}01^2$ y $C_2 = 0{,}03^2$, para rango uno.

$$\mathrm{SSIM}(y, z) = \frac{(2\mu_y\mu_z + C_1)(2\sigma_{yz} + C_2)}{(\mu_y^2 + \mu_z^2 + C_1)(\sigma_y^2 + \sigma_z^2 + C_2)}. \tag{3.20}$$

Se conservó la parametrización del evaluador, incluidos ventana y bordes. Se calcularon métricas por imagen, se resumieron por geometría y se asignó igual peso a cada geometría de la partición. No se mezclaron con métricas obtenidas con la normalización histórica.

3.6.3 Regiones, sesgo y error espacial

Las máscaras de cielo, roca, borde y anomalías se obtuvieron de la geometría, conservando parámetros y correspondencia angular. No se seleccionaron por mostrar errores favorables.

Se trazaron rayos rectos desde la posición nominal a 1.000 m del eje y 1,5 m de altura, con las seis orientaciones del catálogo y longitud máxima de 3.000 m. Se intersectaron con el cono nominal, de radio superior 0,1 m, y con las primitivas de anomalías recortadas al cono. Las máscaras representan proyecciones nominales, no trayectorias dispersadas ni asignaciones de prioridad material en solapamientos.

Tabla 3.6: Definición geométrica de las regiones de evaluación.

Región	Construcción
Cielo	Rayos sin intersección con el cono; erosión de dos píxeles.
Roca	Interior erosionado dos píxeles; exclusión de anomalías dilatadas dos píxeles.
Borde	Diferencia entre dilatación y erosión de dos píxeles de la silueta.
Anomalía	Longitud en la primitiva recortada de al menos 20 m; erosión de un píxel.

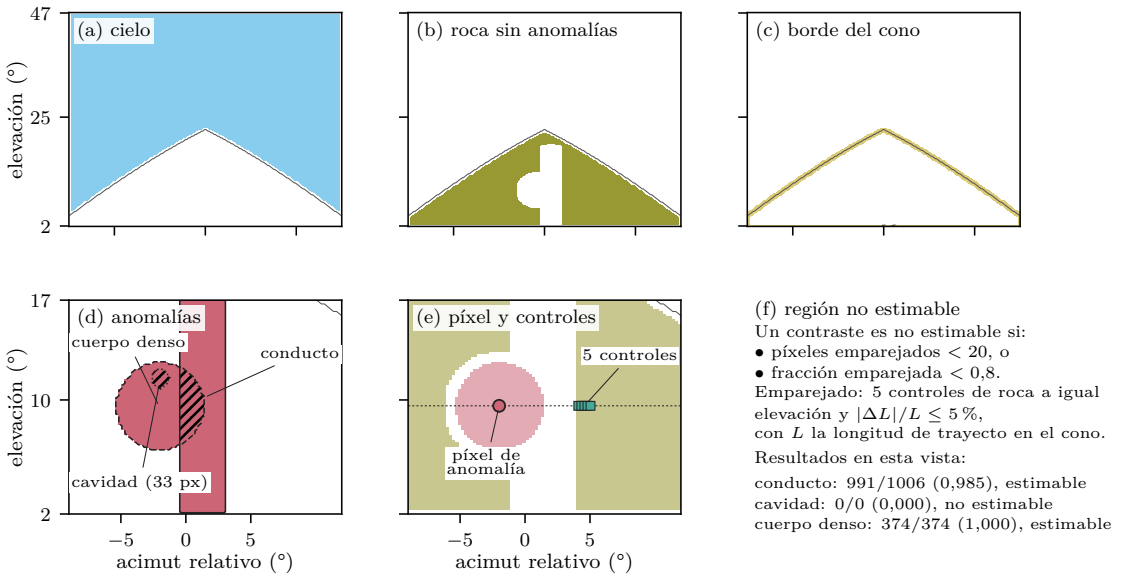

Figura 3.8: Máscaras y controles en geo-train-08, vista 0. Los paneles de anomalías y controles amplían la región de interés. La cavidad no cumple el soporte emparejado en esta vista; se conserva como no estimable. Fuente: elaboración de los autores.

La Tabla 3.6 fija sus definiciones. Se utilizó vecindad cuadrada para erosión y dilatación, tratando el exterior de la imagen como falso en la erosión. Las regiones no constituyen necesariamente una partición exhaustiva y disjunta; no se sumaron sus cuentas como si lo fueran. La Figura 3.8 muestra máscaras y controles de contraste. Se invirtieron predicciones a cuentas antes de sumar. Las Ecuaciones (3.21a) y (3.21b) distinguen sesgo firmado y error espacial para región R y realización k.

$$b_{Rk} = \frac{\sum_{p \in R} (\widehat{c}_{kp} - c_p)}{\sum_{p \in R} c_p}. \tag{3.21a}$$

$$a_{Rk} = \frac{\sum_{p \in R} |\widehat{c}_{kp} - c_p|}{\sum_{p \in R} c_p}. \tag{3.21b}$$

El sesgo permite cancelación entre excesos y déficits; el error espacial acumula magnitudes. Se reportaron ambos para no identificar suma conservada con preservación espacial. Las regiones menores de veinte píxeles o con referencia nula se señalaron como no estimables mediante una regla común.

Las Ecuaciones (3.22a) y (3.22b) definen Q. $\mathcal{A}_{gv}$ contiene anomalías elegibles y V_g es el número de vistas; se exigió soporte completo.

$$\bar{b}_{gvR} = \frac{1}{20} \sum_{k=1}^{20} b_{gvRk}. \tag{3.22a}$$

$$Q_g = \frac{1}{V_g} \sum_{v} \frac{1}{2} \left(|\bar{b}_{gv,\mathrm{roca}}| + \frac{1}{|\mathcal{A}_{gv}|} \sum_{a \in \mathcal{A}_{gv}} |\bar{b}_{gva}| \right). \tag{3.22b}$$

El valor absoluto se aplicó después del promedio entre realizaciones. Q no es error absoluto medio por píxel ni error de densidad. Sin anomalías o con soporte incompleto se conservó el indicador de roca y se señaló Q como no aplicable o incompleto, sin asignarle cero.

3.6.4 Contraste y corrección numérica

Se comparó la media de cuentas de anomalía con controles de roca sin anomalía a igual elevación y trayectos próximos. Se excluyeron del núcleo objetivo los rayos que atravesaban otras anomalías, con margen de dos píxeles. Se exigió diferencia relativa de longitud no mayor de 0,05 y cinco controles por píxel, al menos veinte píxeles emparejados y cobertura mínima del 80 % del núcleo elegible. Los controles pudieron reutilizarse, ponderados por sus asignaciones a píxeles objetivo. No se interpretó este comparador como la misma escena sin anomalía, pues no se dispuso de ese contrafactual. Las Ecuaciones (3.23a) y (3.23b) definen contraste y error absoluto.

$$\chi_R = \frac{\overline{c}_R}{\overline{c}_{\mathrm{control}(R)}} - 1. \tag{3.23a}$$

$$E_{\chi,R} = |\widehat{\chi}_R - \chi_R^{\mathrm{ref}}|. \tag{3.23b}$$

Se registraron controles nulos como no estimables. El resumen utilizó soporte común completo de todos los métodos, informando su tamaño y conservando otros casos en registros detallados. El contraste correspondió a cuentas, no a opacidad.

La revisión C2 corrigió la selección inestable de controles con longitudes prácticamente iguales. Las diferencias absolutas de longitud se ordenaron y agruparon desde el mínimo de cada grupo con tolerancia 10^{-8} m, sin encadenar empates transitivos; se desempató por columna. La tolerancia resolvió una cuestión numérica, no una resolución física. Se guardaron índices y huellas de máscaras para reproducir sin elegir controles nuevamente. Fue una corrección posterior a la evaluación y se identificó como tal; no cambió pesos, imágenes ni métricas de similitud.

3.6.5 Agregación e interpretación

Se informaron diferencias candidato menos comparador por geometría e indicador. Las comparaciones principales fueron cGAN frente a entrada, U-Net frente a entrada y cGAN frente a U-Net; las continuaciones se compararon dentro de cada pareja. No se eligió la mejor semilla con prueba. Las parejas compartieron pesos de partida y no estimaron variabilidad desde cero.

Se distinguieron soporte incompleto, ausencia de deterioro en los indicadores enumerados y compromiso o deterioro. Estas categorías fueron descriptivas: ausencia de deterioro no significó equivalencia estadística. No se usó mejora de SSIM para ocultar alteraciones de cuentas ni se trataron veinte realizaciones como veinte geometrías independientes. En EF-01 el alcance se limitó al catálogo y a la fracción del 5 %; el complemento multifracción se describe en la sección 3.7.

3.7 Evaluación multifracción y métricas locales

3.7.1 Diseño del complemento y conservación de los modelos

El análisis de adquisición se desarrolló en dos etapas. Primero se compararon las entradas sin red al 1, 5, 10 y 50 % con las redes evaluadas al 5 %. Esa comparación describió la relación entre estadística de conteo y calidad, pero no estableció un mínimo aceptable. Después se ejecutó el complemento OE3-C1, en el que los ocho modelos congelados recibieron las cuatro fracciones disponibles. Esta segunda etapa completó la evaluación experimental del tercer objetivo (González Gómez et al., 2026).

Se mantuvieron las tres geometrías de prueba y la geometría de generalización, con seis vistas y veinte realizaciones por vista. Los modelos conservaron los pesos seleccionados o continuados al 5 %; no se entrenó una red distinta para cada fracción ni se ajustaron las pérdidas después de conocer la evaluación final. Por ello, la aplicación al 1, 10 y 50 % examinó la transferencia de los mismos modelos a otras estadísticas de entrada. Se distinguió expresamente esta evaluación de un entrenamiento multifracción.

La transformación de la Ecuación (3.11b) se aplicó con la fracción de cada imagen y con la escala original. Se conservaron el modo de evaluación, lotes de cuatro imágenes, determinismo activado y TF32 desactivado. Se reutilizaron las 3 840 predicciones al 5 %, previa comprobación de sus identidades, y se produjeron 11 520 predicciones adicionales para las tres fracciones restantes. El conjunto evaluado comprendió así 15 360 salidas de redes. Cada matriz mantuvo la correspondencia con geometría, vista, realización, fracción y modelo, necesaria para realizar comparaciones sobre las mismas referencias.

La Tabla 3.7 resume el diseño. La Figura 3.9 organiza la comparación multifracción y la aplicación del criterio de calidad; distingue los datos usados para entrenar de los utilizados exclusivamente para evaluar.

3.7.2 Indicadores locales de anomalía y fondo

Se conservaron las máscaras geométricas y los índices de controles estabilizados en C2. Para cada anomalía se identificaron los píxeles objetivo emparejados y sus cinco controles por píxel. La media de fondo conservó las ponderaciones derivadas de esas asignaciones. Para calcular su desviación espacial se empleó, en cambio, el conjunto de donantes únicos; de esta forma, la reutilización de un mismo píxel como control no se interpretó como una observación adicional para estimar dispersión.

Tabla 3.7: Diseño de la evaluación multifracción OE3-C1.

Elemento	Procedimiento establecido
Modelos	U-Net y cGAN originales; seis continuaciones E1 B1–B3, C0/C1.
Fracciones	0,01; 0,05; 0,10; 0,50, con los mismos pesos entrenados al 5 %.
Entradas por fracción	360 de prueba y 120 de generalización.
Referencia	La imagen finita de alta estadística de la misma vista.
Comparador sin red	Conteos divididos por la fracción y transformados con la escala original.
Criterio principal	Alcanzar conjuntamente SSIM y PSNR de la entrada sin red al 50 %, en todas las vistas de cada partición.
Análisis local	Cuentas regionales, SNR espacial, CNR firmado, contraste e inversiones de signo.

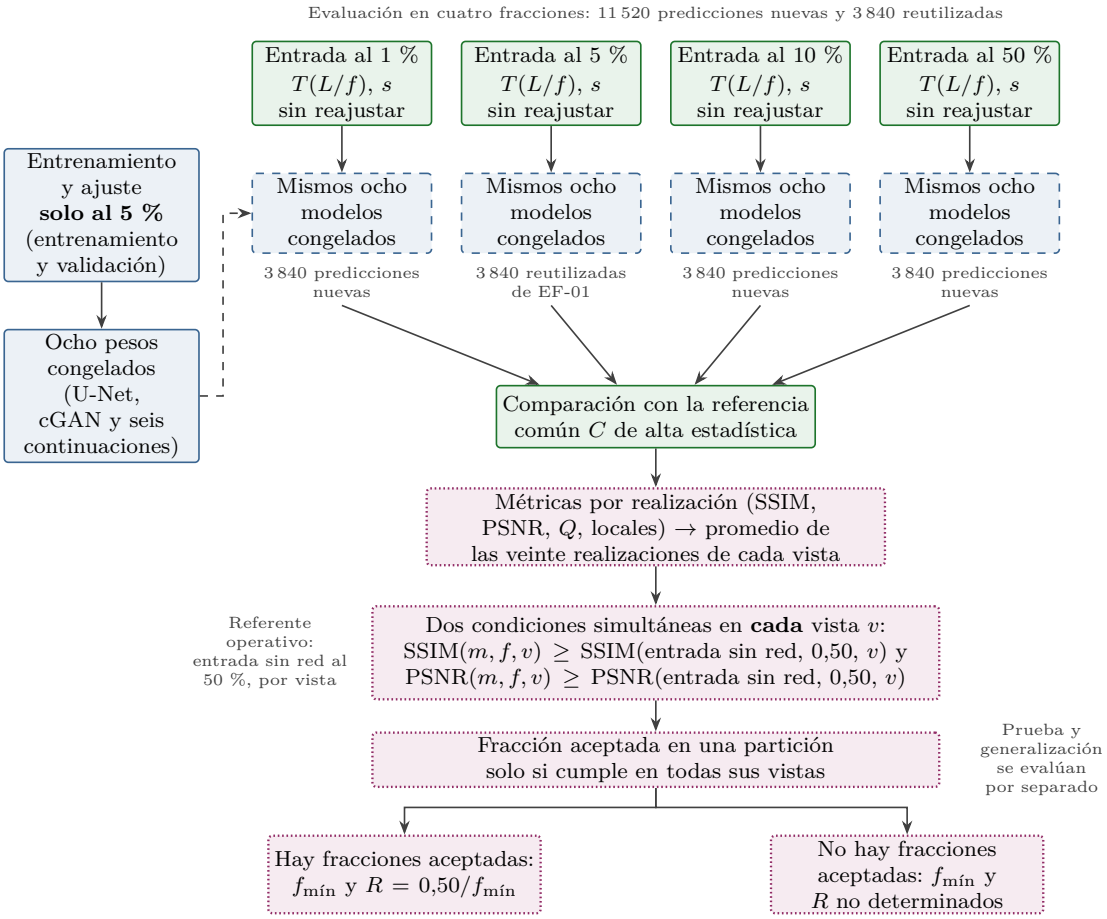

Figura 3.9: Diseño de la evaluación multifracción y del criterio de reducción.

Las Ecuaciones (3.24a) y (3.24b) definen los indicadores de intensidad respecto de dispersión espacial y de contraste respecto del fondo. Se aplicaron a la referencia, a las entradas escaladas y a las cuentas recuperadas de cada red.

$$\mathrm{SNR}_A = \frac{\mu_A}{s_A}. \tag{3.24a}$$

$$\mathrm{CNR}_{A,B} = \frac{\mu_A - \mu_B}{s_B}. \tag{3.24b}$$

Aquí μ_A es la media de cuentas de los objetivos emparejados, μ_B la media ponderada de los controles, y s_A y s_B sus desviaciones espaciales, calculadas con corrección de un grado de libertad. El contraste de cuentas se conservó como en la Ecuación (3.23a). Las tres magnitudes son adimensionales, pero responden a preguntas diferentes: SNR mide intensidad relativa a heterogeneidad interna; CNR conserva el signo de la diferencia respecto del fondo; el contraste expresa esa diferencia en relación con la media del fondo.

La dispersión espacial puede contener tanto fluctuación de conteo como estructura de la escena. En consecuencia, un SNR elevado no se interpretó automáticamente como mayor detectabilidad. Una salida suavizada puede reducir la dispersión y elevar el cociente aunque atenúe una anomalía. La lectura de estos indicadores se acompañó del error de contraste, de su signo y de los errores regionales, sin adoptar un umbral universal de detección.

Se registró también la variabilidad entre realizaciones mediante las Ecuaciones (3.25a) y (3.25b). Para una misma anomalía y vista, k identifica las veinte realizaciones y s_k su desviación muestral.

$$D_k = \mu_{A,k} - \mu_{B,k}. \tag{3.25a}$$

$$J_{\mathrm{rep}} = \frac{\overline{D}}{s_k(D_k)}. \tag{3.25b}$$

Este cociente no se dividió por la raíz del número de realizaciones ni se interpretó como estadístico de significación. La referencia única no proporciona veinte realizaciones independientes para calcularlo. Cuando la desviación fue nula o el soporte insuficiente se conservó el motivo de no estimabilidad, sin asignar infinito ni éxito automático.

Se mantuvieron al menos veinte píxeles objetivo emparejados y cobertura mínima del 80 % del núcleo elegible. Para cada indicador se verificaron los denominadores y la finitud. No se añadieron pseudocuentas ni se sustituyeron valores no estimables por cero. Los soportes comunes se construyeron por métrica para comparar exactamente los mismos casos entre métodos y fracciones.

3.7.3 Agregación de errores y conservación del signo

Los errores locales se calcularon respecto de la misma referencia antes de promediar. La Ecuación (3.26a) define el error para un indicador M, una combinación a de anomalía y vista y la realización k. La Ecuación (3.26b) identifica una inversión de signo del contraste.

$$e_{ak}^{(M)} = \left| M_{ak}^{\mathrm{met}} - M_{a}^{\mathrm{ref}} \right|. \tag{3.26a}$$

$$I_{ak}^{\mathrm{signo}} = \mathbf{1}\Big\{ C_{N,ak}^{\mathrm{met}} C_{N,a}^{\mathrm{ref}} < 0 \Big\}. \tag{3.26b}$$

En la segunda expresión se emplea C_N para el contraste de cuentas definido anteriormente como χ_R. El producto estrictamente negativo exige signos opuestos; los ceros no se cuentan como inversiones. No se eliminó una referencia por tener contraste próximo a cero, aunque se reconoció la sensibilidad de la clasificación en ese caso.

Se promediaron errores sobre realizaciones, luego sobre los casos elegibles de cada geometría y finalmente entre geometrías, con igual peso dentro de la partición. Prueba y generalización permanecieron separadas. El soporte común de SNR comprendió diecinueve combinaciones en prueba y once en generalización; para CNR y contraste fueron veintiuna y once. SSIM, PSNR y Q se mantuvieron sobre sus propios soportes y no se filtraron mediante las exclusiones locales.

Este orden es necesario para interpretar las tablas: el promedio de errores absolutos no equivale al error del promedio. Por ello, el contraste local del complemento no se mezcló con el resumen histórico C2, que utilizó otro soporte y otra agregación. Se conservaron ambos registros con su definición y procedencia.

3.8 Criterio de reducción y diagnóstico de opacidad

3.8.1 Exposición convencional y comparación operativa

Bajo flujo estable y detección constante, la esperanza del conteo es proporcional al tiempo, como expresa la ecuación (2.4b). La Ecuación (3.27) expresa, bajo esa hipótesis, la razón nominal entre fracciones.

$$R_{\mathrm{nom}} = \frac{f_{\mathrm{comparador}}}{f_{\mathrm{modelo}}}. \tag{3.27}$$

La tasa λ se supone constante. La razón corresponde a conteos esperados bajo esas condiciones; no representa un tiempo medido en campo. La campaña conservó además la etiqueta convencional de la Ecuación (3.28), donde N_{gv}^{nom} identifica los primarios de la ventana nominal y S_0 es la normalización tabulada de 36 034 069,911914065

cuentas.

$$T_{gv}^{\mathrm{conv}} = 30\,\mathrm{d}_{\mathrm{conv}}\frac{N_{gv}^{\mathrm{nom}}}{S_0}. \tag{3.28}$$

La etiqueta en días convencionales no constituyó una calibración temporal de un detector. Del mismo modo, dividir por 0,05 produce una razón nominal de veinte respecto de la referencia completa, pero no establece la calidad de la imagen obtenida con una red.

El complemento adoptó como referente operativo la entrada sin red al 50 %, por ser el mayor nivel disponible distinto de la referencia completa. Para cada vista se calcularon sus promedios de SSIM y PSNR sobre veinte realizaciones frente a la referencia. Se conservaron los 48 umbrales resultantes antes de ejecutar las nuevas inferencias. Este criterio evitó utilizar la comparación de la referencia consigo misma, cuyo PSNR sería infinito.

La regla se fijó después de conocer los resultados históricos al 5 % y las curvas de entrada. Por tanto, fue previa a las nuevas inferencias, pero no un umbral original de la propuesta ni una validación confirmatoria independiente. Su carácter operativo se mantuvo separado de una aceptación geofísica. Las métricas regionales y locales se discutieron como evidencia complementaria, sin sustituir retrospectivamente el criterio principal cuando su resultado fue desfavorable.

3.8.2 Fracción mínima y factor asociado

Las Ecuaciones (3.29a) y (3.29b) definen los umbrales por vista v. Las barras indican promedio entre las veinte realizaciones y todas las comparaciones se realizan frente a la misma referencia de alta estadística.

$$\tau_{S,v} = \overline{\mathrm{SSIM}}_{\mathrm{entrada},0{,}50,v}. \tag{3.29a}$$

$$\tau_{P,v} = \overline{\mathrm{PSNR}}_{\mathrm{entrada},0{,}50,v}. \tag{3.29b}$$

Para cada modelo m y partición S, se exigió que ambas métricas alcanzaran sus umbrales en todas las vistas. La Ecuación (3.30) expresa el conjunto de fracciones aceptadas, con $F = \{0{,}01; 0{,}05; 0{,}10; 0{,}50\}$ y tolerancia exclusivamente aritmética $\varepsilon = 10^{-12}$.

$$\mathcal{A}_{m,S} = \left\{ f \in F :\ \forall v \in S,\ \begin{array}{l} \overline{\mathrm{SSIM}}_{m,f,v} + \varepsilon \geq \tau_{S,v} \\ \overline{\mathrm{PSNR}}_{m,f,v} + \varepsilon \geq \tau_{P,v} \end{array} \right\}. \tag{3.30}$$

La tolerancia no fue un margen de equivalencia de calidad. Cuando el conjunto no es vacío, las Ecuaciones (3.31a) y (3.31b) definen el mínimo muestreado y la razón asociada al referente del 50 %.

$$f_{\min,m,S} = \min \mathcal{A}_{m,S}. \tag{3.31a}$$

$$R_{m,S} = \frac{0{,}50}{f_{\min,m,S}}. \tag{3.31b}$$

Si el conjunto es vacío, ambas cantidades se informan como no determinadas. No se asigna cero ni uno, ni se interpola un valor entre las fracciones. Se examinó toda la rejilla sin suponer monotonía. El Algoritmo 3.3 resume la decisión y conserva por separado las dos particiones.

Algoritmo 3.3 Evaluación de la fracción mínima en la rejilla disponible.

Entrada: Métricas por realización, pesos congelados y umbrales por vista.
Salida: Conjuntos aceptados y factores determinados o no determinados.

```
para cada modelo y cada partición hacer
    Inicializar el conjunto de fracciones aceptadas como vacío.
    para cada fracción de la rejilla hacer
        Promediar SSIM y PSNR por vista sobre veinte realizaciones.
        si ambas métricas alcanzan sus umbrales en todas las vistas entonces
            Incorporar la fracción al conjunto aceptado.
        fin si
    fin para
    si el conjunto aceptado está vacío entonces
        Registrar mínimo y factor como no determinados.
    en otro caso
        Obtener el mínimo y calcular la razón respecto de 0,50.
    fin si
    Conservar todas las comparaciones y las exclusiones.
fin para
```

3.8.3 Opacidad nominal y controles geométricos

Como complemento de la interpretación, se calculó una referencia geométrica de opacidad a partir del catálogo y de los rayos centrales. La ecuación (2.3a) expresa la integral de densidad a lo largo de una trayectoria. Para una trayectoria recta de longitud total L que atraviesa una sola anomalía durante una longitud ℓ, la Ecuación (3.32) define la opacidad nominal utilizada.

$$X_{\mathrm{nom}} = 100\,[\rho_r(L-\ell) + \rho_a \ell]\,. \tag{3.32}$$

Las densidades ρ_r y ρ_a se expresan en $\mathrm{g\,cm^{-3}}$ y las longitudes en metros; el factor cien convierte estas últimas a centímetros, de modo que X queda en $\mathrm{g\,cm^{-2}}$. Esta

magnitud no se identificó con el contraste adimensional de cuentas.

Se conservaron las máscaras y los controles C2. Se comprobó que los objetivos seleccionados no atravesaran otras anomalías y que los controles no atravesaran anomalías, evitando sumar materiales incompatibles en regiones superpuestas. La diferencia entre opacidad media de objetivo y control se separó como en la Ecuación (3.33).

$$\overline{X}_A - \overline{X}_B = 100(\rho_a - \rho_r)\overline{\ell} + 100\rho_r(\overline{L}_A - \overline{L}_B). \tag{3.33}$$

El primer término describe el contraste nominal de densidad y el segundo la diferencia de longitud entre los rayos comparados. Se preservaron las ponderaciones de los controles y se verificaron unidades y composición mediante casos analíticos. Así se evitó atribuir a la anomalía una diferencia causada únicamente por trayectos distintos.

El cálculo utilizó densidades declaradas y trayectorias rectas; no reconstruyó opacidad desde las predicciones ni siguió las trayectorias dispersadas de los muones. Se registró la discrepancia de material de la anomalía 2 de `geo-gen-01`, cuya densidad nominal de 0,048 $\mathrm{g\,cm^{-3}}$ activa la sustitución por aire en el constructor conservado. No se supuso una densidad efectiva de producción sin trazabilidad del entorno ejecutado. Este diagnóstico delimitó la interpretación de las métricas, sin modificar las imágenes, sus referencias ni los criterios del experimento cerrado.

3.9 Reproducibilidad y trazabilidad

Se conservaron catálogo, tablas, receta, semillas, coordenadas, particiones, escala, pesos y predicciones con identidades verificables. Una huella comprobó igualdad de archivos; no se interpretó como prueba de validez científica ni del momento en que se tomó una decisión.

Se distinguieron tres niveles: integridad y correspondencia; recálculo de transformaciones y métricas desde matrices; y nueva ejecución de un procedimiento, como recuperación o inferencia desde pesos. El recálculo de métricas no se describió como repetición completa de transporte o entrenamiento.

La Tabla 3.8 resume los elementos mínimos. Las fuentes detalladas se conservaron en la revisión documental `9558099` (González Gómez et al., 2026). Los comandos y registros extensos permanecieron como material reproducible; el capítulo describió operaciones en lenguaje metodológico y pseudocódigo. La producción Geant4 correspondió a ejecuciones estudiantiles en SC3. Los entrenamientos conservaron el entorno de cada entrega, sin atribuirlos automáticamente al de transporte. La reproducción local de pares registró NumPy 2.4.4; la revisión C2 utilizó Python 3.12.14, NumPy 2.3.5, PyTorch 2.6.0 y scikit-image 0.26.0. Son versiones de etapas diferentes,

Tabla 3.8: Información para reproducir e interpretar la cadena.

Etapa	Identidad mínima	Comprobación
Transporte	Receta, entorno, binario, geometrías, tablas y semillas.	Bloques, primarios, coordenadas y sumas.
Preparación	Referencias, fracciones, semillas y versión de NumPy.	Correspondencia de arreglos y procedencia.
Entrenamiento	Particiones, escala, código, optimizadores y estados aleatorios.	Recuperación y rechazo de identidades incompatibles.
Evaluación	Pesos, orden de imágenes, máscaras y controles C2.	Integridad y recálculo de métricas.
Adquisición	Fracciones, soporte y supuestos temporales.	Comparación discreta sin extrapolación.

no un entorno universal.

Las limitaciones se incorporaron al diseño de interpretación: geometrías idealizadas, fuente híbrida, registro de primarios, referencia finita, dependencia entre realizaciones, exposición histórica de escenas y entrenamiento de redes en una sola fracción. Estas condiciones delimitan lo que puede concluirse. El criterio operativo de comparación se aplicó a toda la rejilla de fracciones y se conservó su resultado, incluso cuando no permitió definir un factor. El cierre experimental no implicó equivalencia instrumental ni reconstrucción cuantitativa de opacidad.

4. Resultados y discusión

Este capítulo presenta los resultados del estudio computacional y examina su relación con los objetivos planteados. La exposición sigue la secuencia del capítulo 3: primero se describe el conjunto sintético y sus controles; después se compara la recuperación de imágenes al 5 % de los conteos; finalmente se analiza la evaluación multifracción, el comportamiento local de las anomalías y el factor de reducción definido para el tercer objetivo. Los resultados corresponden al experimento concluido y a sus revisiones conservadas en el repositorio (González Gómez et al., 2026).

La comparación distingue similitud de imagen, conservación de cuentas e interpretación física. SSIM y PSNR se calcularon en la representación transformada; el sesgo y los errores regionales se calcularon después de recuperar cuentas. Por ello, la mejora de una métrica no se utiliza como sustituto de las demás. Las cifras de prueba resumen tres geometrías con igual peso, mientras que generalización describe un único escenario y se informa por separado. Las veinte realizaciones por vista caracterizan el submuestreo de una referencia común; no aumentan el número de escenarios independientes.

4.1 Conjunto sintético y controles de la campaña

4.1.1 Producto obtenido y diversidad de las referencias

La campaña corregida produjo 114 imágenes de referencia, correspondientes a diecinueve geometrías y seis vistas por geometría. Cada imagen contiene 256×256 conteos direccionales. Se procesaron 1 026 bloques, con 344 millones de primarios por vista y 39 216 millones en toda la campaña. Estas cantidades describen los muones generados y transportados, no el total registrado en los píxeles, que dependió de cada escenario y de las condiciones de selección.

A partir de esas referencias se obtuvieron 9 120 pares mediante submuestreo binomial, con cuatro fracciones y veinte realizaciones por fracción. Se conservaron 5 760 pares de entrenamiento, 1 440 de validación, 1 440 de prueba y 480 de generalización en el conjunto completo. Para los entrenamientos al 5 % se utilizaron únicamente 1 440 pares de entrenamiento y 360 de validación, conforme a la Tabla 3.3. Esta diferencia evita atribuir a cada modelo el uso de todas las estadísticas disponibles.

La Figura 4.1 reúne configuraciones del catálogo y vistas con distinta suficiencia de conteo. La comparación permite observar la silueta proyectada del edificio y la dependencia angular del conteo. Su propósito es ilustrar la variación del conjunto,

sin presentar la selección como muestra estadística de volcanes reales.

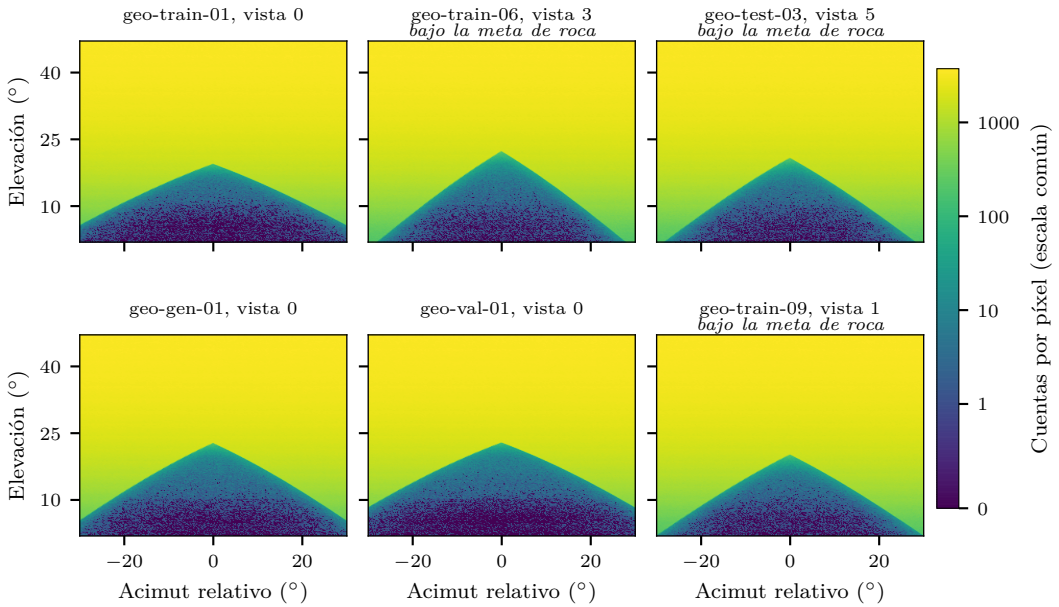

Figura 4.1: Referencias del conjunto corregido en escenarios y vistas seleccionados.

La reducción del conteo se aprecia en la Figura 3.4, que conserva una misma vista y la misma escala para las cuatro fracciones. Al disminuir el número de eventos se incrementa la fluctuación relativa y aparecen más celdas vacías en las regiones de baja transmisión. Las entradas reducidas proceden de la referencia finita; no son simulaciones de transporte independientes. En consecuencia, el conjunto permite estudiar recuperación condicionada por ese mecanismo de reducción, con una referencia que conserva su propia incertidumbre de conteo.

4.1.2 Respuesta en los bordes angulares

Las 1 710 regiones de borde cumplieron el criterio establecido antes de la campaña. La Figura 4.2 representa las diferencias respecto del interior y los intervalos simultáneos, junto con la tolerancia de un punto porcentual. El cumplimiento se refiere al intervalo completo, según la Ecuación (3.7b), y no solo a que las estimaciones puntuales se aproximen a cero.

Este resultado respalda la estabilidad del observable en los extremos de la ventana respecto del interior definido por la misma fuente. Su alcance es específico: no verifica por sí mismo una respuesta instrumental, la calibración del flujo ni la equivalencia entre el plano computacional y un detector físico. La referencia ideal utilizada en el control responde a las hipótesis de generación; por tanto, superar esta comprobación no elimina las simplificaciones de la fuente y del transporte.

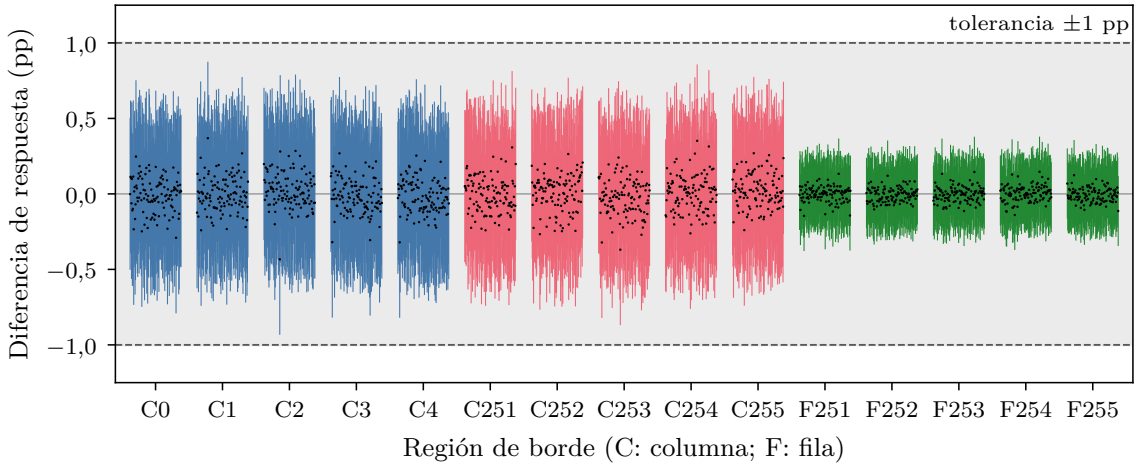

Figura 4.2: Diferencias de respuesta de las quince regiones de borde en las 114 vistas, expresadas en puntos porcentuales. C identifica columnas y F filas; las líneas discontinuas delimitan la tolerancia de ±1 punto porcentual. Los intervalos corresponden al control simultáneo de la campaña. Fuente: elaboración de los autores a partir de la evaluación congelada del OE1.

4.1.3 Suficiencia de conteo en roca y conservación de excepciones

En las 21 816 regiones de roca de 4×4 píxeles se encontraron 20 713 con al menos cien cuentas, equivalentes al 94,944 % del total. Sin embargo, el criterio se había definido por vista: al menos el 90 % de sus regiones debía alcanzar ese conteo. La meta se cumplió en 107 de las 114 vistas. Las siete restantes se conservaron y se identifican en la Tabla 4.1; no se retiraron para mejorar el porcentaje global.

Tabla 4.1: Vistas que no alcanzaron el 90 % de regiones de roca con cien cuentas. Se conservaron en el conjunto definitivo. Fuente: registros de calidad del OE1.

Geometría	Vista	ROI conformes	ROI totales	Proporción (%)
`geo-test-03`	1	199	222	89,64
`geo-test-03`	5	198	222	89,19
`geo-train-06`	3	218	244	89,34
`geo-train-09`	1	185	206	89,81
`geo-train-09`	4	185	206	89,81
`geo-train-09`	5	184	206	89,32
`geo-train-12`	2	210	234	89,74

Las proporciones de estas vistas quedaron entre 89,19 y 89,81 %. La Figura 4.3 sitúa las excepciones dentro del conjunto completo, evitando que el agregado oculte su distribución. La diferencia frente a la meta fue pequeña, pero se conserva como incumplimiento de ese indicador descriptivo y no como una aprobación redondeada.

El umbral de cien cuentas se aplicó a la suma de dieciséis píxeles. No permite

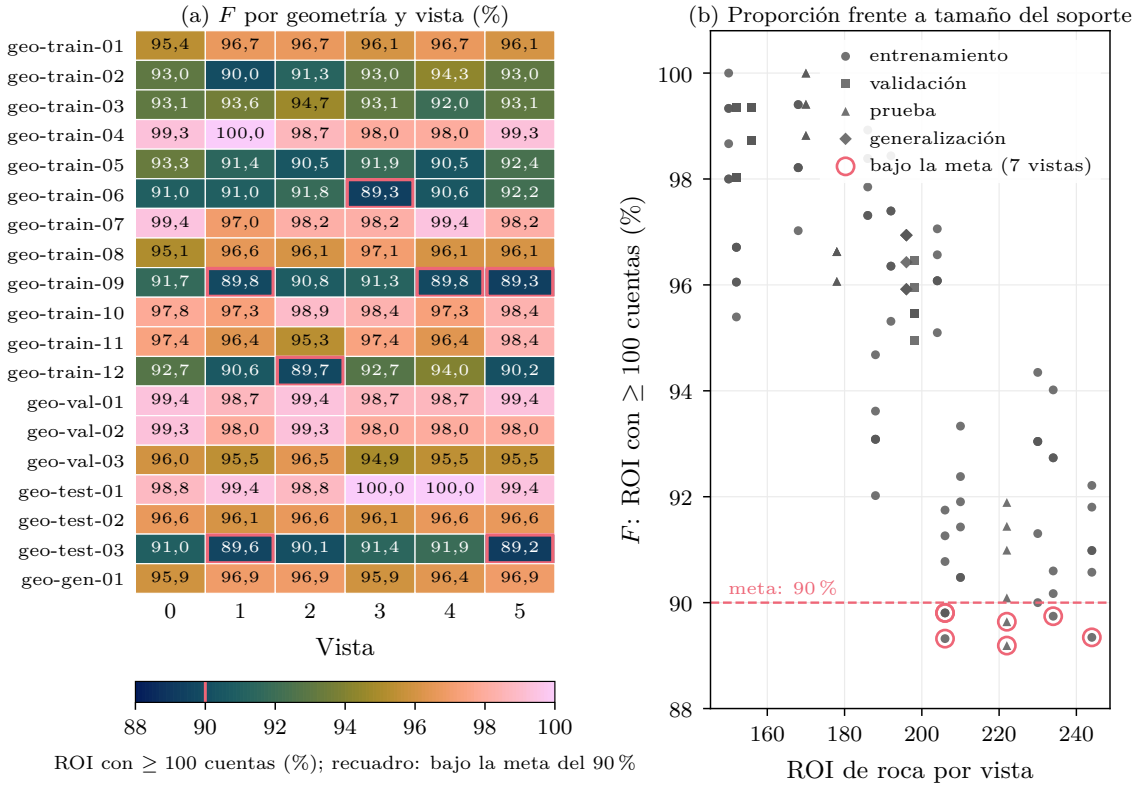

Figura 4.3: Suficiencia de conteo en roca por geometría y vista.

afirmar que cada píxel tenga cien eventos ni que toda la imagen alcance una precisión relativa del 10 %. Además, las regiones fueron seleccionadas mediante la columna nominal del cono homogéneo. El indicador describe la disponibilidad de conteo en ese soporte y no sustituye una evaluación de contraste de todas las anomalías.

4.1.4 Integridad, reproducción y alcance del primer objetivo

La revisión verificó 477 huellas de los productos de fusión y exportación y reprodujo los 9 120 pares, con coincidencia de las 342 huellas de contenido de sus arreglos. Se contrastaron las imágenes con los histogramas y se comprobó la conservación de cuentas y coordenadas. La distribución del conjunto también fue recuperada y verificada de manera independiente. Estas comprobaciones respaldan la identidad de los datos entregados y la reproducción de su posproceso.

No se realizó una segunda campaña independiente de transporte Geant4. La evidencia de esa etapa quedó constituida por la receta, las semillas, los bloques y sus registros. Esta distinción es relevante porque reproducir el submuestreo o verificar un archivo no equivale a reproducir todas las interacciones físicas que originaron la referencia.

El producto obtenido satisface el alcance idealizado adoptado para el OE1: un conjunto de imágenes de transmisión sintéticas, con distintas configuraciones y

estadísticas de conteo. La representación cubre caminos de diferente columna de masa y contrastes de densidad, pero no caracteriza un volcán particular ni una población geológica. El cierre del objetivo conservó la fuente híbrida, el transporte de primarios, la exposición convencional y las siete excepciones de roca como condiciones de interpretación.

4.2 Recuperación de imágenes al cinco por ciento

4.2.1 Modelos seleccionados y resultado de similitud

El piloto concluyó tras doce épocas para U-Net y trece para cGAN. En ambos modelos, el mayor SSIM de validación correspondió a la época cinco, cuyos pesos se conservaron para la evaluación final. Las seis variantes E1 se obtuvieron mediante cinco épocas adicionales desde la cGAN original, manteniendo la última época de cada continuación de acuerdo con el diseño. Por tanto, los ocho modelos representan dos entrenamientos originales y seis continuaciones, no ocho ejecuciones independientes desde cero.

La Tabla 4.2 presenta todos los modelos y el comparador sin red al 5 %. Los valores de Q se expresan en porcentaje; en las fuentes numéricas se almacenan como fracciones. SSIM y PSNR aumentan con la similitud en la representación transformada, mientras que un Q menor indica menor sesgo regional agregado.

En prueba, la cGAN incrementó el SSIM de 0,7643 a 0,8342 y el PSNR de 24,258 a 31,170 dB respecto de la entrada. La U-Net obtuvo valores mayores, de 0,8545 y 33,074 dB. El mismo orden se observó en generalización: U-Net superó a cGAN en ambas métricas, y las dos redes superaron la entrada. Bajo las configuraciones evaluadas, la componente adversaria no proporcionó una ventaja global de SSIM o PSNR frente al generador entrenado únicamente con L1.

La comparación visual de la Figura 4.4 complementa esas cifras con casos fijados por índice. Se mantiene la misma vista y realización en cada geometría y una escala común de la transformación, para evitar que cambios de contraste gráfico se confundan con diferencias entre métodos.

La apariencia más regular de una salida puede ser consistente con un incremento de similitud, pero no demuestra por sí sola recuperación del contenido físico. SSIM y PSNR comparan cada imagen con la misma referencia finita. Además, se calculan después de una transformación no lineal que comprime el intervalo de conteos; una discrepancia pequeña en ese dominio puede traducirse en una diferencia relevante al recuperar cuentas.

Tabla 4.2: Similitud y sesgo regional al 5 % de conteos. Prueba resume tres geometrías con igual peso y generalización corresponde a una. Fuente: síntesis auditada del complemento, consistente con EF-01-C2 en estas métricas.

Método	SSIM	PSNR (dB)	Q (%)
Prueba			
Entrada sin red	0,7643	24,258	1,832
U-Net original	0,8545	33,074	22,388
cGAN original	0,8342	31,170	14,566
B1–C0	0,8277	30,839	5,825
B1–C1	0,8278	30,849	4,821
B2–C0	0,8274	30,772	3,996
B2–C1	0,8273	30,770	4,727
B3–C0	0,8263	30,729	4,828
B3–C1	0,8273	30,768	5,480
Generalización			
Entrada sin red	0,7502	23,904	1,093
U-Net original	0,8454	32,883	26,505
cGAN original	0,8252	31,047	16,959
B1–C0	0,8161	30,485	3,808
B1–C1	0,8151	30,509	4,323
B2–C0	0,8145	30,331	4,131
B2–C1	0,8154	30,403	4,755
B3–C0	0,8149	30,404	4,054
B3–C1	0,8146	30,371	2,271

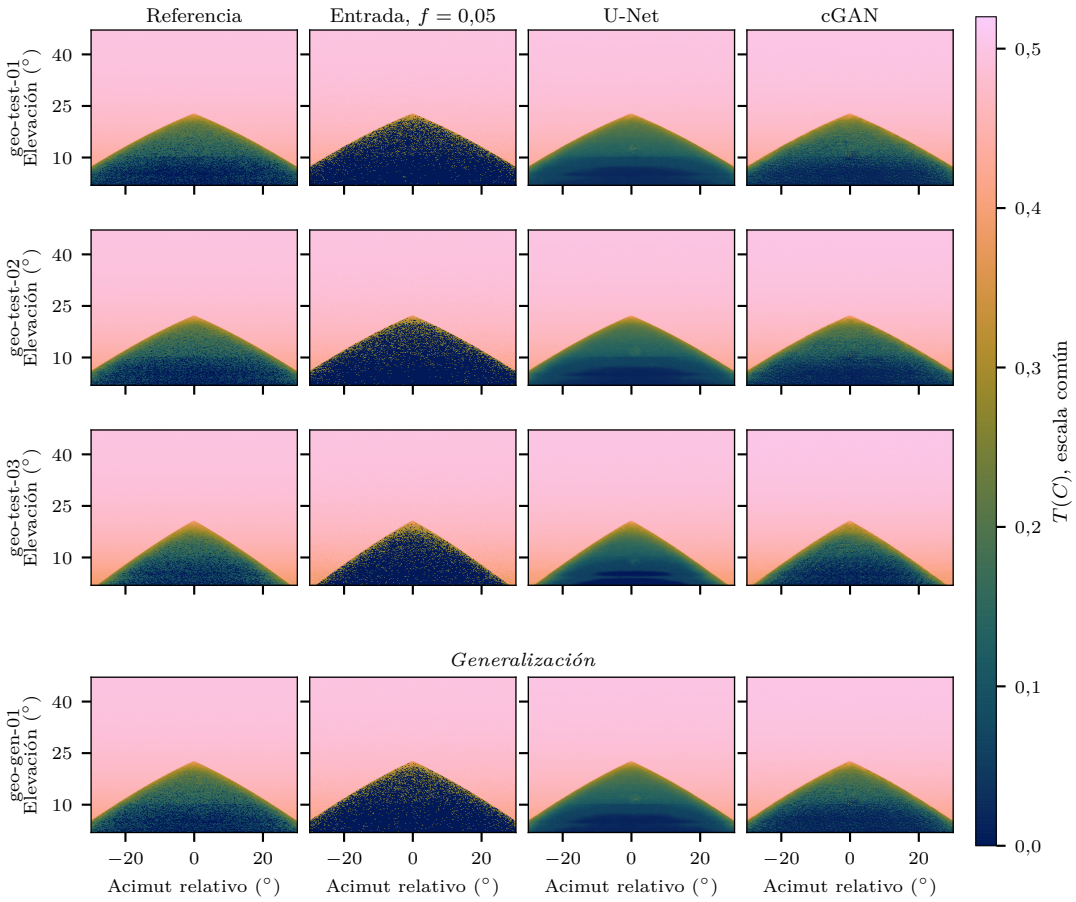

Figura 4.4: Comparación de referencia, entrada y modelos originales en casos fijados por índice.

4.2.2 Compromiso entre similitud y conservación regional

La mejora de SSIM y PSNR coexistió con un aumento del sesgo regional. En prueba, Q pasó de 1,832 % en la entrada a 14,566 % con cGAN y 22,388 % con U-Net. En generalización pasó de 1,093 % a 16,959 y 26,505 %, respectivamente. La Figura 4.5 permite examinar conjuntamente esos indicadores; un desplazamiento hacia mayor similitud no implica necesariamente acercamiento a menor sesgo.

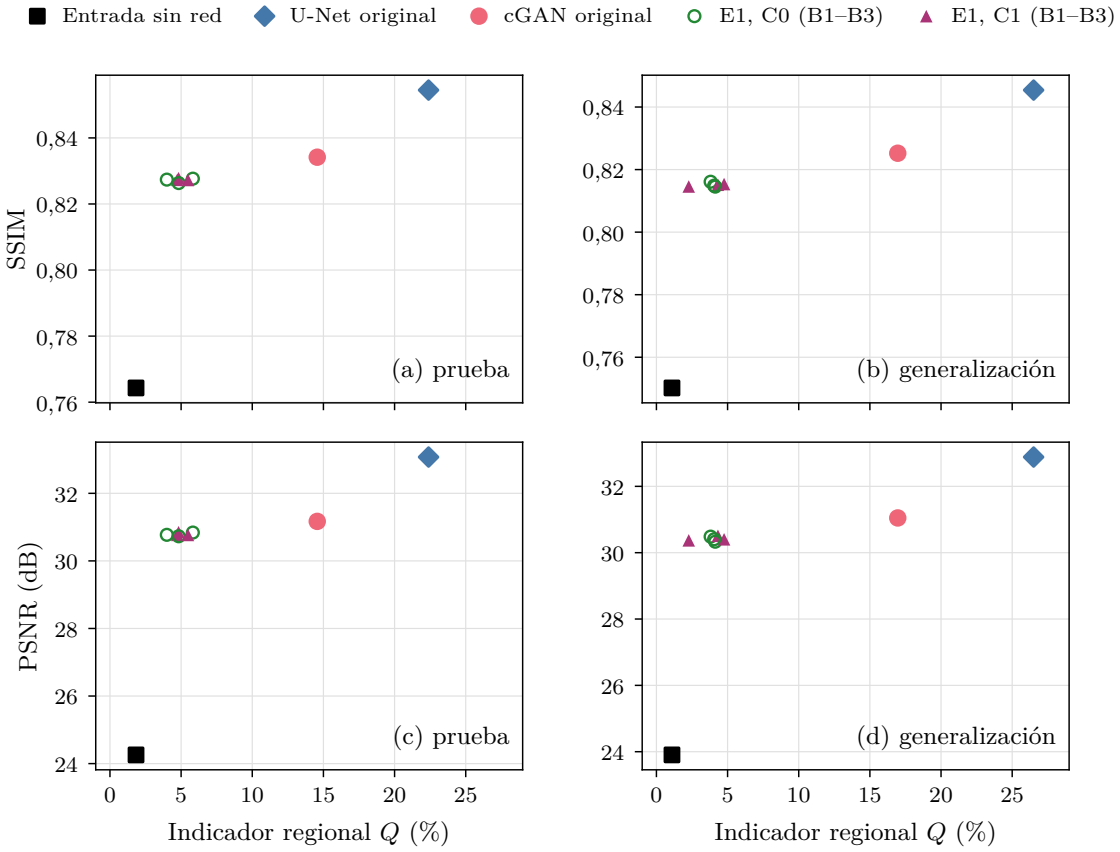

Figura 4.5: Relación de SSIM y PSNR con Q al 5 %, para prueba y generalización por separado. Se conservan las seis continuaciones E1; cada punto representa el resumen de una configuración, no una repetición independiente. Fuente: elaboración de los autores a partir de los resultados EF-01-C2.

La entrada escalada conserva en esperanza condicional las cuentas de la referencia bajo el mecanismo binomial. Ese atributo explica que pueda mantener promedios regionales cercanos a la referencia aun cuando exhiba mayor ruido por píxel. Las redes optimizaron pérdidas que combinan discrepancia transformada y, en la cGAN, una puntuación adversaria. Ninguna de esas pérdidas originales impuso conservación exacta de las cuentas de cada región. Esta diferencia entre lo optimizado y lo evaluado es compatible con el compromiso observado, aunque el experimento no identifica una causa única de todos los sesgos.

Las continuaciones E1 redujeron Q respecto de las redes originales: en prueba

sus valores quedaron entre 3,996 y 5,825 %, con SSIM entre 0,8263 y 0,8278. Persistió, sin embargo, un sesgo superior al de la entrada. La mejora regional se obtuvo junto con una similitud menor que la de U-Net y cGAN originales. No corresponde seleccionar retrospectivamente el menor Q de una semilla y presentarlo como resultado universal del método.

El indicador Q aplica valor absoluto después de promediar sesgos entre realizaciones, según la Ecuación (3.22b). Por tanto, no debe interpretarse como error medio absoluto de todos los píxeles ni como error porcentual de densidad. Sus diferencias se complementan con error espacial y contraste, porque una suma regional cercana a la referencia puede ocultar redistribución interna de cuentas.

4.2.3 Efecto de la pérdida espacial de borde

La Figura 4.6 compara los errores de borde de las tres parejas E1. La variante C1 añade el término espacial al término regional ya presente en C0. La Tabla 4.3 cuantifica la diferencia para cada geometría, calculando la reducción relativa como cien veces uno menos el cociente entre el error C1 y el error C0.

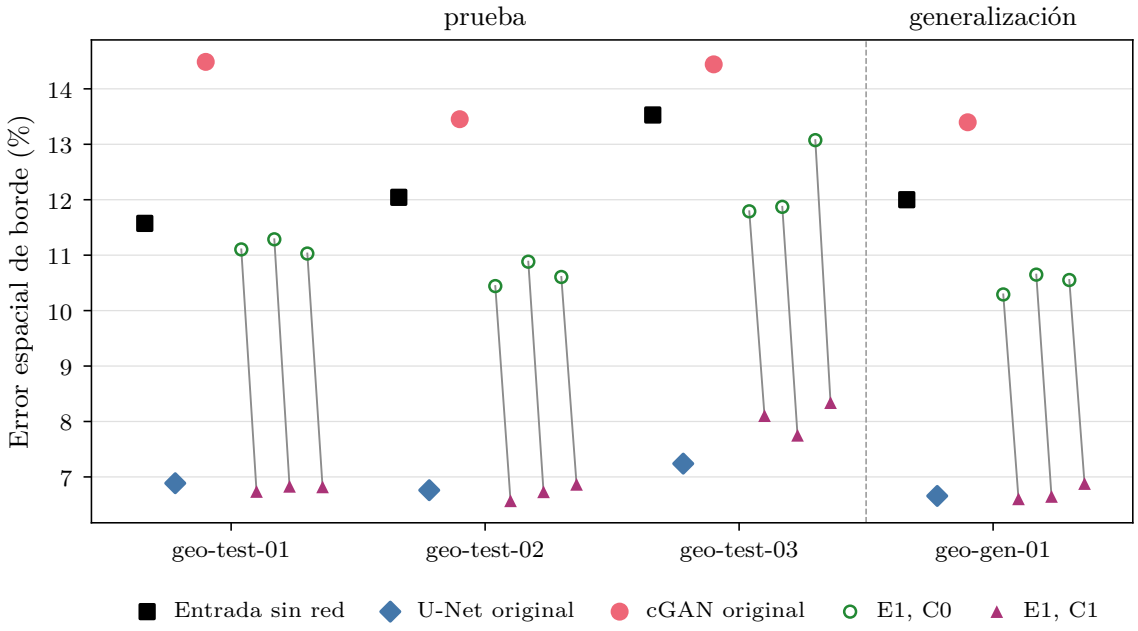

Figura 4.6: Error de borde al 5 % en las cuatro geometrías reservadas. Los segmentos unen C0 y C1 de una misma pareja; los puntos de una geometría no representan réplicas independientes. Se distinguen prueba y generalización. Fuente: elaboración de los autores a partir de EF-01-C2.

C1 redujo el error de borde en las doce comparaciones pareja–geometría, entre 31,26 y 39,49 %. El efecto es coherente con la incorporación de una pérdida que actúa explícitamente sobre esa franja. No obstante, restringir el error de borde no garantiza corregir el interior ni mejorar simultáneamente la similitud y el contraste.

Tabla 4.3: Error espacial de borde en porcentaje y reducción relativa de C1 respecto de C0. Fuente: recálculo desde los resúmenes por geometría de EF-01-C2.

Geometría	Pareja	C0 (%)	C1 (%)	Reducción (%)
`geo-test-01`	B1	11,103	6,737	39,33
`geo-test-01`	B2	11,286	6,830	39,49
`geo-test-01`	B3	11,029	6,819	38,17
`geo-test-02`	B1	10,442	6,569	37,10
`geo-test-02`	B2	10,882	6,731	38,15
`geo-test-02`	B3	10,607	6,865	35,27
`geo-test-03`	B1	11,791	8,105	31,26
`geo-test-03`	B2	11,871	7,750	34,72
`geo-test-03`	B3	13,075	8,339	36,22
`geo-gen-01`	B1	10,291	6,604	35,83
`geo-gen-01`	B2	10,649	6,647	37,58
`geo-gen-01`	B3	10,552	6,880	34,80

Las diferencias de Q entre C0 y C1 cambiaron según pareja y geometría, lo que impide describir C1 como superior en todos los aspectos.

Las doce comparaciones predeclaradas de EF-01, seis por partición, conservaron la clasificación descriptiva de compromiso o deterioro en al menos un indicador. Esa clasificación no expresa significación estadística. Las parejas comparten pesos iniciales y el catálogo reservado tuvo exposición histórica; la evidencia se refiere al comportamiento de las configuraciones y escenas evaluadas.

4.3 Transferencia de los modelos a otras fracciones

4.3.1 Evaluación completa y correspondencia entre entregas

El complemento OE3-C1 añadió 96 matrices con 11 520 predicciones, correspondientes a los ocho modelos, las tres fracciones nuevas y las cuatro geometrías. Junto con las 3 840 salidas al 5 % conservadas de EF-01, se evaluaron 15 360 predicciones. Las redes mantuvieron los pesos ajustados al 5 %, por lo que el resultado describe transferencia entre estadísticas y no entrenamiento especializado para cada nivel de conteo.

La revisión verificó los 294 archivos del manifiesto y las 96 matrices nuevas, con aproximadamente 3,02 GB de datos binarios. El recálculo de tablas y registros numéricos coincidió dentro de la tolerancia establecida entre entornos, con una diferencia absoluta máxima de $7{,}105 \times 10^{-15}$. Esta concordancia respalda la reproducción del cálculo de métricas sobre predicciones conservadas; no se presenta como una repetición local de toda la inferencia GPU ni de los entrenamientos.

4.3.2 Respuesta de la cGAN frente a la estadística de entrada

La Tabla 4.4 compara la cGAN original y la entrada sin red en las cuatro fracciones. Se incluye el comparador de cada fracción para que el desempeño de la red pueda examinarse frente a la información disponible en su propia entrada, además del referente fijo utilizado para el factor de reducción.

Tabla 4.4: Evaluación de la cGAN original y de la entrada sin red en las cuatro fracciones. Se conservan los mismos pesos entrenados al 5 %. Fuente: síntesis auditada OE3-C1.

Fracción	Método	SSIM	PSNR (dB)	Q (%)
Prueba				
1 %	Entrada sin red	0,6959	22,537	2,897
1 %	cGAN original	0,8124	29,264	45,279
5 %	Entrada sin red	0,7643	24,258	1,832
5 %	cGAN original	0,8342	31,170	14,566
10 %	Entrada sin red	0,7964	25,722	1,334
10 %	cGAN original	0,8378	31,213	15,732
50 %	Entrada sin red	0,9250	33,101	0,437
50 %	cGAN original	0,7761	27,255	38,996
Generalización				
1 %	Entrada sin red	0,6851	22,299	3,067
1 %	cGAN original	0,8040	29,069	52,203
5 %	Entrada sin red	0,7502	23,904	1,093
5 %	cGAN original	0,8252	31,047	16,959
10 %	Entrada sin red	0,7834	25,349	0,895
10 %	cGAN original	0,8304	31,174	10,179
50 %	Entrada sin red	0,9197	32,752	0,449
50 %	cGAN original	0,7644	27,274	29,066

En prueba, la cGAN obtuvo SSIM de 0,8124 al 1 %, 0,8342 al 5 % y 0,8378 al 10 %. El PSNR pasó de 29,264 a 31,170 y 31,213 dB en esos niveles. El incremento entre 5 y 10 % fue pequeño frente al cambio de conteos. Al 50 %, el SSIM descendió a 0,7761 y el PSNR a 27,255 dB, por debajo de la entrada sin red con esa fracción. En generalización se observó el mismo deterioro de similitud al 50 %.

El sesgo regional tampoco siguió una reducción uniforme con el conteo. En prueba, Q fue 45,279 % al 1 %, 14,566 % al 5 %, 15,732 % al 10 % y 38,996 % al 50 %. Una entrada con más eventos no aseguró mejor salida de una red entrenada con otra estadística. El escalamiento por la fracción mantiene la esperanza condicional de cuentas, pero no iguala la distribución de fluctuaciones ni convierte el entrenamiento al 5 % en entrenamiento para todas las entradas.

La Figura 4.7 debe leerse junto con la tabla para identificar los cambios de cada modelo sin suponer monotonía. Las ocho redes presentaron menor SSIM y PSNR al 50 % que al 5 % y que la entrada sin red al 50 %, en ambas particiones.

Se conserva el conjunto completo de 72 filas de la síntesis en el material numérico asociado al manuscrito, sin excluir variantes desfavorables.

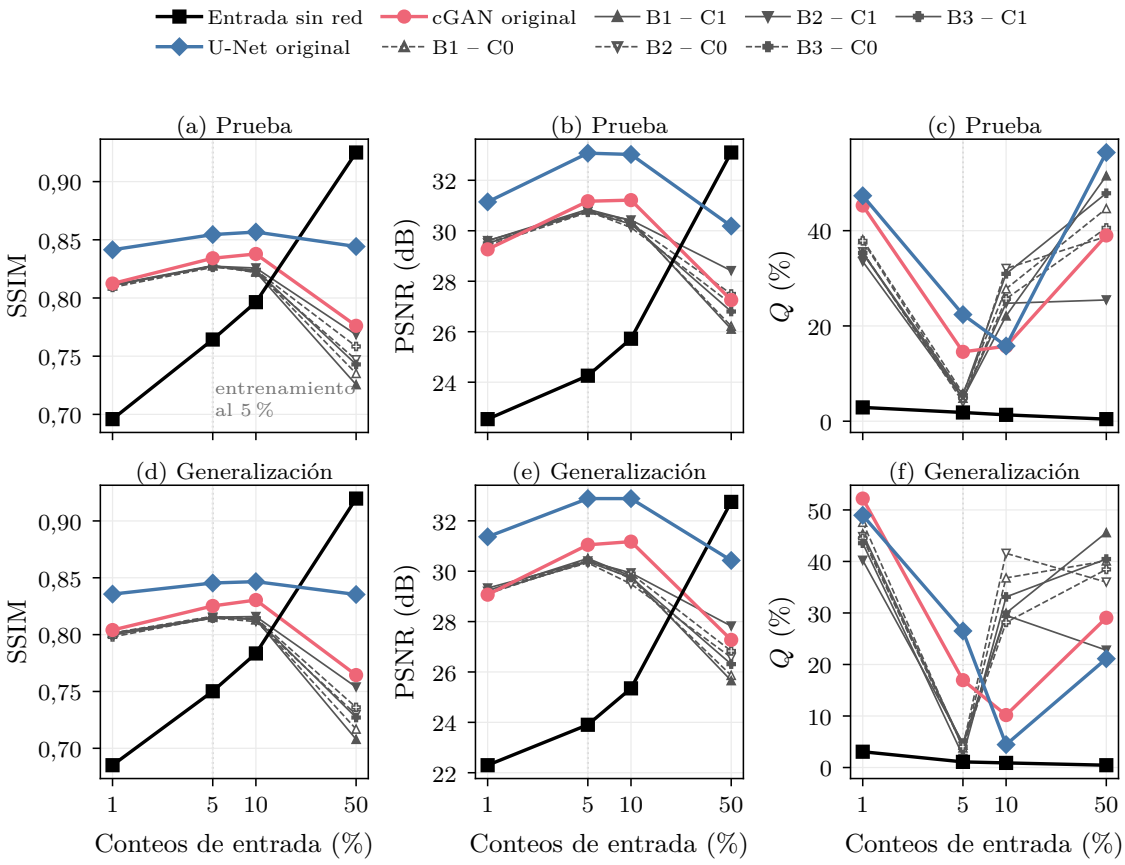

Figura 4.7: Similitud y sesgo regional de los modelos en las cuatro fracciones.

Este comportamiento acota la aplicabilidad de los pesos obtenidos. Es compatible con una dependencia del modelo respecto de la estadística utilizada durante el ajuste, pero no demuestra por sí mismo qué mecanismo interno produjo el deterioro. Tampoco implica que una red entrenada específicamente al 50 % o con varias fracciones reprodujera el mismo resultado. El experimento permite describir el comportamiento observado; una explicación causal requeriría un diseño adicional que no forma parte del estudio cerrado.

4.4 Conservación de anomalías y métricas locales

4.4.1 Soportes y lectura conjunta de los indicadores

La evaluación local se realizó sobre regiones y controles definidos geométricamente, sin seleccionar anomalías por el resultado de la red. En el soporte común multifracción se conservaron diecinueve combinaciones anomalía–vista de prueba y once de generalización para SNR. CNR y contraste utilizaron veintiuna y once, respectivamente.

Los casos no estimables permanecieron identificados y no se sustituyeron por ceros.

La Tabla 4.5 compara la entrada y la cGAN al 5 %. Se presentan errores absolutos respecto de la referencia y proporciones de inversión de signo, siguiendo el orden de agregación de la sección 3.7.2. Cada error se calcula por realización antes de resumir casos y geometrías. Por ello, los valores de contraste de esta tabla no son intercambiables con el resumen histórico C2.

Tabla 4.5: Errores absolutos de indicadores locales y proporción de inversiones de signo del contraste al 5 %. Los tres errores son adimensionales y la última columna se expresa en porcentaje. Fuente: soporte común de la síntesis OE3-C1.

Método	Error SNR	Error CNR	Error contraste	Inversión (%)
Prueba				
Entrada sin red	0,6497	0,0567	0,1707	38,12
cGAN original	0,1804	0,0646	0,0756	43,54
Generalización				
Entrada sin red	0,6509	0,0709	0,1588	40,00
cGAN original	0,0972	0,0825	0,0786	44,09

En prueba, el error de SNR espacial disminuyó de 0,6497 a 0,1804 y el error de contraste de 0,1707 a 0,0756. Simultáneamente, el error de CNR aumentó de 0,0567 a 0,0646 y la proporción de inversión de signo pasó de 38,12 a 43,54 %. En generalización se observó el mismo sentido de cambio: menores errores de SNR y contraste, junto con mayor error de CNR y mayor inversión de signo.

Los indicadores, por tanto, no sostienen una mejora uniforme de la información local. Reducir el error medio de un cociente no garantiza preservar su signo en todos los casos. Una predicción próxima a cero puede reducir una discrepancia grande y, a la vez, cruzar el signo de una referencia pequeña. Además, la referencia conserva fluctuación de conteo, de modo que su signo es sensible en anomalías con contraste cercano a cero. Esta limitación se mantuvo sin eliminar retrospectivamente esos casos mediante un umbral favorable.

4.4.2 Suavizado, señal local y límites de detectabilidad

La reducción de dispersión espacial puede incrementar SNR y regularizar visualmente la imagen. Sin embargo, la dispersión incluye tanto ruido como estructura. Una salida más uniforme puede atenuar una anomalía o modificar su relación con el fondo. El CNR firmado aporta otra perspectiva porque conserva la diferencia entre la media objetivo y la media de controles, relativa a la dispersión de esos controles.

Estas métricas se definieron para estudiar el conjunto sintético y no como probabilidades de detección. La geometría de las anomalías era conocida y se utilizó para construir máscaras; en una aplicación a un volcán real esa información no

estaría disponible necesariamente. En consecuencia, los resultados evalúan preservación en regiones predefinidas, sin demostrar localización autónoma de estructuras desconocidas.

El descenso del error de contraste tampoco puede presentarse como reconstrucción de densidad. El contraste comparó cuentas entre rayos de longitudes próximas y a igual elevación, conservando diferencias geométricas y una referencia finita. La mejora de ese indicador es un resultado específico que debe leerse junto con Q, error espacial y CNR. La coexistencia de mejoras y deterioros constituye el hallazgo, en lugar de un motivo para escoger una única métrica como resumen favorable.

4.5 Factor de reducción y diagnóstico de opacidad

4.5.1 Resultado del criterio operativo por vista

El criterio de la sección 3.8.2 exigió alcanzar simultáneamente SSIM y PSNR del referente sin red al 50 % en todas las vistas de cada partición. Las 768 combinaciones modelo–fracción–vista se conservaron en la evaluación: ocho modelos, cuatro fracciones y veinticuatro vistas. Ninguna satisfizo conjuntamente ambas condiciones. La Tabla 4.6 muestra el balance por modelo y partición.

Tabla 4.6: Combinaciones fracción–vista que alcanzaron conjuntamente SSIM y PSNR del referente al 50 %. Cada modelo tiene 72 comparaciones en prueba y 24 en generalización. El mínimo y el factor no se determinaron en ninguna partición. Fuente: registro auditado de 768 comparaciones OE3-C1.

Modelo	Prueba	Generalización	$f_{\min}$ y R
U-Net original	0/72	0/24	No determinado
cGAN original	0/72	0/24	No determinado
B1–C0	0/72	0/24	No determinado
B1–C1	0/72	0/24	No determinado
B2–C0	0/72	0/24	No determinado
B2–C1	0/72	0/24	No determinado
B3–C0	0/72	0/24	No determinado
B3–C1	0/72	0/24	No determinado

Los conjuntos de aceptación definidos en la Ecuación (3.30) fueron vacíos. Por ello, no se obtuvo un mínimo de la rejilla ni el factor asociado de la Ecuación (3.31b). El resultado se informa como no determinado o no demostrado bajo el criterio adoptado. No corresponde escribir que el factor fue cero, pues no se estimó una razón nula; tampoco fue uno, que habría requerido aceptar la fracción del 50 % sin reducción.

La ausencia de una fracción aceptada es un resultado experimental. El criterio no se cambió después para asegurar una cifra favorable, ni se interpoló entre los

niveles disponibles. El alcance permanece ligado a estos modelos, estas fracciones y este referente. No demuestra que cualquier arquitectura, entrenamiento o conjunto futuro sea incapaz de reducir conteos con calidad útil.

4.5.2 Comparación descriptiva con el doble de conteos

La comparación secundaria de cGAN al 5 % frente a la entrada sin red al 10 % mantuvo una mejora de SSIM y PSNR en las veinticuatro vistas reservadas y en las 480 correspondencias por realización. Ambas imágenes se evaluaron frente a la misma referencia completa. La comparación describe una razón nominal de conteos 2:1; no mide directamente distancia entre la salida de la red y la entrada al 10 %.

En prueba, la entrada al 10 % presentó SSIM de 0,7964 y PSNR de 25,722 dB, frente a 0,8342 y 31,170 dB de cGAN al 5 %. El sesgo regional siguió el comportamiento contrario: Q fue 1,334 % en esa entrada y 14,566 % en la cGAN. La ganancia de similitud no estuvo acompañada de mejor conservación regional.

La comparación 2:1 y el resultado negativo frente al 50 % son compatibles porque utilizan referentes diferentes. La primera documenta una mejora descriptiva de determinadas métricas; el segundo responde al criterio operativo del complemento. Ninguno permite presentar veinte veces menos conteos como reducción efectiva de adquisición con calidad equivalente. La relación entre conteos y tiempo sigue siendo idealizada, sin calibración de un instrumento de campo.

4.5.3 Opacidad nominal y diferencia respecto de una inversión

El diagnóstico geométrico conservó 54 registros de anomalía y vista, de los cuales 48 cumplieron el soporte C2. Se comprobaron unidades y composición mediante cuatro casos analíticos y se reprodujeron los registros geométricos. La descomposición de la Ecuación (3.33) presentó un residuo máximo de aproximadamente $1{,}0004 \times 10^{-10}$ g cm^{-2}, compatible con precisión numérica del cálculo.

En los registros elegibles, la contribución nominal de densidad varió entre $-17\,242{,}01$ y $+5\,616{,}20$ g cm^{-2}. El término debido a diferencia de longitud frente a los controles no cambió el signo de la contribución de densidad en esos casos. Estos valores describen el catálogo y los rayos seleccionados; no son errores de reconstrucción de una red ni umbrales de detección de anomalías.

La Figura 4.8 separa las contribuciones geométricas para facilitar su interpretación. Se deben conservar las seis filas elegibles de la anomalía 2 de `geo-gen-01` con su advertencia de material: el catálogo declara 0,048 g cm^{-3}, mientras el constructor conservado utiliza aire para densidades inferiores a 0,05 g cm^{-3}. El diagnóstico no certificó la densidad efectiva de cada material del binario de producción.

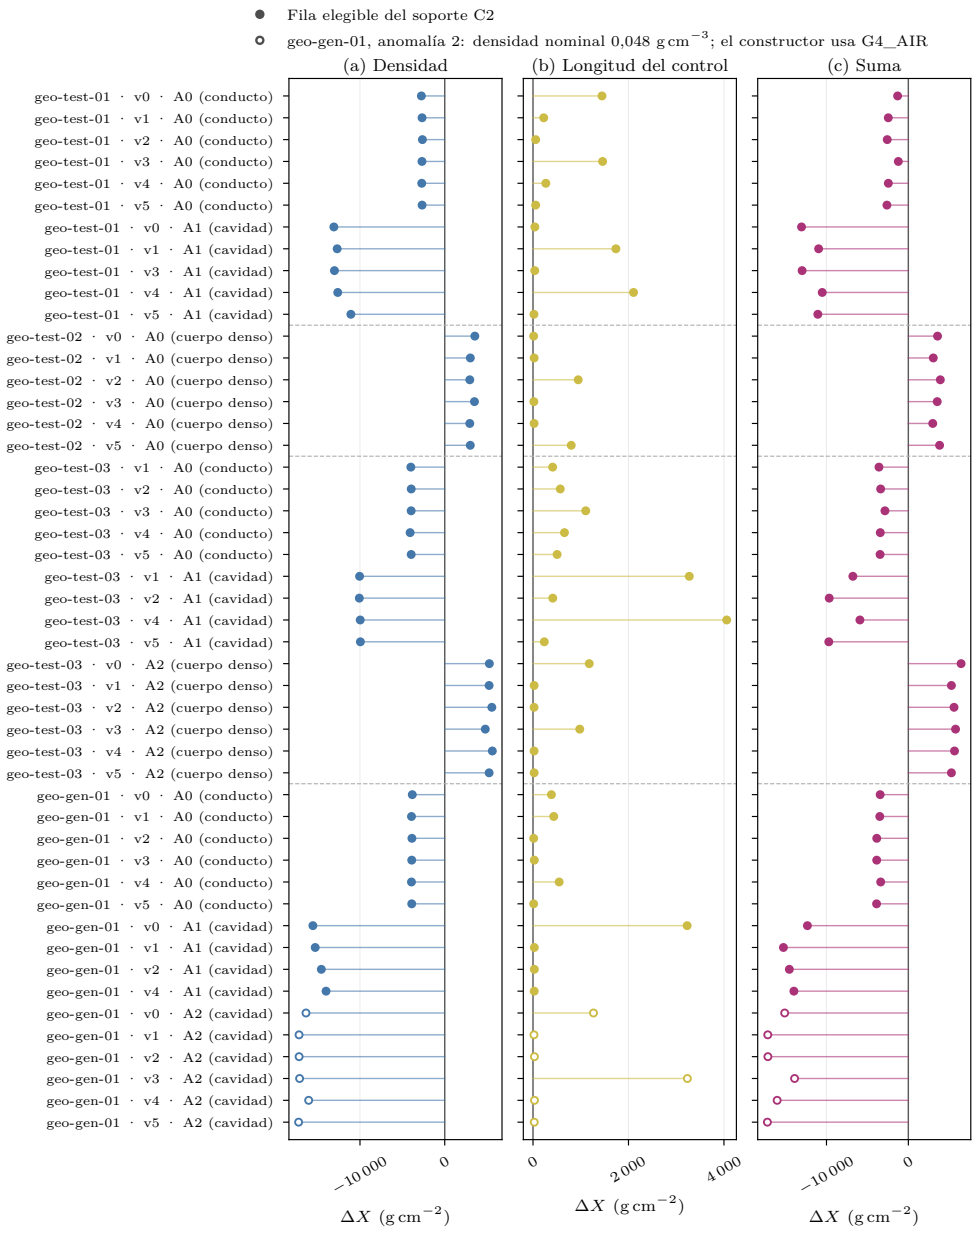

Opacidad nominal del catálogo, no reconstruida por la red.
Filas no elegibles, sin valor asignado: geo-test-01 v2 A1; geo-test-03 v0 A0; geo-test-03 v0 A1; geo-test-03 v3 A1; geo-gen-01 v3 A1; geo-gen-01 v5 A1

Figura 4.8: Contribuciones nominales de densidad y longitud en los controles geométricos.

El contraste de cuentas es adimensional, mientras que la opacidad integra densidad y longitud. Calcular esta última desde una geometría conocida no demuestra que pueda recuperarse desde la imagen mejorada. No se ejecutó una inversión validada de las predicciones a opacidad. Ese componente quedó delimitado como alcance parcial del trabajo, sin resolverlo mediante un cambio de nombre del contraste ni atribuir causalmente el desempeño de las redes a la discrepancia de material.

4.6 Discusión integrada y alcance de los resultados

4.6.1 Correspondencia entre la tarea aprendida y la calidad evaluada

El experimento mostró que una red puede aproximarse a una referencia en la escala utilizada para entrenar y conservar, al mismo tiempo, discrepancias relevantes en cuentas. U-Net alcanzó los mayores SSIM y PSNR al 5 %, pero también el mayor Q entre los modelos originales. La cGAN presentó un compromiso diferente, sin dominar al control en todas las métricas. Las continuaciones redujeron parte del sesgo y el término espacial mejoró el borde, aunque ninguna configuración eliminó de forma conjunta todas las discrepancias.

Estos resultados hacen necesario precisar la expresión calidad comparable. Si se refiere a SSIM y PSNR frente a entradas de baja estadística, existe una mejora documentada. Si se exige el criterio conjunto frente al referente sin red al 50 %, no se obtuvo aceptación en la rejilla. Si se pretende conservación cuantitativa de cuentas, contraste y opacidad, las alteraciones regionales y la ausencia de inversión limitan esa afirmación. Las tres lecturas responden a preguntas distintas y se mantienen separadas.

La transformación acotada contribuye a explicar por qué los indicadores deben examinarse en más de un dominio: comprime los conteos y su inversa amplifica de manera no uniforme las discrepancias. Sin embargo, esta propiedad matemática no prueba por sí sola el origen de cada error observado. El análisis permite establecer coexistencia y límites, sin atribuir todos los efectos a un único componente de la arquitectura o de la pérdida.

4.6.2 Dependencia de los datos y alcance de generalización

El número de escenarios reservados fue pequeño: tres de prueba y uno de generalización. Las veinte realizaciones de una vista comparten referencia y las vistas comparten geometría. Por ello, las numerosas predicciones no constituyen miles de escenarios independientes. Los promedios y comparaciones describen este catálogo, sin estimar una tasa poblacional de generalización a volcanes.

Las escenas reservadas tuvieron exposición histórica durante etapas anteriores. Aunque los modelos finales se ajustaron con entrenamiento y validación, esa historia impide presentar la evaluación como confirmación completamente independiente. De igual forma, el criterio del complemento se estableció antes de las nuevas inferencias, pero después de conocer resultados previos. Su aplicación fue explícita y completa; su carácter posterior limita la fuerza de la inferencia, no convierte el resultado desfavorable en una actividad sin ejecutar.

Las referencias de alta estadística son finitas. El submuestreo comparte eventos con ellas y la verdad de comparación corresponde a esa realización sintética, no a una intensidad instrumental exacta. La evaluación conserva ese vínculo y no extrapola automáticamente la mejora a adquisiciones independientes o a observaciones reales con fondo, respuesta del detector y condiciones ambientales variables.

4.6.3 Balance del experimento concluido

La Tabla 4.7 relaciona los productos obtenidos con las afirmaciones que la evidencia permite sostener. El cierre operativo de los tres objetivos se distingue del alcance científico de sus conclusiones.

Tabla 4.7: Balance de resultados y alcance de los tres objetivos.

Objetivo	Resultado obtenido	Alcance sustentado
OE1	Conjunto de 114 referencias y 9 120 pares, con controles e integridad revisados.	Cumplido y cerrado dentro de la familia sintética idealizada; sin equivalencia instrumental.
OE2	cGAN implementada y entrenada; comparación con U-Net y seis continuaciones; mejoras de similitud al 5 %.	Ejecución y evaluación concluidas. Calidad comparable respaldada parcialmente por persistencia de sesgos y compromisos.
OE3	Evaluación de ocho modelos en cuatro fracciones; indicadores locales y criterio por vista aplicados.	Experimento concluido con factor no demostrado bajo el criterio adoptado; sin reconstrucción cuantitativa de opacidad.

La aportación del estudio comprende tanto los productos reproducibles como la delimitación de su utilidad. Se obtuvo una cadena verificable desde la simulación hasta la evaluación multifracción y se cuantificó la diferencia entre suavizar imágenes, aumentar similitud y preservar cantidades relevantes para la muografía. El resultado negativo del criterio principal y los comportamientos locales desfavorables se conservan como parte de esa evidencia.

5. Conclusiones y trabajo futuro

Este capítulo resume, para cada objetivo, lo que se logró y lo que no pudo demostrarse con la evidencia del capítulo 4, y presenta posibles líneas de investigación que darían continuidad al trabajo. Los objetivos se cumplieron de forma parcial: las actividades de los tres objetivos se ejecutaron y revisaron, pero el alcance de las afirmaciones del segundo y del tercero quedó delimitado por los resultados.

5.1 Conclusión del primer objetivo específico

Se generó el conjunto de datos sintéticos que el primer objetivo formuló, dentro del alcance idealizado adoptado. La simulación en Geant4 de diecinueve escenarios volcánicos produjo 114 referencias de alta estadística y, por submuestreo binomial, 9 120 pares de entrada y referencia con cuatro fracciones de conteo, particionados por geometría completa. Las 1 710 regiones de borde cumplieron el criterio fijado antes de la campaña y 107 de las 114 vistas alcanzaron la meta descriptiva de conteo en roca; las siete restantes se conservaron como excepciones (sección 4.1).

No se demostró la equivalencia de estas imágenes con las de un instrumento real. El conjunto representa mecanismos y configuraciones de una familia idealizada, no un volcán particular; registra muones primarios sin fondo ni respuesta de detector, su exposición es una escala convencional y no se repitió la campaña de transporte de forma independiente.

5.2 Conclusión del segundo objetivo específico

Se diseñó, implementó, entrenó y evaluó el modelo generativo condicional que el segundo objetivo formuló. Con el 5 % de los conteos, la cGAN aumentó en prueba el SSIM de 0,7643 a 0,8342 y el PSNR de 24,258 a 31,170 dB respecto de la entrada, con el mismo patrón en generalización (tabla 4.2). La U-Net entrenada solo con $\mathcal{L}_1$ alcanzó valores mayores, de modo que no se observó una ventaja general de similitud atribuible a la componente adversaria bajo las configuraciones evaluadas.

La calidad comparable a la de alta estadística quedó respaldada solo de forma parcial. La mejora de similitud coexistió con un aumento del sesgo regional de cuentas, que en prueba pasó de 1,832 % en la entrada a 14,566 % con la cGAN. Las continuaciones con pérdidas regional y espacial redujeron ese sesgo y el error de borde, pero ninguna configuración mejoró simultáneamente todos los indicadores, y las doce comparaciones predeclaradas se clasificaron como compromiso o deterioro (sección 4.2). El experimento no identificó una causa única de esos sesgos. La

conclusión corresponde a una evaluación descriptiva sobre datos potencialmente expuestos y a referencias idealizadas.

5.3 Conclusión del tercer objetivo específico

Se evaluó el desempeño de los ocho modelos con entradas al 1, 5, 10 y 50 % de los conteos y se aplicó a toda la rejilla el criterio por vista fijado antes de las nuevas inferencias, que exigía alcanzar a la vez el SSIM y el PSNR de la entrada sin red al 50 %. Con ese criterio no se logró demostrar un factor de reducción del tiempo de adquisición: ninguna de las 768 combinaciones de modelo, fracción y vista cumplió ambas condiciones, y la fracción mínima y el factor asociado quedaron no determinados (tabla 4.6).

Los demás resultados de la evaluación no modifican esa conclusión. La cGAN al 5 % superó en similitud a la entrada sin red al 10 % en las veinticuatro vistas reservadas, pero con mayor sesgo regional; esa relación de dos a uno es una comparación descriptiva y no un factor de reducción. La razón nominal de veinte describe solo la reducción de conteos de la entrada. Al 50 %, las ocho redes presentaron menor similitud que al 5 % y que la entrada sin red con esa fracción (sección 4.3). En los indicadores locales disminuyeron los errores de SNR y de contraste, pero aumentaron el error de CNR y las inversiones de signo (sección 4.4). No se realizó una inversión de las predicciones a opacidad. Se evaluó, por tanto, el desempeño de los modelos y se delimitó su aplicabilidad; se observaron mejoras de similitud a baja estadística, pero no se demostró un factor de reducción bajo el criterio adoptado ni equivalencia cuantitativa de opacidad.

5.4 Conclusión general

El objetivo general, desarrollar y validar un esquema de reconstrucción muográfica asistido por aprendizaje profundo para reducir el tiempo efectivo de adquisición, evaluando la mejora en calidad y detectabilidad de estructuras internas, se cumplió de forma parcial. Se desarrolló una cadena completa y verificable, desde la simulación hasta la evaluación multifracción, y se cuantificó que aumentar la similitud global y preservar las cuentas regionales resultaron propiedades distintas: las redes mejoraron la similitud a baja estadística y, al mismo tiempo, alteraron cuentas en regiones relevantes para la interpretación. La validación del esquema como medio para reducir el tiempo de adquisición no se alcanzó, porque ningún modelo cumplió el criterio adoptado y la relación entre conteos y tiempo se mantuvo idealizada.

Respecto de las estructuras internas, los indicadores locales se calcularon en regiones cuya ubicación se conocía a partir de la geometría de cada escenario.

Ese diseño permitió estudiar cómo se comportan la intensidad, el contraste y su signo en esas regiones, pero no demuestra que el modelo detecte o localice anomalías desconocidas. El resultado negativo del criterio principal se conserva como parte de la evidencia; no equivale a un factor nulo ni a la imposibilidad de que otra arquitectura, otro entrenamiento u otro conjunto reduzcan los conteos con calidad útil.

5.5 Trabajo futuro

Las líneas que siguen se proponen como continuación posible del trabajo y no como tareas pendientes de este estudio, cuyos resultados se presentaron en el capítulo 4. Ninguna de ellas garantiza un resultado favorable; cada una exigiría una pregunta, un protocolo y unos criterios propios, declarados antes de evaluar nuevos casos. La tabla 5.1 relaciona cada limitación identificada con una línea de investigación posible y con lo que esta permitiría evaluar.

Tabla 5.1: Limitaciones identificadas en el estudio y posibles líneas de investigación posteriores. Las líneas son propuestas y no resultados del trabajo.

Componente	Limitación identificada	Línea posible	Qué permitiría evaluar
Criterio y reserva	Criterio fijado después de resultados históricos; escenas reservadas con exposición previa.	Criterios declarados de antemano y escenas nuevas sin inspeccionar.	Desempeño en una evaluación confirmatoria.
Factor de reducción	Ninguna combinación cumplió el criterio; redes entrenadas solo al 5 %.	Entrenamiento con varias fracciones y repeticiones independientes.	Si existe una fracción aceptada bajo criterios previos.
Conservación de cuentas	Sesgo regional mayor que el de la entrada en todas las redes.	Pérdidas acordes con el modelo de conteo.	El compromiso entre similitud y conservación.
Anomalías	Indicadores calculados en regiones de ubicación conocida.	Evaluación sin información de ubicación.	La detección de anomalías no informadas.
Opacidad	Sin modelo de respuesta ni inversión de las predicciones.	Inversión de opacidad con un modelo de respuesta.	La relación entre cuentas predichas y opacidad.
Instrumento real	Primarios sin fondo ni detector; exposición convencional.	Simulación instrumental y adquisiciones de campo.	La reducción efectiva del tiempo de adquisición.

Como condición común, se propone fijar antes de cualquier evaluación nueva los criterios de aceptación de SSIM y PSNR, justificados por la aplicación o por una referencia externa, y generar escenas de reserva después de fijar el protocolo, manteniéndolas sin inspeccionar hasta la evaluación final (Kaufman et al., 2012). Esta medida no cambiaría el resultado obtenido, pero permitiría que una evaluación posterior tuviera carácter confirmatorio y que incluyera varias geometrías de generalización.

Se propone investigar el entrenamiento con varias fracciones de entrada, con repeticiones independientes desde la inicialización. Sería útil porque los modelos del estudio se entrenaron solo al 5 % y su evaluación con otras fracciones midió transferencia; esta línea permitiría evaluar si un modelo adaptado a cada nivel de conteo alcanza el criterio en alguna fracción. Podría mejorar el desempeño en otras fracciones, pero no garantiza un factor de reducción aceptable. El algoritmo A.1, incluido en el anexo A, describe un protocolo posible.

Se propone investigar pérdidas basadas en la verosimilitud del proceso de conteo y restricciones de conservación regional. Sería útil porque las pérdidas empleadas no imponían la conservación exacta de las cuentas; una hipótesis compatible con los resultados, que el estudio no comprobó, es que esa propiedad de las pérdidas contribuya al sesgo observado. Esta línea permitiría evaluar si es posible reducir el sesgo sin la pérdida de similitud que se observó en las continuaciones.

Se propone evaluar las anomalías sin proporcionar su ubicación, con escenas cuya estructura no se informe al evaluador. Sería útil porque los indicadores del estudio dependen de regiones conocidas; esta línea permitiría estimar si las imágenes mejoradas facilitan la detección y la localización de estructuras desconocidas.

Como investigación posterior, la inversión de las predicciones a opacidad requeriría un modelo de respuesta que relacione los conteos con el flujo, la opacidad y la detección, validado en un conjunto distinto del usado para ajustarlo. Permitiría evaluar si las cuentas predichas conservan la información de opacidad que el contraste de cuentas no expresa por sí solo.

También como investigación posterior, la validación con un instrumento real incluiría la simulación del fondo y de la respuesta de un detector, la topografía de un volcán concreto y adquisiciones de campo de exposición prolongada, que podrían dividirse en intervalos más cortos para obtener pares de baja y alta estadística (Lechmann et al., 2021; Lesparre et al., 2010). Esta línea permitiría evaluar si la mejora observada en datos sintéticos se mantiene con datos reales y medir una reducción efectiva del tiempo de adquisición.

Referencias

Agostinelli, S., Allison, J., Amako, K., Apostolakis, J., Araujo, H., Arce, P., Asai, M., et al. (2003). Geant4—a simulation toolkit. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, *506*(3), 250-303. https://doi.org/10.1016/S0168-9002(03)01368-8

Allison, J., Amako, K., Apostolakis, J., Arce, P., Asai, M., Aso, T., Bagli, E., et al. (2016). Recent developments in Geant4. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, *835*, 186-225. https://doi.org/10.1016/j.nima.2016.06.125

Arjovsky, M., Chintala, S., & Bottou, L. (2017). *Wasserstein GAN*. arXiv: 1701.07875. https://doi.org/10.48550/arXiv.1701.07875

Blau, Y., & Michaeli, T. (2018). The perception-distortion tradeoff. *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 6228-6237. https://doi.org/10.1109/CVPR.2018.00652

Bonomi, G., Checchia, P., D'Errico, M., Pagano, D., & Saracino, G. (2020). Applications of cosmic-ray muons. *Progress in Particle and Nuclear Physics*, *112*, Artículo 103768. https://doi.org/10.1016/j.ppnp.2020.103768

Cárdenas Tirado, R., & Pinto Ortega, D. A. (2026). *Propuesta de capítulos de la tesis* [Rama propuesta/capitulos-tesis]. https://github.com/anlegogo/muografia-documentada/tree/propuesta/capitulos-tesis/propuesta-capitulos

Clopper, C. J., & Pearson, E. S. (1934). The Use of Confidence or Fiducial Limits Illustrated in the Case of the Binomial. *Biometrika*, *26*(4), 404-413. https://doi.org/10.1093/biomet/26.4.404

Cohen, J. P., Luck, M., & Honari, S. (2018). Distribution matching losses can hallucinate features in medical image translation. En A. F. Frangi, J. A. Schnabel, C. Davatzikos, C. Alberola-López & G. Fichtinger (Eds.), *Medical Image Computing and Computer Assisted Intervention – MICCAI 2018* (pp. 529-536). Springer. https://doi.org/10.1007/978-3-030-00928-1_60

Dunn, O. J. (1961). Multiple Comparisons among Means. *Journal of the American Statistical Association*, *56*(293), 52-64. https://doi.org/10.1080/01621459.1961.10482090

Gaisser, T. K., Engel, R., & Resconi, E. (2016). *Cosmic Rays and Particle Physics* (2ª ed.). Cambridge University Press. https://doi.org/10.1017/CBO9781139192194

Galgóczi, G., Albrecht, G., Hamar, G., & Varga, D. (2024). Background suppression for volcano muography with machine learning. *Machine Learning: Science and Technology*, *5*(3), 035032. https://doi.org/10.1088/2632-2153/ad64a7

González Gómez, A. L., Cárdenas Tirado, R., & Pinto Ortega, D. A. (2026). *muografia-documentada: repositorio documental del trabajo de grado* [Revisión 9558099]. https://github.com/anlegogo/muografia-documentada

Goodfellow, I. J., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A., & Bengio, Y. (2014). Generative adversarial nets. *Advances in Neural Information Processing Systems*, *27*, 2672-2680. https://doi.org/10.48550/arXiv.1406.2661

Groom, D. E., Mokhov, N. V., & Striganov, S. I. (2001). Muon stopping power and range tables 10 MeV–100 TeV. *Atomic Data and Nuclear Data Tables*, *78*(2), 183-356. https://doi.org/10.1006/adnd.2001.0861

Guan, M., Chu, M.-C., Cao, J., Luk, K.-B., & Yang, C. (2015). A parametrization of the cosmic-ray muon flux at sea-level. *arXiv preprint arXiv:1509.06176*. https://arxiv.org/abs/1509.06176

Gulrajani, I., Ahmed, F., Arjovsky, M., Dumoulin, V., & Courville, A. C. (2017). Improved training of Wasserstein GANs. *Advances in Neural Information Processing Systems*, *30*. https://doi.org/10.48550/arXiv.1704.00028

Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., et al. (2020). Array programming with NumPy. *Nature*, *585*(7825), 357-362. https://doi.org/10.1038/s41586-020-2649-2

Horé, A., & Ziou, D. (2010). Image quality metrics: PSNR vs. SSIM. *2010 20th International Conference on Pattern Recognition*, 2366-2369. https://doi.org/10.1109/ICPR.2010.579

Isola, P., Zhu, J.-Y., Zhou, T., & Efros, A. A. (2017). Image-to-image translation with conditional adversarial networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 1125-1134. https://doi.org/10.1109/CVPR.2017.632

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4), Artículo 15. https://doi.org/10.1145/2382577.2382579

Kingma, D. P., & Ba, J. (2015). *Adam: A method for stochastic optimization*. arXiv: 1412.6980. https://doi.org/10.48550/arXiv.1412.6980

Kingman, J. F. C. (1992). *Poisson Processes* (Vol. 3). Oxford University Press. https://doi.org/10.1093/oso/9780198536932.001.0001

Lechmann, A., Mair, D., Ariga, A., Ariga, T., Ereditato, A., Nishiyama, R., Pistillo, C., Scampoli, P., Schlunegger, F., & Vladymyrov, M. (2021). Muon tomography in geoscientific research – A guide to best practice. *Earth-Science Reviews*, *222*, Artículo 103842. https://doi.org/10.1016/j.earscirev.2021.103842

Lefevre, B., Attié, D., Bajou, R., & Gomez, H. (2024). 2D and 3D analysis improvements with machine learning for muography applications. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, *1068*, 169755. https://doi.org/10.1016/j.nima.2024.169755

Lesparre, N., Gibert, D., Marteau, J., Déclais, Y., Carbone, D., & Galichet, E. (2010). Geophysical muon imaging: feasibility and limits. *Geophysical Journal International*, *183*(3), 1348-1361. https://doi.org/10.1111/j.1365-246X.2010.04790.x

Luo, S., Feng, C., Zeng, G., Feng, S., Shen, M., Huang, X., Wang, L., Zhao, S., Du, X., Feng, S., Xiao, M., Liu, Z., & Wang, X. (2025). Image reconstruction techniques in muography: A review of algorithms and physical principles. *Journal of Applied Physics*, *138*(4), 041101. https://doi.org/10.1063/5.0273072

Mirza, M., & Osindero, S. (2014). *Conditional generative adversarial nets*. arXiv: 1411.1784. https://doi.org/10.48550/arXiv.1411.1784

O'Donnell, W., Mahon, D., Yang, G., & Gardner, S. (2025). Muographic Image Upsampling with Machine Learning for Built Infrastructure Applications. *Particles*, *8*(1), 33. https://doi.org/10.3390/particles8010033

Oláh, L., Tanaka, H. K. M., Ohminato, T., & Varga, D. (2018). High-definition and low-noise muography of the Sakurajima volcano with gaseous tracking detectors. *Scientific Reports*, *8*, 3207. https://doi.org/10.1038/s41598-018-21423-9

Pagano, D., Bonomi, G., Donzella, A., Zenoni, A., Zumerle, G., & Zurlo, N. (2021). EcoMug: An Efficient COsmic MUon Generator for cosmic-ray muon applications. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, *1014*, Artículo 165732. https://doi.org/10.1016/j.nima.2021.165732

Particle Data Group, Workman, R. L., Burkert, V. D., Crede, V., Klempt, E., Thoma, U., Tiator, L., Agashe, K., Aielli, G., Allanach, B. C., et al. (2022). Review of

particle physics. *Progress of Theoretical and Experimental Physics*, *2022*(8), 083C01. https://doi.org/10.1093/ptep/ptac097

Peña-Rodríguez, J., Pisco-Guabave, J., Sierra-Porta, D., Suárez-Durán, M., Arenas-Flórez, M., Pérez-Archila, L. M., Sanabria-Gómez, J. D., Asorey, H., & Núñez, L. A. (2020). Design and construction of MuTe: A hybrid muon telescope to study Colombian volcanoes. *Journal of Instrumentation*, *15*(09), P09006. https://doi.org/10.1088/1748-0221/15/09/P09006

Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional networks for biomedical image segmentation. *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, *9351*, 234-241. https://doi.org/10.1007/978-3-319-24574-4_28

Sattler, F. A., Alameddine, J. M., Bueno Rodríguez, Á., Stephan, M., & Barnes, S. (2025). A comprehensive framework toward the seamless integration of muon reconstruction algorithms with machine learning. *Journal of Applied Physics*, *138*(14), 144904. https://doi.org/10.1063/5.0288348

Tanaka, H. K. M., Bozza, C., Bross, A., Cantoni, E., Catalano, O., Cerretto, G., Giammanco, A., Glukhov, S., Holma, M., Kin, T., et al. (2023). Muography. *Nature Reviews Methods Primers*, *3*, 88. https://doi.org/10.1038/s43586-023-00270-7

Tanaka, H. K. M., Nakano, T., Takahashi, S., Yoshida, J., Takeo, M., Oikawa, J., Ohminato, T., Aoki, Y., Koyama, E., Tsuji, A., & Niwa, K. (2007). High resolution imaging in the inhomogeneous crust with cosmic-ray muon radiography: The density structure below the volcanic crater floor of Mt. Asama, Japan. *Earth and Planetary Science Letters*, *263*(1–2), 104-113. https://doi.org/10.1016/j.epsl.2007.09.001

Vinodkumar, P. K., Avots, E., Ozcinar, C., & Anbarjafari, G. (2025). 3D reconstruction and denoising of high-Z materials from muon tomography using 3D CNN. *Signal, Image and Video Processing*, *19*(5), 378. https://doi.org/10.1007/s11760-025-03992-1

Wang, H., Yu, P., Chen, L., He, W., Zhang, Y., Yu, Y., Zhang, X., Yang, L., & Sun, Z. (2026). U-Net based image enhancement for short-time muon scattering tomography. *Nuclear Instruments and Methods in Physics Research Section A: Accelerators, Spectrometers, Detectors and Associated Equipment*, *1092*, 171797. https://doi.org/10.1016/j.nima.2026.171797

Wang, Z., Bovik, A. C., Sheikh, H. R., & Simoncelli, E. P. (2004). Image quality assessment: From error visibility to structural similarity. *IEEE Transactions on Image Processing*, *13*(4), 600-612. https://doi.org/10.1109/TIP.2003.819861

Yang, Q., Yan, P., Zhang, Y., Yu, H., Shi, Y., Mou, X., Kalra, M. K., Zhang, Y., Sun, L., & Wang, G. (2018). Low-dose CT image denoising using a generative adversarial network with Wasserstein distance and perceptual loss. *IEEE Transactions on Medical Imaging*, *37*(6), 1348-1357. https://doi.org/10.1109/TMI.2018.2827462

A. Protocolo propuesto para estimar el factor de reducción

Este anexo detalla un protocolo posible para la línea de entrenamiento con varias fracciones descrita en la sección 5.5. Es una propuesta que no se ejecutó en este trabajo. Su finalidad es que la determinación del factor de reducción se realice con criterios fijados antes de evaluar y sobre escenas no inspeccionadas, y que el resultado, favorable o no, se informe completo. La regla de decisión es la del algoritmo 3.3, con las Ecuaciones (3.30) a (3.31b). El algoritmo A.1 resume las entradas, las salidas y los pasos.

Algoritmo A.1 Protocolo prospectivo propuesto para estimar el factor de reducción.

Entrada: Cadena verificada de simulación y submuestreo; rejilla de fracciones de entrada; criterios de aceptación de SSIM y PSNR justificados por la aplicación o por una referencia externa; número de repeticiones de entrenamiento.

Salida: Conjunto de fracciones aceptadas por modelo y partición; fracción mínima y factor asociado, o su condición de no determinados; registro completo de comparaciones y variabilidad entre repeticiones.

1: Registrar criterios, rejilla, métricas, particiones y número de repeticiones antes de generar escenas nuevas.
2: Generar geometrías nuevas de prueba y de generalización con la cadena verificada y mantenerlas sin inspeccionar.
3: **para** cada repetición independiente **hacer**
4: Inicializar los pesos con una semilla registrada.
5: Entrenar con entradas de varias fracciones y seleccionar los pesos solo con validación.
6: Congelar los pesos y registrar sus huellas.
7: **fin para**
8: **para** cada modelo, fracción y vista de las escenas nuevas **hacer**
9: Calcular SSIM y PSNR por realización frente a la referencia y promediarlos por vista.
10: Calcular la conservación regional y los indicadores locales como evidencia complementaria.
11: **fin para**
12: **para** cada modelo y cada partición **hacer**
13: Aplicar la regla del algoritmo 3.3 con los criterios registrados.
14: **si** el conjunto de fracciones aceptadas está vacío **entonces**
15: Informar la fracción mínima y el factor como no determinados.
16: **en otro caso**
17: Informar la fracción mínima y el factor asociado.
18: **fin si**
19: **fin para**
20: Informar la variabilidad entre repeticiones sin seleccionar la más favorable.